



SZKOŁA GŁÓWNA HANDLOWA W WARSZAWIE
WARSAW SCHOOL OF ECONOMICS

Studium Magisterskie

Kierunek Metody Ilościowe w Ekonomii i Systemy Informacyjne

Specjalność 1 Systemy informatyczne w zarządzaniu

Specjalność 2 Consulting IT w przedsiębiorstwie

Michał Żbikowski

Nr albumu 58354

**Wieloagentowy model zero-intelligence-trader (ZIT)
wykorzystujący model rynków finansowych bazujący na
podwójnej ciągłej aukcji.**

Praca magisterska napisana w
Instytucie Ekonometrii, Zakładzie Wspomagania i Analizy Decyzji
pod kierunkiem naukowym
dr Przemysława Szufla

Warszawa 2015

Spis treści

1	Wprowadzenie	5
2	Rynki finansowe a mechanizm podwójnej ciągłej aukcji	9
2.1	Teoria rynków finansowych.....	9
2.1.1	Błędzenie losowe	9
2.1.2	Zero intelligence trader	13
2.1.3	Model Danielsa (ZIT) oraz predykcyjny model Farmera	15
2.1.4	Modelowanie wieloagentowe w ekonomii.....	19
2.2	Podwójna aukcja w analizie rynku finansowego.....	21
2.2.1	Podwójna ciągła aukcja.....	21
2.2.2	Model z agentem „low-Intelligence”	28
2.2.3	Efektywność rynków finansowych.....	32
2.2.4	Efektywność rynków finansowych według Fama, (1970)	33
3	Wieloagentowe modelowanie rynków finansowych.....	35
3.1	Agenci na rynkach finansowych.....	35
3.2	Platforma symulacyjna MASON	40
3.3	Informatyczny model ZIT z mechanizmem podwójnej ciągłej aukcji	44
4	Symulacje wieloagentowe podwójnej ciągłej aukcji	49
4.1	Hipoteza badawcza	49
4.2	Założenia	50
4.3	Wyniki	52
4.4	Dyskusja	70
5	Podsumowanie	72
6	Bibliografia	75
7	Spis tabel, rysunków i wykresów.....	78
7.1	Tabele	78
7.2	Rysunki	78

7.3	Wykresy	79
8	Załączniki	79
9	Streszczenie	80

1 Wprowadzenie

Celem pracy jest stworzenie modelu rynku opartego na mechanizmie podwójnej ciągłej aukcji, poprzez którą oddziałują agenci typu ZIT (Zero Intelligence Trader) rozbudowanego o agentów typu „low-intelligence”. Model ten stanowi rozbudowę modelu zaproponowanego przez J.D.Farmera (por. Farmer, i in. 2003) wykorzystujący mechanizm podwójne aukcji, poprzez którą oddziałują na siebie agenci cierpliwi i niecierpliwi. Budowa oraz analiza modeli rynków finansowych pozwala na poznawania oraz lepsze rozumienie ich złożonej i dynamicznie zmieniającej się struktury. Większa wiedza w tym zakresie pozwala na usprawnianie ich działania, dokonywanie regulacji, których celem jest poprawa efektywności funkcjonowania rynków (por. Fama, 1970). Budowanie oraz analiza takich modeli pozwala na tworzenie coraz doskonalszych modeli predykcyjnych, na podstawie których można budować warunkowe przewidywania zachowania się rynków finansowych.

Tematykę analizy, predykcji oraz mechanizmów funkcjonowania rynków finansowych podejmowano w literaturze wielokrotnie. Jednym z pierwszych modeli wskazujących na losowy charakter rynków finansowych został zaproponowany na początku XX wieku w roku 1900 przez francuskiego matematyka i ekonomistę Luisa Bachelier w jego rozprawie doktorskiej (por. Bachelier, 1900). Model ten ewoluował w czasie poprzez badania i analizy jakie dokonywali w ostatnim stuleciu naukowcy między innymi tacy jak: Osbourne, (1959), Mandelbrot (1963) czy wspomniany wyżej Farmer, i in. (2003), który problem rozpatruje już w obecnym stuleciu. Osbourne, (1959) zwracał uwagę na fakt, iż to nie ceny, a stopy procentowe posiadają rozkład normalny, a ponieważ ceny i stopy procentowe są powiązane logarytmicznie to ceny powinny mieć rozkład logarytmicznie normalny co w konsekwencji wskazuje, że to stopy procentowe mają charakter białego szumu (por. Osbourne, 1959), a nie ceny jak wskazywał Luisa Bachelier (por. Bachelier, 1900). Mandelbrot (1963) jako pierwszy zwrócił uwagę oraz opisał, że rozkład cen jest rozkładem Pareto znany również jako prawo Zipf'a z grubym ogonem dystrybucji (stabilny rozkład Levy-ego) czyli losowy charakter stóp zwrotu ma szerszy zakres niż w przypadku rozkładu normalnego (por. Mandelbrot, 1963) co zmienia spojrzenie na model Osbournea, (1959). Nadal jednak podtrzymywał, że stopy procentowe mają charakter białego szumu. Modele te różniły się głównie dla skrajnych wartości czyli właśnie w zakresie ogona dystrybucji. Jednak taki model wprowadza trudności w wykorzystaniu statystycznych metod do obliczenia zmienności czyli wariancji, która w praktyce może istnieć, a według modelu jest wartością nieokreślona z granicą w nieskończoności (por. Weatherall, 2013). Farmer, i in. (2003) również przyjmują założenie, że

stopy zwrotu mają charakter białego szumu oraz, że rynek finansowy funkcjonuje na zasadach podwójnej ciągłej aukcji poprzez którą wchodzą w interakcję agenci. Poprzez model agenta ZIT (Zero Intelligence Trader) został zasymulowany losowy charakter rynku finansowego.

Pierwszy wieloagentowy model ZIT zaproponowali Gode i Sunder (1993). Wykonali oni eksperyment, w którym brali udział studenci reprezentujący agentów kupujących i sprzedających akcje na rynku działającym według zasady podwójnej ciągłej aukcji. Celem było sprawdzenie zachowania się rynku po wprowadzeniu dodatkowego agenta typu ZIT. Wynikiem prac było stwierdzenie, że elementem ustalającym więzi na rynku jest przypadkowy układ ofert kupna i sprzedaży, a nie określona strategia pojedynczych agentów. Innymi słowy efektywna alokacja środków (przydział cenowy) zależy do samej struktury podwójnej aukcji (gry) niezależnie od samego efektu uczenia czyli „zero intelligence” (por. Gode i Sunder, 1993). Farmer, i in. (2003) dokonali modyfikacji tego modelu wprowadzając dwa typy agentów cierpliwego (ang. *patient trader*) i niecierpliwego (ang. *impatient trader*). Agent cierpliwy składa zamówienia ograniczone (ang. *limit order*) zarówno ceną jak i ilością, które chciałby zrealizować. Zamówienie nie musi być realizowane od razu w danej turze. Może poczekać do kolejnych lub zostać odwołane. Są to agenci, którzy zapewniają płynność sprzedaży tworząc księgi zamówień (ang. *order book*). Typ niecierpliwy realizuje zamówienie ograniczone jedynie poprzez ich liczbę, a zamówienie musi być zrealizowane od razu w obecnie najlepszej cenie (ang. *market order*). Model został opisany w pracy Daniels, i in. (2003), i zakłada on wykorzystanie podwójnej ciągłej aukcji jako najczęściej stosowanej metody kształtowania się cen w obecnej formie funkcjonowania rynków finansowych, (por. Smith, i in. 2003).

W tej pracy rozbudowa modelu zaproponowanego przez Farmer, i in. (2003) o agentów typu „low-intelligence” będzie polegała na wprowadzeniu agentów podejmujących decyzję o kupnie lub sprzedaży akcji na podstawie algorytmu wykorzystującego sztuczne sieci neuronowe z algorymem propagacji wstecznej. Celem pracy jest zbadanie zachowania nowego modelu w odniesieniu do pierwowzoru. Farmer, i in. (2003) sformułowali we wskazówkach dotyczących dalszych badań w swojej pracy możliwość dodania agenta typu „low intelligence” jako korektora antykorelacji wygenerowanej przez mechanizm podwójnej aukcji, która wpływa na zaburzenie efektywności rynku. W ich pracy została podjęta próba zrozumienia w jaki sposób ceny zależą od wskaźników przepływów realizowanych na zamodelowanym rynku. (por. Farmer, i in. 2003).

W pracy zostanie zweryfikowana następująca hipoteza: wprowadzenie agenta typu „low-intelligence” nie wpłynie na zachowanie rynku w sposób poprawiający jego efektywność według Fama, (1970). Oznacza to, że wprowadzenie zmodyfikowanego agenta nie zmieni

mechanizmu formowania się cen wprowadzając pozytywną autokorelację. Zakładam, że przez wprowadzenie innego rozwiązania w mechanizmie podejmowania decyzji przez agenta niecierpliwego (ang. *impatient trader*) uda się uzyskać charakterystykę rynku zbliżoną do rzeczywistej. Założenie to potwierdza również praca Briggs, i in. (2008?). Zwiększając liczbę zamówień ograniczonych (ang. *limit orders*), a zmniejszając liczbę zamówień rynkowych (ang. *market orders*) zwiększa się płynność rynku. Pozwoli to uzyskać zbliżone do rzeczywistego grupowanie zmienności rynku. Wprowadzenie agenta z możliwością uczenia się zmienia jego charakter, który możemy określić jako „low-intelligence”. Jak zostało wspomniane wyżej silna antykorelacja sugeruje nieefektywność rynku. Stąd Farmer, i in. (2003) wskazują na możliwość wprowadzenie agenta typu „low-intelligence” jako temat do dalszych badań mających na celu skorygowanie tej nieefektywności. Modyfikacja polega na implementacji algorytmu wykorzystującego sztuczne sieci neuronowe z algorymem propagacji wstecznej. Całość nadal stanowi model, który jest typu ZIT. Celem jest sprawdzenie czy i na ile taka modyfikacja będzie miała wpływ na wyniki modelu, w stosunku do wersji zaproponowanej przez Farmer, i in. (2003), a przez to na charakterystykę odniesioną do rzeczywistości. Weryfikacja zostanie wykonana poprzez sprawdzenia autokorelacji stopy zwrotu oraz grupowanie zmienności rynku. Autorzy Farmer, i in. (2003) opisali, że jednym z głównych obszarów, w których model odbiega od realiów to dyfuzja ceny. Przyrost rzeczywistych cen w przybliżeniu ma charakter białego szumu stąd ich próbki składają się z nieskorelowanych zmiennych czyli brak jest autokorelacji, która pozwala na określenie czy występuje powtarzająca się zależność danego sygnału. W przypadku białego szumu nie występuje autokorelacja. Zbyt silna antykorelacja w zakresie dyfuzji cen wskazuje na nieefektywność rynku. Stąd też problem do rozwiązania, który można sformułować poprzez pytanie czy wprowadzenia agenta typu „low-intelligence” wpłynie na zachowanie rynku w taki sposób, żeby spełniał on warunki rynku efektywnego (por. Fama, 1970).

W celu wykonania symulacji pozwalających na otrzymanie wyników do dalszej analizy w pracy został skonstruowany model wieloagentowy (por. Macal i North, (2009), Farmer i Foley, (2009), Farmer, (2012), Danielsa, i in. (2003)), gdzie agencie są typu ZIT (Zero Intelligence Trader). Agenci wchodzą ze sobą w interakcje poprzez mechanizm ciągłej podwójnej aukcji (por. Smith, i in. 2003). Model został zasymulowany przy wykorzystaniu bibliotek z platformy MASON (Luke, i in. 2005) pozwalających na wieloagentową symulację rynków finansowych. Modyfikacji został poddany model Farmer, i in. (2003) czyli jak już zostało to opisane wyżej agent niecierpliwy (ang. *impatient trader*) został zmodyfikowany do postaci „low-intelligence”.

Model w pierwotnej postaci został zaimplementowany na platformie MASNO przez Briggs, i in. (2008?). Kod modelu został napisany w języku programowania Java.

Wyniki z modelu pierwotnego Farmer, i in. (2003) zostały porównane z modelem zmodyfikowanym o agenta „low-intelligence” w celu weryfikacji hipotezy. Została sprawdzona autokorelacja stopy zwrotu oraz grupowanie zmienności rynku. Analizy zostały przeprowadzone przy użyciu języka programowania R.

W pracy przyjęto następujący układ. Po niniejszym wprowadzeniu w rozdziale 2 można zobaczyć zarys historyczny modelowania rynków finansowych począwszy od wprowadzenia modelu w 1900 (por. Bachelier, 1900) o charakterze białego szumu poprzez rozpatrywanie modelowania rynków w oparciu o mechanizm podwójnej ciągłej aukcji z wykorzystaniem agentów typu ZIT (por. Gode i Sander, 1993). Istotną częścią rozdziału jest opis modelu z podwójną ciągłą aukcją zaproponowaną przez Danielsa, i in. (2003). Podsumowanie stanowi spojrzenie na wieloagentowe modelowanie rynków finansowych (por. Farmer i Foley, 2009) jako nową formę całościowego ujęcia złożonego systemu (ang. *complex system*) rynku finansowego (por. Farmer, 2013). W drugiej części tego rozdziału poruszona jest kwestia teoretycznego spojrzenia na model podwójnej aukcji z zastosowaną analizą wymiarową do opisu zależności zachodzących na rynku finansowym (por. Smith, i in. 2003). Kolejną istotną kwestią, która została opisana w tym rozdziale to teoretyczna podstawa agenta „low-intelligence” wykorzystanego w modelu zbudowanym w tej pracy. Składa się na nią opis wykorzystanego tutaj algorytmu propagacji wstępnej stosowanego w sztucznych sieciach neuronowych. Zakończenie tej części stanowi krótka charakterystyka efektywności rynków finansowych (por. Fama, 1970).

Następnie w rozdziale 3 zostało poruszone i scharakteryzowane modelowanie wieloagentowe jako forma symulowania rynków finansowych. W drugiej części tego rozdziału została omówiona platforma informatyczna MASON pozwalająca na zrealizowanie symulacji wieloagentowej z wykorzystaniem języka programowania Java. Ostatnią część tego rozdziału jest opis modelu zbudowanego w tej pracy, na który składają się zarówno schematy jak i kod. W podsumowaniu, które stanowi 4 rozdział tej pracy zostały przedstawione wyniki, analiza oraz schematy analiz wraz z kodem stanowiącym podstawę replikacji i dalszych badań. Znajduje się tutaj opis dokonanych modyfikacji, które pozwoliły uzyskać przedstawione wyniki. Zakończenie tego rozdziału stanowią wskazania do dalszych badań.

Pracę zamykają uwagi końcowe, bibliografia oraz załączniki.

2 Rynki finansowe a mechanizm podwójnej ciągłej aukcji

Rozdział drugi został podzielony na dwie części. Pierwsza część stanowi opis historii powstawania rynków finansowych i składa się ona z czterech części. Pierwsza nawiązuje do zagadnienia błędzenia losowego, druga zero intelligence trader, trzecia do modelu, który stanowi podstawę opisywanego w tej pracy projektu, a czwarta poruszą kwestię zasadności zastosowania modelowania wieloagentowego w literaturze. W drugiej części tego rozdziału poruszona została teoretyczna kwestia dotycząca podwójnej ciągłej aukcji. Ta część rozdziału składa się z opisu podwójnej ciągłej aukcji według Farmera, i in. (2003), opisu modelu low-intelligence , ogólnego poruszenia zagadnienia efektywności rynków finansowych oraz odniesienia się do efektywności rynków finansowych według Fama, (1970).

2.1 Teoria rynków finansowych

W tej części rozdziału drugiego można zobaczyć zarys historyczny modelowania rynków finansowych począwszy od wprowadzenia modelu w 1900 (por. Bachelier, 1900) o charakterze białego szumu poprzez rozpatrywanie modelowania rynków w oparciu o mechanizm podwójnej ciągłej aukcji z wykorzystaniem agentów typu ZIT (por. Gode i Sander, 1993). Istotną częścią rozdziału jest opis modelu z podwójną ciągłą aukcją zaproponowaną przez Danielsa, i in. (2003). Podsumowanie stanowi spojrzenie na wieloagentowe modelowanie rynków finansowych (por. Farmer i Foley, 2009) jako nową formę całościowego ujęcia złożonego systemu (ang. complex system) rynku finansowego (por. Farmer, 2013).

2.1.1 Błędzenie losowe

Zgodnie z artykułem Sewella, (2012) pierwsze informacje o błędzeniu losowym zostały zauważone przez szkockiego botanika Roberta Browna (1828). Zauważył on pod mikroskopem, że drobiny pyłku kwiatowego zawieszone w wodzie poruszają się charakterystycznym szybko oscylującym ruchem. Ruchy o takiej charakterystyce, zauważono dla wszystkich badanych drobin pyłków niezależnie od ich rodzaju. Ich zachowanie zostało określone jako Ruchy Browna (Brown, 1828). Francuski makler giełdowy Jules Regnault (1863) zaobserwował, że im dłużej dany papier wartościowy jest trzymany przez inwestora tym więcej może on zyskać lub stracić na jego zmianie ceny w czasie. Choć na dzień dzisiejszy uważa się, że to Luis Bachelier jest prekursorem nauki o rynkach finansowych z wykorzystaniem teorii bazującej na modelu błędzenia losowego to jednak należy pamiętać, że

pierwszym, który zapoczątkował tę naukę był Jules Regnault, (1863). Charakterystyczna zależność, o której pisał Regnault, (1863) to proporcjonalność wartości odchylenia do pierwiastka kwadratowego upływającego czasu. Brytyjski fizyk Lorda Rayleigh (1880) świadomie wykorzystuje zjawisko błędzenia losowego, bez używania samego określenie, do analizy losowego zjawiska wibracji (Strutt, 1880). Jak pisze Sewell, (2012) brytyjski matematyk i filozof John Venn (1888) miał jasną koncepcję zarówno błędzenia losowego jak i ruchów Browna. Venn, (1888) zilustrował losowy charakter cyfr liczby pi wykorzystując je do wygenerowania błędzenia losowego w dwóch wymiarach.

Jak już zostało wyżej opisane w roku 1900 powstała praca doktorska francuskiego matematyka Louisa Bacheliera szczegółowo opisująca zagadnienie błędzenia losowego (Bachelier, 1900). Stworzył on pierwszy w historii matematyczny i statystyczny opis ruchów Browna. Istotny jest fakt, że opis ten powstał pięć lat wcześniej niż praca przedstawiona przez Einsteina (1905), który jest uważany za prekursora ujęcia w formie matematycznej tego zagadnienia. Jednak praca Bacheliera nie została doceniona w owych czasach. Odkrył ją dopiero w roku 1955 matematyk Leonard Jimmie Savage, który rozesłał kartki do swoich kolegów z pytaniem czy ktoś zna Bacheliera. Jednym z adresatów zapytania był ekonomista Paul Samuelson, który jako pierwszy Amerykanin otrzymał nagrodę Nobla w dziedzinie ekonomii za pracę naukową, poprzez którą rozwinął statyczną i dynamiczną teorię ekonomii oraz aktywnie uczestniczył w podniesieniu poziomu analizy w dziedzinie ekonomii (por. Nobel Prize Organization, 1970). Paul Samuelson w 1956 w pracy na temat wyceny instrumentów typu opcje uznał Luisa Bacheliera za uznanego prekursora (Sewella, 2012).

W tym samy roku, w którym Einstein (1905) stworzył równanie opisujące ruchy Browna, profesor Karl Pearson na łamach dziennika naukowego Nature wprowadził pojęcie „random walk” (Pearson, 1905). Również polski naukowiec, fizyk, pionier fizyki statystycznej Marian Smoluchowski prowadził badania nad ruchami Browna w 1906 roku. Wyniki jego badań wykorzystał Einstein przy formułowaniu równania ruchów Browna (Sewell, 2012).

Zjawisko opisane przez Bachelier (1900) można przedstawić w uproszczony sposób jak to zrobił Weatherall (2013) na przykładzie człowieka będącego pod wpływem dużej ilości alkoholu, który wyszedł z baru i wrócił do hotelu, w którym po wyjściu z windy stoi na środku korytarza. Korytarz rozciąga się w lewą stronę, na końcu której jest pokój z numerem 799 oraz w prawą stronę, gdzie na końcu znajduje się pokój o numerze 700. Celem tego człowieka jest dotarcie do swojego pokoju. Nie wie on jednak, w którym iść kierunku, żeby dotrzeć do

swojego pokoju. Człowiek idąc potyka się co krok zmieniając kierunek swojej trasy. Połowę czasu idzie w jednym kierunku, a połowę w drugim kierunku. Teoria błądzenia losowego pozwala na udzielenie odpowiedzi jakie jest prawdopodobieństwo, że człowiek po wykonaniu określonej (np.: 100) ilości kroków stanie przed drzwiami swojego pokoju. Zakładając, że rynki finansowe zachowują się tak jak wspomniany człowiek pod wpływem dużej ilości alkoholu możemy przewidywać prawdopodobieństwo osiągnięcia przez ceny wartości o zakładanym poziomie. Jeżeli rozpatrujemy wartość cenową akcji w określonym momencie, który zdefiniujemy jako wartość startu, a zachowanie akcji ma charakter błądzenia losowego będziemy mogli określić z jakim prawdopodobieństwem cena ta osiągnie nowy poziom na końcu czyli po określonej i założonej ilości kroków, a inaczej po określonych rozpatrywanych przedziałach czasowych (np.: po 100 krokach). Bachelier, (1900) pokazał w swojej pracy, że ceny akcji na giełdzie mają charakter błądzenia losowego, a prawdopodobieństwo osiągnięcia określonej wartości po zdefiniowanym okresie czasu ma rozkład normalny. Wartość średnia czyli środkowa wartość rozkładu jest punktem startowym. Oznacza to, że najbardziej prawdopodobne będzie to, że cena końcowa będzie bliska wartości średniej, a inaczej wartości początkowej. Im więcej kroków jest rozpatrywane czyli im dłuższy horyzont czasowy jest brany pod uwagę tym bardziej krzywa normalna jest rozplaszczona. Bardzo dobrze obrazuje to wykres rozkładu prawdopodobieństwa w modelu Bachelier (Weatherall, 2013, strona 14 , rysunek 1)

Bachelier zakładał, że prawdopodobieństwo wzrostu ceny akcji jest równe prawdopodobieństwu jej spadku. Wpływ na to czy cena wzrośnie czy spadnie ma informacja jaką posiada gracz. Transakcja zachodzi wtedy, gdy kupujący i sprzedający zgodzą się na ustaloną cenę. Jednak każdy z nich inaczej interpretuje dostępną informację na rynku. Kupujący godzi się na cenę zakładając, że wartość akcji wzrośnie, a sprzedający zakłada, że cena spadnie. Takie przedstawienie funkcjonowania rynku zainicjowało do powstawania w późniejszych latach hipotezy efektywności rynku zaprezentowanej przez Fama, (1970).

W 1959 roku Osborne, (1959) pokazał, że to logarytm cen akcji, a nie same wartości ceny mają charakter błądzenia losowego. Stwierdził, jak to opisuje Weatherall, (2013), że to stopy procentowe, a nie ceny mają rozkład normalny. Ceny akcji i stopy procentowe są powiązane ze sobą logarytmicznie.

Na podstawie Zivot, (2015)

$$r_t = \ln(1 + R_t) = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(P_t) - \ln(P_{t-1}) \quad (1)$$

gdzie:

r_t ciągła skumulowana stopa zwrotu; R_t efektywna stopa zwrotu;

P_t cena w momencie t; P_{t-1} cena w momencie t-1;

$1+R_t$ nominalna stopa zwrotu;

$$R_t = e^{r_t} - 1 \quad (2)$$

Osbornea, (1959) w swojej pracy wskazuje, że ceny powinny mieć rozkład log-normalny. Rozkład prawdopodobieństwa modelu Osbornea, (1959) jest dobrze zobrazowany na wykresie (Weatherall, 2013, strona 37 , rysunek 2). Jak pisze Weatherall, (2013) statystyk powiedziałby, że logarytm ceny posiada cechę równych interwałów czyli różnica pomiędzy logarytmami dwóch cen jest nawiązaniem do odczucia rozpatrywanego w aspekcie psychologicznym wygranej lub straty w odniesieniu do dwóch cen akcji. Innymi słowy nie jest istotna zmiana obiektywnej wartości ceny akcji na rynku, a reakcja inwestora na zmianę tej ceny. Stąd istotna jest zmiana stopy procentowej, a nie sama wartość bezwzględna ceny. Osborn, (1959) udowodnił również zaobserwowaną wcześniej przez Regnaulta, (1863) zależność proporcjonalność wartości odchylenia do pierwiastka kwadratowego upływającego czasu.

Mandelbrot, (1963) wskazał, że ogon dystrybucji rozkładu stóp zwrotu jest odmienny od rozkładu normalnego. Różnica polegała na tym, że ogon ten odpowiadał prawu Zipfa z tzw. grubym ogonem dystrybucji (stabilny rozkład Levy-ego). Rozkład ten określany jest również rozkładem Pareto. Różnica ta powoduje, że losowy charakter stóp procentowych ma szerszy zakres niż w przypadku rozkładu normalnego (por. Mandelbrot, 1963). Model ten różni się od tego przedstawionego przez Osborna, (1959) głównie dla skrajnych wartości znajdujących się w ogonie dystrybucji. Problem, który implikuje przyjęcie takiego modelu to trudności z wykorzystaniem statystycznych metod pozwalających na określenie zmienności czyli wariancji. Według modelu wariancja może być nieokreślona z granicą w nieskończoności podczas, gdy w praktyce może ona istnieć (por. Weatherall, 2013).

Rozwiążanie zaproponowane przez Mandelbrota, (1963) było trudniejsze do analiza właśnie ze względu na ograniczoną liczbę narzędzi statystycznych w przeciwieństwie do modelu

zaproponowanego przez Osborna, (1959). Zgodnie z zapisem Wealtheralla, (2013) środowisko naukowe obrało w 1965 roku drogę badania rynków finansowych w oparciu o model zaproponowany przez Osborna, (1959). W 1962 podczas spotkania społeczności ekonometrycznej w odpowiedzi na pracę Mandelbrota, (1963) oświadczyło ono, że podobnie jak premier Churchill przed nim nie obiecuje on utopii, a krew, pot i łzy. Jeżeli ma on rację to prawie wszystkie dotychczasowe narzędzia statystyczne są przestarzałe... bez wyjątku prawie cały dotychczasowy dorobek ekonometryczny jest bez znaczenia...powinni mieć jakiś dowód na to, że dotychczasowa praca jest faktycznie bezużyteczna (por. Weatherall, 2013).

Podsumowując początki powstania modelu błądzenia losowego jednym z prekursorów był Luis Bachelier, który przyjął, że ceny akcji na rynku finansowym mają charakter losowy typu błądzenia losowego. Następnie Osborne, (1959) zauważył, że taki model powoduje, że ceny mogą przyjmować wartości ujemne co nie jest logiczne i nie jest zgodne z rzeczywistością. Zmienił on model wskazując na to, że to nie ceny, a stopy procentowe mają charakter typu błądzenia losowego. Model ten znacznie lepiej odwzorowywał zachowanie rynków finansowych niż ten przedstawiony przez Bacheliera. Następnie Mandelbrot, (1963) wskazał, że model Osborna, (1959) nie jest do końca prawidłowy ponieważ szczegółowa analiza pokazuje, że w granicznych wartościach czyli w końcach ogonów dystrybucji wartości między modelami są różne (różnice widać w ekstremalnych warunkach) (por. Weatherall, 2013).

2.1.2 Zero intelligence trader

Na początku lat dziewięćdziesiątych dwudziestego wieku Gode i Sunder, (1993) przeprowadzili eksperyment wykorzystując jako bazę model podwójnej ciągłej aukcji, poprzez którą wchodzili w interakcję agenci czyli gracze. Z jednej strony zostali wprowadzeni agenci, którzy byli reprezentowani przez ludzi, a z drugiej strony byli to agenci typu zero-intelligence (ZI) reprezentowani przez komputery, na których zostały wywołane algorytmy. Każdy człowiek biorący udział w grze jest odmienną jednostką, która podejmuje indywidualne decyzje. Każdy agent ZI jest taki sam i generuje on przypadkowe oferty kupna lub sprzedaży rozłożone niezależnie, identycznie i równomiernie w całym realnym zakresie cen kupna sprzedaży od 1 do 200 (w zależności od tego czy jest kupującym czy sprzedającym). W modelu występują 3 decyzje: oferta kupna, oferta sprzedaży i transakcja. Każda z decyzji występuje jako osobna jednostka. Transakcja nie zachodzi przy nieprzyjętej ofercie kupna i nieprzyjętej ofercie sprzedaży. Gdy oferta kupna (ang. bid) i oferta sprzedaży (ang. ask) się przetną to cena transakcji będzie taka jak wcześniej (por. Gode i Sunder, 1993). Występują cztery możliwe

stany zamówienia. Pierwsza to opcja, gdy nie ma dobrej oferty kupna (najniższa oferta kupna) oraz nie ma dobrej oferty sprzedaży (najwyższa oferta sprzedaży). Druga występuje, gdy jest najlepsza oferta kupna oraz nie ma dobrej oferty sprzedaży. Trzecia jest wtedy, gdy nie ma najlepszej oferty kupna oraz jest najlepsza oferta sprzedaży, a czwarta gdy jest najlepsza oferta kupna oraz jest najlepsza oferta sprzedaży. Sytuacja przecięcia cen występuje wtedy, gdy najlepsza oferta kupna będzie większa niż najlepsza oferta sprzedaży w przypadku, gdzie taka sytuacja ma miejsce w opcji czwartej oraz istnieje co najmniej jedna najlepsza oferta kupna i jedna najlepsza oferta sprzedaży w zamówieniu za każdym razem. W modelu ZIT kupujący mają losowo przypisane wartości pomiędzy zerem, a maksymalną wartością kupującego. Sprzedający mają losowo przypisane ceny sprzedaży pomiędzy zerem, a maksymalną wartością sprzedającego. W każdym takcie zegara zarówno kupujący, jak i sprzedający są wybierani przypadkowo. Kupujący przypadkowo formuluje cenę oferty kupna pomiędzy jego wartością a wartością zero lub pomiędzy maksymalną wartością kupującego i zero. Sprzedający przypadkowo formuluje cenę oferty sprzedaży pomiędzy jego wartością, a maksymalną wartością sprzedającego lub pomiędzy zerem i maksymalną wartością sprzedającego. Wybrany kupujący porównuje swoją ofertę kupna z obecnym stanem zamówienia. Jeżeli jego oferta kupna jest wyższa niż najlepsza oferta sprzedaży to akceptuje on ofertę sprzedaży i kupuje po zaoferowanej najlepszej cenie sprzedaży. Następuje wymiana. Zamówienie po tej wymianie pozostaje puste.

Jeżeli oferta kupna jest poniżej najlepszej ceny sprzedaży (lub nie ma najlepszej oferty sprzedaży) i nie ma najlepszej oferty kupna to wtedy ta oferta staje się najlepszą ofertą kupna. Jeżeli oferta kupna jest poniżej najlepszej ceny sprzedaży (lub nie ma najlepszej ceny sprzedaży) i powyżej najlepszej oferty kupna, to ta oferta zastępuje najlepszą ofertę kupna. Jeżeli oferta kupna jest poniżej najlepszej oferty kupna to oferta kupna jest ignorowana. Analogicznie sytuacja przedstawia się, gdy wybranym agentem jest sprzedawca poprzez przypadkowe sformułowanie oferty sprzedaży do aktualnego zamówienia. Jeżeli wybrany sprzedawca przedstawia ofertę sprzedaży poniżej najlepszej oferty kupna to sprzedaż jest realizowana w cenie najlepszej oferty kupna. Po wybraniu kupującego lub sprzedającego jeżeli sprzedaż występuje to zaangażowani kupujący i sprzedający są usuwani z rynku do momentu, w którym każdy kupujący i sprzedający będą mogli ponownie przystąpić do kupna lub sprzedaży jednej jednostki. Proces jest realizowany do momentu osiągnięcia maksymalnej liczby transakcji.

Zgodnie z Gode i Sander, (1993) Becker, (1962) dowódł, że zarówno opadająca funkcja popytu jak i rosnąca funkcja podaży oraz wzrosty na giełdzie mogą być konsekwencją zupełnie przypadkowego działania agentów w zakresie ograniczeń dotyczących budżetu. Pomimo możliwego nieracjonalnego działania gospodarstw domowych sam rynek może funkcjonować zupełnie racjonalnie. Becker, (1962) wskazuje, że przewidywania ekonomicznych teorii dotyczących rynku oparte na zachowaniu agentów są bardziej spójne niż te oparte na maksymalizacji użyteczności. Zgodnie z Gode i Sander, (1993) Smith, (1982) wykazuje z kolei, że takie przewidywania są znacznie bardziej spójne z samym mechanizmem handlu.

Gode i Sander, (1993) przedstawiają model podwójnej aukcji, który podtrzymuje wysoki poziom efektywności (skuteczność przydziału środków) nawet jeżeli pojedynczy agent nie maksymalizuje użyteczności (Beker) lub nie szuka zysku (Smith).

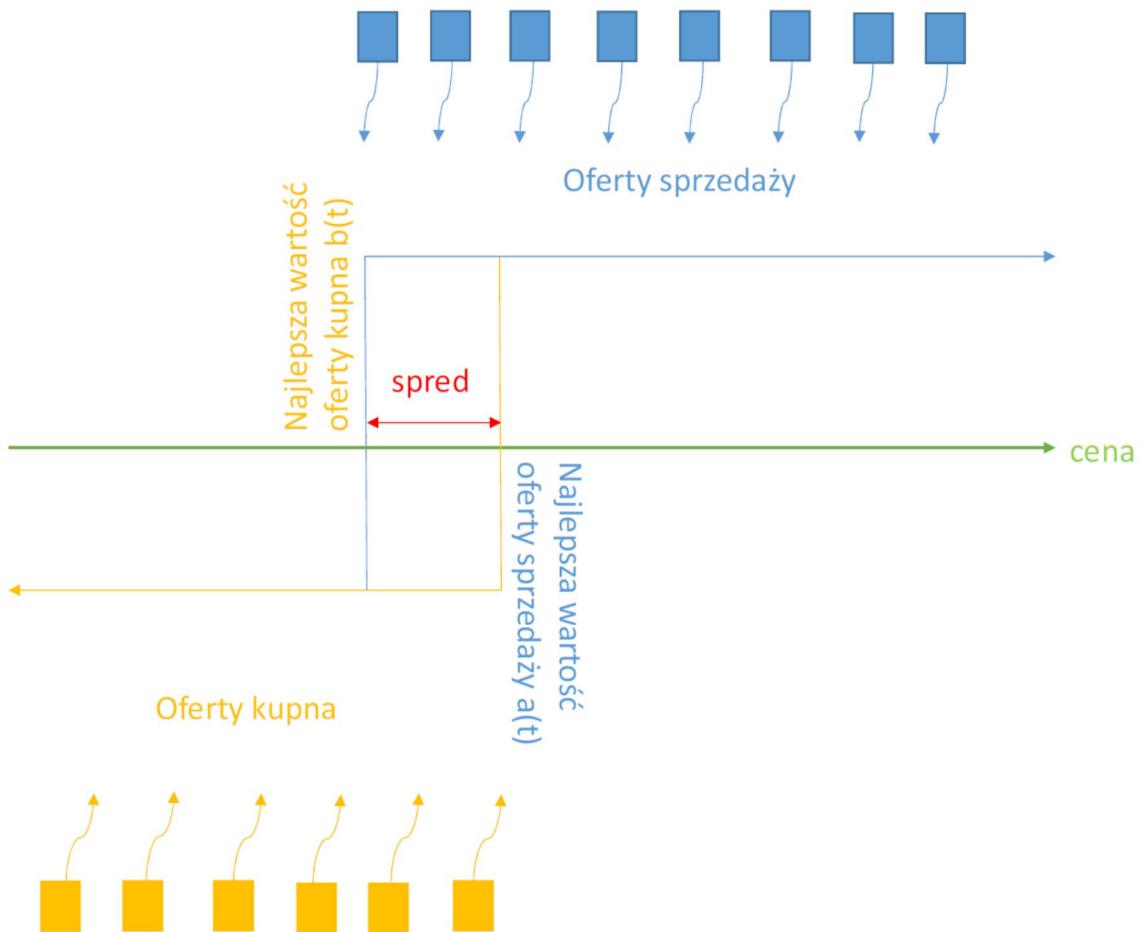
W celu odizolowania efektu reguł rynku od samego zachowania pojedynczych agentów na efektywność rynku Gode i Sander, (1963) wprowadzili trzy kroki postępowania. Pierwszy to wybór biorącego udział w rynku zmotywowanego zyskiem agenta, który był reprezentowany przez człowieka i agenta ZI przedstawiającego model maszynowy agenta handlującego na rynku. W drugim kroku obserwowana jest efektywność rynku zamodelowanego jako podwójna aukcja z udziałem wprowadzonych wcześniej dwóch rodzajów agentów. W jednym zbiorze rynku agenci ZI podlegają ograniczeniom budżetowym, a w drugim zbiorze rynku ZI ograniczenia budżetowe nie istnieją. W kroku trzecim porównywane były obserwacje w celu oddzielenia charakterystyk efektywności rynku, które mogą być przypisane do jego struktury. McBride, (2014) napisał na podstawie modelu stworzonego przez Gode i Sander, (1993), że agenci typu ZI mogą prowadzić do wysokiego poziomu efektywności rynkowej pomimo losowego charakteru podejmowania decyzji. Racjonalne podejmowanie decyzji nie jest warunkiem koniecznym do osiągnięcia efektywności.

2.1.3 Model Danielsa (ZIT) oraz predykcyjny model Farmera

Daniels, i in. (2003) stworzyli model rynku finansowego z wykorzystaniem metod zaczerpniętych z dziedziny fizyki, które pozwoliły na zasymulowanie rynku finansowego i odtworzenie mechanizmu formowania się cen przy założeniu, że napływające zamówienia jak i ich usuwanie odbywać się będą z wykorzystaniem losowego procesu Poissona. Model Danielsa, i in (2003) pozwala na testowanie predykcji podstawowych własności rynku finansowego takich jak dyfuzję stóp procentowych cen, która jest podstawowym czynnikiem

wykorzystywanym do analizy ryzyka. Kolejnymi właściwościami są spred oraz funkcja impaktu ceny (ang. price impact function), które stanowią podstawę wyceny kosztów transakcyjnych. Wykorzystanie analizy wymiarowej, symulacji oraz teorii pola średkowego pozwoliło im znaleźć skalowalną zależność pomiędzy parametrami, której elementem łączącym jest współczynnik przepływu zamówień. Wykazali oni, że nawet przy całkowicie losowym charakterze przepływu zamówień potrzeba akumulowania podaży i popytu w celu utrzymania handlu powoduje powstawania anomalii w zakresie dyfuzji cen oraz ich tymczasowych struktur. Istotnym elementem jest możliwość zrealizowania predykcji ilościowych podstawowych właściwości rynku. W tym modelu nie ma wprowadzonych założeń określających powiązania między agentami. Model generuje możliwe do zweryfikowania wyniki. Model ten ma charakter błędzenia losowego i podobnie jak działa większość nowoczesnych rynków finansowych ma on również charakter ciągły. Różnica pojawiająca się w każdym kroku pomiędzy wartościami kupna i sprzedaży jest rozwiązana poprzez rynek bazujący na dwóch typach zamówienia. Pierwsze to zamówienie rynkowe zrealizowane na określoną liczbę akcji od razu w obecnie najlepszej cenie (ang. market order). Zamówienie to jest realizowane przez agenta niecierpliwego (ang. impatient trader). Drugi typ zamówienia to zamówienie ograniczone (ang. limit order), które stanowi ograniczoną cenę nawiązującą do najniższej możliwej ceny pozwalającej na zrealizowanie transakcji. To zamówienie często nie dochodzi do realizacji w określonym kroku, w którym powstaje. Jeżeli nie dojdzie do transakcji to zamówienie to wchodzi do kolejki, w której jest przechowywane. Ta kolejka nosi nazwę księgi zamówień (ang. order book). Zamówienia te są składane przez agentów cierpliwych (ang. patient trader) i noszą nazwę odpowiednio oferty kupna (ang. bid) oraz oferty sprzedaży (ang. ask). Wszystkie wartości cen są w modelu ich logarytmem. Stąd najlepsza oferta sprzedaży $a(t)$ jest logarymem ceny odpowiadającej wartości najlepszej czyli najniższej oferty sprzedaży. Podobnie dla najlepszej oferty kupna. Jest to logarytm ceny odpowiadającej najwyższej wartości oferty kupna oznaczonej jako $b(t)$. Niezerowa różnica pomiędzy tymi cenami jest określana mianem spredyu $s(t)$:

$$s(t) = a(t) - b(t) \quad (3)$$



Rysunek nr 1. Schemat składania zamówień kupna i sprzedaży oraz procesu przecinania się ofert. Nowe oferty sprzedawy mogą być złożone w dowolnej cenie większej niż najlepsza oferta kupna $b(t)$, a nowe oferty kupna mogą być złożone w dowolnej cenie mniejszej niż najlepsza oferta sprzedaży $a(t)$.

Źródło: Opracowanie własne na podstawie Daniels, i in. (2003), strona 2, rysunek 1.

W momencie, gdy pojawiają się zamówienia rynkowe są one dopasowywane do zamówień ograniczonych o przeciwnym znaku w zależności od ceny i czasu pojawienia się na rynku. Ze względu na fakt, iż zamówienia są składane na różną liczbę akcji dopasowanie nie zawsze jest typu jeden do jednego. Dla przykładu założmy, że najlepsza oferta sprzedaży jest wystawiona dla 100 akcji po 10 dolarów. Następna w kolejności najlepsza oferta sprzedaży jest po 10,25 dolarów dla 200 akcji. Jeżeli zostało złożone zamówienie rynkowe dla 150 akcji to 100 akcji jest kupowanych po 10 dolarów, a 50 akcji jest kupowanych po cenie 10,25 dolarów. Takie zamówienie przesuwa najlepszą cenę sprzedaży $a(t)$ z wartości 10 dolarów za akcję na poziom 10,25 dolarów. Dodatkowo na rynku w cenie 10,25 dolarów jest dostępnych już tylko 50 akcji. Na tym przykładzie, dobrze obserwowalny jest fakt, że wysoka gęstość akcji na określoną cenę

zamówień ograniczonych skutkuje wysoką płynnością dla zamówień rynkowych nie wpływając jednocześnie na duże zmiany ceny przy określonych zamówieniach rynkowych.

Tabela nr 1. Zmieniające się wartości akcji i spredy po realizacji zamówienia 150 akcji.

Złożone zamówienie rynkowe dla 150 akcji				Wynik realizacji zamówienia rynkowego dla 150 akcji			
Ograniczone oferty kupna		Ograniczone oferty sprzedaży		Ograniczone oferty kupna		Ograniczone oferty sprzedaży	
liczba akcji	cena	liczba akcji	cena2	liczba akcji	cena	liczba akcji	cena2
80	9,75	100	10	80	9,75	150	10,25
70	9,5	200	10,25	70	9,5	100	10,5
150	9,25	100	10,5	150	9,25		
Spread:		0,25		Spread:		0,5	

Źródło: Opracowanie własne.

Wszystkie przepływy zamówień są realizowane jako losowy proces Poissona. Autorzy założyli, że zamówienia rynkowe będą realizowane w kawałkach σ [liczba akcji] napływających ze wskaźnikiem μ [(liczba akcji)/(jednostka czasu)] z równym prawdopodobieństwem wystąpienia zarówno ofert kupna jak i ofert sprzedaży. Podobnie zamówienia ograniczone są składane w kawałkach σ [liczba akcji] napływających ze wskaźnikiem α [(liczba akcji)/(jednostka ceny*jednostka czasu)]. Składane zamówienia sprzedaży posiadają rozkład jednostajny ciągły będący całkowitą wielokrotnością minimalnej wartości dozwolonej zmiany ceny (ang. tick) dp dla ceny spełniającej nierówność $b(t) < p < \infty$. Podobnie jest dla składanego zamówienia kupna, gdzie cena spełnia nierówność $-\infty < p < a(t)$.

Należy mieć na uwadze, że wartość p jest logarytmem ceny, szerokość dp jest logarytmem szerokości ceny. Napływ zamówień rynkowych powoduje zaistnienie transakcji. Przy założeniu stałej wielkości zamówienia oferta rynkowa kupna usuwa ofertę sprzedaży w cenie $a(t)$, a oferta rynkowa sprzedaży usuwa ofertę kupna w cenie $b(t)$. Dodatkowo zamówienia ograniczone mogą być usuwane spontanicznie poprzez usunięcie lub przedawnienie ważności. Usuwanie zamówień jest procesem losowym ze stałym prawdopodobieństwem δ [(1)/(jednostka czasu)]. Taki proces składania zamówień został zaprojektowany w celu umożliwienia otrzymywania możliwych do analizy wyników otrzymanych w ramach modelowania ciągłej podwójnej aukcji. Autorzy są świadomi, że założenie składania ograniczonych zamówień w przedziale wartości ceny od $-\infty$ do $+\infty$ nie jest założeniem nawiązującym do rzeczywistości. Jednak prowadzi ono do identyfikacji warunków brzegowych dla modelowania zachowania księgi zamówień w najistotniejszym obszarze jakim jest

środkowa wartość ceny $m(t) = (a(t)+b(t))/2$. Dodatkowo wprowadzenie takiego założenie zostało zrealizowane wiedząc, że zamówienia ograniczone będące w dużej odległości od środkowej wartości ceny ulegają najczęściej przedawnieniu lub są usuwane zanim dojdzie do transakcji z ich udziałem. Dla modelu analitycznego wartość wielkości zamówienia σ jest przyjmowana stała. Dla uproszczenia Daniels, i in. (2003) nie dopuszczają, aby wartości zamówień ograniczonych przecinały bezpośrednio najlepszą wartość cenową. Dla przykładu wielkość zamówienia kupna mająca wartość równą $x+y$ może mieć wartość ceny ograniczonej, która jest wyższa niż najlepsza cena sprzedaży. W ten sposób ilość akcji równa x podlega transakcji natychmiast, a liczba akcji y pozostaje w księdze zamówień. Jest to sytuacja dla zamówienia rynkowego liczby akcji x , które podlegają transakcji bezzwłocznie, gdzie kolejna liczba akcji y nie przecina zamówień granicznych. Akcje następnie trafiają do księgi zamówień i podlegają regułom wpływającym na ich ustawienie w kolejce o odpowiednim porządku.

2.1.4 Modelowanie wieloagentowe w ekonomii

Farmer, 2012 wskazuje na fakt, że ekonomia jest systemem złożonym (ang. complex) i chcącą ją zrozumieć należy ją właśnie rozpatrywać poprzez pryzmat „complex”. W tym celu potrzebne są bardziej realistyczne modele zachowań, ale co istotniejsze potrzebne jest uchwycenie najważniejszych czynników ekonomicznych oraz sposobów interakcji pomiędzy tymi czynnikami. Podejście do złożonego ekonomicznego systemu jest podejściem pośrednim pomiędzy tradycyjnym podejściem teoretycznym, a podejściem ekonometrycznym. Tradycyjne podejście można określić jako podejście typu ze szczytu na dół (ang. top-down). Modelowanie decyzji jest realizowane z wykorzystaniem podstawowych zasad teoretycznych czyli wymaga zachowania aspektu ekonomicznego w formułowanej teorii np. określone zachowania są wynikiem określonych preferencji. Następnie skalibrowany model jest testowany na danych rzeczywistych. Podejście ekonometryczne można określić jako podejście typu z dołu na szczyt (ang. bottom-up), oparte na danych, ale fundamentalnie jest to podejście ad hoc. Podejście typu „complex” jest rozwiązaniem pośrednim czyli jest ono typu z dołu na szczyt oparte na danych. Różni się ono od podejścia ekonometrycznego tym, że reprezentuje wyłącznie agentów i instytucje oraz symuluje interakcje pomiędzy nimi bez wymogu obligującego do bazowania na fundamentalnych zasadach. To podejście może być uwolnione od więzów wymagających osiągnięcia równowagi układu (por. Farmer, 2012).. Ekonomia typu „complex” jest oparta na matematyce nieliniowej i jest nauką o tym w jaki sposób

niskopoziomowe bloki, z których jest zbudowany system oddziałując na siebie tworząc nowe interesujące zjawisko. Jeżeli interakcje są liniowe to całość jest jedynie sumą podstawowych bloków. Jeżeli jednak interakcje są nieliniowe to całość może być znacznie bardziej złożona i różna od sumy pojedynczych elementów co w nauce określa się mianem zjawiska emergencji (z interakcji pomiędzy prostymi elementami powstają zupełnie nowe jakościowo formy). Według Farmer, (2012) teoria ekonomii z podejściem ze szczytu na dół jest scharakteryzowana poprzez zdefiniowanie w pierwszej kolejności określonej preferencji i przekonań, a następnie wyprowadzanie z tego rozwiązania będącego w stanie równowagi. Jest to podejście, które usprawiedliwia się faktem złożoności zagadnień ekonomicznych. Z drugiej strony w ekonometrii, gdzie mamy doczynienia z podejściem od dołu do szczytu w oparciu o dane rzeczywiste używane są różnego rodzaju modele funkcyjne, których parametry są szacowane na podstawie przeprowadzonych analiz statystycznych. Takie podejście może być bardzo użyteczne np. w przypadku realizacji ekonomicznych predykcji. Jednak jest ono ograniczone w aspekcie poznawczym danego zjawiska. Model mający charakter systemu typu „complex” będący pośrodku tych dwóch rozwiązań powinien rozpoczynać i kończyć się na danych. Oznacza to, że nisko poziomowe dane są wykorzystywane do formułowania założeń stanowiących podstawę tworzenia bloków modelu. Natomiast zarówno nisko jak i wysokopoziomowe dane są wykorzystywane do testowania wyników powstały ze zjawiska emergencji czyli nawiązuje w jakimś zakresie do rzeczywistości. Takie podejście powoduje, że aspekt ekonomiczny (np. preferencje w zachowaniu agentów) jest zanegowany na rzecz unrealnienia całego modelu (por. Farmer, 2012). Nauka o złożonych systemach „complex” bada zjawiska powstania interakcji pomiędzy niskopoziomowymi blokami wykorzystując do tego takie narzędzia jak symulację komputerową. Gdy zasady interakcji są już dobrze zrozumiałe to samo zadanie systemu „complex” jest stosunkowo proste i polega na skonstruowaniu symulacji, reprodukcji zjawiska emergencji i poszukiwaniu sposobu matematycznego opisu tego zjawiska.

Metodą pozwalającą na zrealizowanie podejścia do ekonomii jako systemu „complex” jest modelowanie wieloagentowy, które jak opisał Farmer i Foley, (2009) jest symulacją komputerową o określonej liczbie podejmujących decyzję agentów i instytucji, którzy oddziałują na siebie poprzez określone reguły. Taki model nie zakłada stanów równowagi, ani tego, że musi zajść jakaś interakcja w celu kontynuowania funkcjonowania całego rynku. Każdy agent w dowolnym momencie zachowuje się odpowiednio do otaczającej go sytuacji reagując na zewnętrzne bodźce. Komputer podąża za każdą interakcją występującą między

agentami i przechowuje ją w pamięci co pozwala przeprowadzać szereg analiz w celach poznaawczych. Modele wieloagentowe wykorzystują moce obliczeniowe komputerów w celu reprezentowania tak wielu różnych agentów jak tylko jest to możliwe. Dzięki temu, że agencie nie bazują na matematycznych równaniach pochodnych ani zamkniętych rozwiązańach to możliwe jest stosunkowo proste zaimplementowanie nieliniowych modeli zachowań bez ograniczeń w stosunku do rzeczywistości.

2.2 Podwójna aukcja w analizie rynku finansowego

W drugiej części tego rozdziału poruszona jest kwestia teoretycznego spojrzenia na model podwójnej aukcji z zastosowaną analizą wymiarową do opisu zależności zachodzących na rynku finansowym (por. Smith, i in. 2003). Kolejną istotną kwestią, która została opisana w tym rozdziale to teoretyczna podstawa agenta „low-intelligence” wykorzystanego w modelu zbudowanym w tej pracy. Składa się na nią opis wykorzystanego tutaj algorytmu propagacji wstecznej stosowanego w sztucznych sieciach neuronowych. Zakończenie tej części stanowi krótka charakterystyka efektywności rynków finansowych (por. Fama, 1970).

2.2.1 Podwójna ciągła aukcja

Zgodnie z Farmer, i in.(2003) analiza teoretyczna pozwalająca na zrozumienie spredu, wolumenu i funkcji impaktu na rynkach finansowych wykorzystywała do tej pory paradygmat agenta racjonalnego. Choć do szczegółowego opisu historii powstania koncepcji dojścia do rozwiązania bazującego na modelowaniu z wykorzystaniem agentów nieracjonalnych wykorzystanych przez Farmer, i in.(2003) odwołuję właśnie do ich pracy to warto zaznaczyć kilka znaczących faktów. Badania nad spredem opisał Demsetz (1968), gdzie odniósł się do kwestii związanej z kosztami transakcyjnymi i determinantami spredu jako wyniku maksymalizacji użyteczności kreatorów rynku (ang. market maker). Model bławdzenia losowego wykorzystali Lo, MacKinlay i Zhang (2002) badając reakcje maksymalizujących użyteczność agentów wpływających między innymi na takie parametry rynku jak wolumen. Model ten przewidywał pozytywną relację pomiędzy wolumenem, a ograniczonymi zamówieniami. Copeland i Gali (1983) analizowali wpływ efektu informacji asymetrycznej na proces składania zamówień.

Badania empiryczne również obfitują w obszerną literaturę i przykłady realizacji. Roll (1884) szacował wartość spredu na podstawie danych zawierających koszty transakcji. Badania

empiryczne nad wolumenem zostały zainicjowane przez opis statystyczny procesu kształcenia wolumenu przez Engle (1982). Kompleksowe badania nad dwuwymiarowym rozkładem prawdopodobieństwa wolumenu i stopy zwrotu zostały wykonane przez A.R. Gallanta, P.E. Rossiego oraz G.E. Tauchena (1992, 1993) (por. Farmer, i in. 2003).

W modelu ciągłej podwójnej aukcji wykorzystującej model typu błądzenia losowego widoczne są dwa trendy widoczne w literaturze ekonomicznej oraz w literaturze fizycznej. W literaturze ekonomicznej modele te są ukierunkowane na ekonometrię, a proces składania zamówień jest traktowany jako proces statyczny. W kontraste do tego podejścia modele w literaturze fizycznej przyjmują formę modeli konceptualnych, a poprzez przyzwolenie reagowania na zmiany ceny w procesie zamówień mogą być zakwalifikowane jako proces dynamiczny (por. Farmer, i in. 2003). Model zaproponowany przez Farmera, i in. (2003) łączy dwa trendy będąc zarówno modelem dynamicznym jak i wykorzystującym ekonometrię.

Pierwszym modelem w literaturze ekonomicznej zgodnie z Farmer, i in. (2003) był model opisany Mendelsona (1982), który zamodelował losowy proces składania zamówień z okresowym ich usuwaniem. Jednak losowy proces Poissona usuwania zamówień, wraz z zamodelowaniem zamówień ograniczonych oraz zamówień rynkowych wprowadził dopiero Cohen, i in. (1985). Jednak ograniczyli oni możliwość generowania cen ograniczonych zamówień do dwóch stałych wartości czyli najlepszej ceny kupna dla zamówienia kupna i analogicznie najlepszej ceny sprzedaży. Mogli w ten sposób obliczyć własności takie jak oczekiwana liczba przechowywanych ograniczonych zamówień, oczekiwany czas realizacji transakcji oraz względne prawdopodobieństwo realizacji transakcji versus usunięcie zamówień z księgi zamówień. Kolejną modyfikację polegającą na wprowadzeniu wielu poziomów cen (nie tylko dwóch) poprzez arbitralne składanie zamówień i ich usuwanie wprowadzili Domowitz i Wang (1994). Założyli oni, że te procesy są zakotwiczone w czasie i nie reagują na zmiany najlepszej oferty kupna i sprzedaży. Takie podejście pozwoliło im na określenie rozkładu dystrybucji spodu, cen transakcji oraz czasów oczekiwania na usunięcie zamówień. Jednak fakt występujących w modelu określonych wartości cen wpływa na brak możliwości określenia dyfuzji cen, generuje błędy w predykcji spodu, zgromadzonej podaży i popytu (por. Farmer, i in. 2003).

Jak już zostało opisane wcześniej modele opisane w literaturze fizycznej uwzględniają dynamikę cen poprzez zmianę realizacji procesu zamówień jako odpowiedź na zmiany ceny. Są to modele, których głównym celem było zrozumienie zjawiska dyfuzji cen. Jednak były to

modele uproszczone określane mianem konceptualnych. Pierwsze publikacje zostały przedstawione przez Bak, i in. (1996). Model ten został rozwinięty przez Eliezer i Kogan (1998) oraz przez Tang (1999). Założyli, że ograniczone zamówienia są składane o wartościach rozmieszczonych w stałej odległości od wartości środkowej. Następnie ceny tych ograniczonych zamówień są mieszane w sposób losowy do momentu wystąpienia transakcji. To właśnie ten losowy proces mieszania skutkował pojawieniem się dyfuzji cen. Maslov (2000) zaproponował odmienny model, który został rozwiązany analitycznie z wykorzystaniem teorii pola środkowego przez F. Slanina (2001). Każde zamówienie, zarówno kupna jak i sprzedaży jest wybierane losowo z równym prawdopodobieństwem. Jeżeli jest wybrane zamówienie ograniczone to jest ono umieszczone w sposób losowy w zakresie stałej odległości od obecnej ceny. Jednak zarówno w pracy zbiorowej Bak, i in. (1996) oraz w pracy Maslova, (2000) pojawiła się rozbieżność w zakresie analizy dyfuzji ceny, gdzie wartości wykładnika Hursta równej $H=1/4$, która powinna wynosić standardowo $H=1/2$ lub dla realnych wartości cen $H>1/2$ (por. Farmer, i in. 2003). Następnie pojawiły się dwa modele, które wprowadziły proces usuwania zamówień według rozkładu Poissona. Challet i Stinchcombe (2001) pokazali, że wykładnik Hursta w krótkim okresie faktycznie osiąga wartość $H=1/4$, ale w długim okresie asymptotycznie osiąga wartość $H=1/2$. Drugim modelem, który stanowi podstawę do badań przeprowadzonych przez Farmera, i in. (2003) jest model zaproponowany przez Danielsa, i in. (2003). Model ten oprócz stworzenia możliwości modelowania składania zamówień i ruchu cen jest zdefiniowany poprzez pięć skalarnych parametrów co umożliwiło testowanie go względem danych rzeczywistych. Model Danielsa, i in. (2003) umożliwia analizę wymiarową, która pozwala na oszacowanie predykcyjne wielu skalowalnych własności jak spred, wolumen, głębokość rynku, impakt ceny, prawdopodobieństwo i czas zrealizowania zamówienia (por. Farmer, i in. 2003).

W modelu występują trzy podstawowe wymiary czyli liczba akcji, cena oraz czas. Dodatkowo występuje pięć parametrów, na które składają się trzy wskaźniki przepływu zamówień i dwa dyskretne parametry. Wskaźniki przypływu to $\mu[(\text{liczba akcji})/(\text{jednostka czasu})]$ wskaźnik napływu zamówień rynkowych, a $[(\text{liczba akcji})/(\text{jednostka ceny} * \text{jednostka czasu})]$, wskaźnik napływu zamówień ograniczonych oraz $\delta[(1)/(\text{jednostka czasu})]$ wskaźnik zanikania zamówień ograniczonych. Dwa parametry dyskretne to minimalna wartość dozwolonej zmiany ceny (ang. tick) dp [cena] oraz wielkość zamówienia σ [liczba akcji]. Ze względu na to, że mamy trzy wymiary i pięć parametrów wszystkie własności księgi zamówień mogą być wyrażone w funkcji dwóch niezależnych parametrów. Redukcja wymiarów pozwoliła na stworzenie

bezwymiarowych parametrów zależnych wyłącznie od parametrów przepływu zamówień oraz na stworzenie bezwymiarowych wersji parametrów dyskretnych jako niezależnych, których postać pozostaje zrozumiała. Pozwoliło to otrzymać charakterystyczną liczbę akcji $N_c = \mu / 2\delta$, charakterystyczny interwał cenowy $p_c = \mu / 2\alpha$ oraz charakterystyczną podziałkę skali czasu na $t_c = 1/\delta$. Stała wartość liczby dwa w mianowniku jest wynikiem przyjęcia wskaźnika zamówień rynkowych dla kupna i sprzedaży równego $\mu / 2$. Tak sformułowane charakterystyczne wartości pozwalają na określenie bezwymiarowych koordynatów ceny $p_{\hat{h}} = p/p_c$, ilości akcji $N_{\hat{h}} = N/N_c$ i czasu $t_{\hat{h}} = t/t_c$. W ten sposób została zmniejszona liczba stopni swobody z pięciu do dwóch. Bezwymiarowe parametry bazujące na wielkości zamówienia są skonstruowane poprzez podzielenie pierwotnej wielkości zamówienia przez charakterystyczną liczbę ilości akcji N_c . Stąd otrzymany został parametr granularności zamówień przechowywanych w księdze zamówień $\epsilon = \sigma/N_c = \delta\sigma/\mu$. Bezwymiarowy parametr oparty na minimalnej wartości dozwolonej zmiany ceny został skonstruowany poprzez podzielenie przez charakterystyczny interwał cenowy czyli $dp/p_c = 2\alpha dp/\mu$. Analizy teoretyczne oraz symulacje pokazały, że niezerowa wartość dyfuzji ceny oraz skończona wartość spredy są osiągane przy minimalnej wartości dozwolonej zmiany ceny dążącej do zera $dp \rightarrow 0$. Ze względu na znakomy wpływ tego parametru na model przyjmuje się go zazwyczaj właśnie jako wartość dążąca do zera $dp \rightarrow 0$ co dobrze oddziałuje na oszacowanie skończonej minimalnej wartości dozwolonej zmiany ceny (por. Daniels, i in. 2003). Daniels, i in. (2003) wskazują, że symulacje bardzo dobrze odwzorowuje teorię dla dużych wartości ϵ . Dla małych wartości ϵ teoria dobrze odwzorowuje średnią wartość spredy. Predykcja pozostałych parametrów pozostaje jakościowo poprawna jednak brak jest dobrego odwzorowania ilościowego (por. Daniels, i in. 2003). Jak napisali Daniels, i in. (2003) nie oczekują od modelu, żeby dokładnie przewidywał ilościowo zamiany na rynku, a raczej oczekują, że model ten będzie dostarczał wyniki, które będą stanowiły benchmark do dalszej pracy nad jego rozwojem. Model przy założeniu losowego przepływu zamówień przedstawia w jaki sposób gromadzone podaż i popyt dostarczają tymczasowych interesujących własności dotyczących ceny i płynności. Demonstruje on również istotę rozwijania realistycznych modeli będących odzwierciedleniem mechanizmów zachodzących na rynkach finansowych (por. Daniels, i in. 2003).

Tabela nr 2. Charakterystyczne współczynniki dla analizy wymiarowej rynków finansowych na podstawie Smith, i in. (2003).

Oznaczenie	Nazwa	Nazwa ang.	Jednostki
------------	-------	------------	-----------

α	Współczynnik zamówień ograniczonych	Limit order rate	Shares/(price time)
μ	Współczynnik zamówień rynkowych	Market order rate	Shares/time
δ	Współczynnik usuwania zamówień	Order cancellation rate	1/time
dp	Minimalna wartość dozwolonej zmiany ceny	Tick size	Price
σ	Wielkość zamówienia	Characteristic order size	Shares
Nc	Charakterystyczna liczba akcji	Characteristic number of shares	$\mu/2\delta$
pc	Charakterystyczny interwał cenowy	Characteristic price interval	$\mu/2\alpha$
tc	Charakterystyczna podziałka skali czasu	Characteristic time	$1/\delta$
dp/pc	Bezwymiarowy parametr oparty na minimalnej wartości dozwolonej zmiany ceny	Non-dimensional tick size	$2\alpha dp/\mu$
ϵ	Parametr granularności zamówień	Non-dimensional order size	$2\delta\sigma/\mu$

Źródło: Smith, i in. (2003)

Farmer, i in. (2003) stworzyli model wykorzystujący koncepcję stworzoną przez Danielsa, i in. (2003), a następnie przeprowadzili symulację z wykorzystaniem danych z Londyńskiej Giełdy Papierów Wartościowych (ang. London Stock Exchange LES), która składa się z dwóch części otwartej elektronicznej księgi zamówień oraz rynku górnych notowań. Dane wykorzystane w projekcie Farmera, i in. (2003) pochodzą z elektronicznej księgi zamówień, jako że stanowią one większą część realizowanych transakcji na LSE oraz pozwalają na zebranie znacznie większej ilości informacji na temat transakcji przeprowadzonych przez każdą z biorących w nich udział instytucji. Dane pochodzą z okresu od 01.08.1998 do 30.04.2000 roku czyli 434 dni handlu, które dostarczyły około sześciu milionów zdarzeń. Przeanalizowanych zostało 11 firm, z udziałem których zostało wykonanych co najmniej 300 000 zdarzeń, a każdego dnia nie było ich mniej niż 80. Model nie uwzględnia danych z otwarcia aukcji. Jeżeli napływanające zamówienie niezależnie od typu zlecenia jest realizowane bezzwłocznie to jest ono traktowane jako zamówienie rynkowe. Jeżeli zamówienie pozostaje w kolejce księgi zamówień to jest ono traktowane jako zamówienie ograniczone. Wszystkie rodzaje usunięcia zlecenia są traktowane jako usunięcia. Pomiar czasu został zrealizowany w oparciu o liczbę zdarzeń. Czas jaki upłynął w danym okresie to suma wszystkich zdarzeń w tym czasie. Interwał cenowy został policzony

jako różnica logarytmów ceny. W celu bardziej szczegółowego opisu pozyskiwania danych odwołujemy do pracy Farmera, i in. (2003).

Pomiar dyfuzji ceny między kolejnymi dniami jest realizowany poprzez pomiar wariancji średka ceny $V(\tau) = \text{Var}\{m(t+\tau) - m(t)\}$ dla różnych skali czasu τ . W przedziale czasu t są uśredniane wszystkie zawierające się w nim zdarzenia, które zmieniły wartość środkowego punktu ceny. Wykres $V(\tau)$ względem τ jest określany jako krzywa dyfuzji zarówno dla niezależnego jak i identycznego rozkładu o charakterze błądzenia losowego jest to linią prostą o współczynniku kierunkowym równym wartości współczynnika dyfuzji D . Pomiar D jest realizowany każdego dnia. Następnie do dziennej krzywej dyfuzji jest dopasowywana linia prosta $V(\tau) = Dt^*\tau$. Realizowane jest to poprzez wykorzystanie metody najmniejszych kwadratów ważonych pierwiastkiem liczby obserwacji dla każdej $V(\tau)$. Wskaźnik dyfuzji z dnia na dzień jest znacząco skorelowany. Tutaj należy odnieść się do wykresów zamieszczonych w pracy przez Farmer, i in. (2003), strona 12, rysunek 6 i 7 przedstawiających procedurę pomiaru współczynnika dyfuzji ceny dla firmy Vodafone oraz szereg czasowy wraz z funkcją autokorelacji dla dziennych współczynników dyfuzji ceny również dla firmy Vodafone.

Współczynnikiem dyfuzji ceny jest w centrum zainteresowania ponieważ wpływa on na zmienność cen przez co jest kluczowym determinantem ryzyka finansowego. Jeżeli założymy, że ceny wykonują losowy spacer (mają charakter błądzenia losowego) to dyfuzja cen jest miarą wielkości i częstotliwości kroków. Wariancja nieskorelowanych normalnych losowych kroków po czasie t rośnie według zależności $V(t)=D*t^{2H}$, gdzie D jest współczynnikiem dyfuzji, H jest wykładnikiem Hursta, który dla rynków finansowych wynosi 0,5. Jednak dla badanego modelu ze względu na dynamikę kształtowania się cen poprzez podwójną ciągłą aukcję oraz przepływ zamówień realizowany według rozkładu Poissona ceny wykazują silnie nieskorelowany charakter białego szumu. Dla krótszych czasów $H<0,5$ choć dla dużych zakresów t , $H=0,5$. Stąd też jako alternatywne rozwiązanie na potrzeby modelu został utworzony zależny od czasu współczynnik dyfuzji w taki sposób, żeby wariancja ceny była wyrażona następującą zależnością $V(t)=D(t)*t$ zgodnie z Daniels, i in. (2003) oraz Smith, i in. (2003). Zależny od czasu współczynnik dyfuzji ceny został wyrażony następująco: dla $t>0$, $D(0)\sim\mu^2\delta/\alpha^2\varepsilon^{-1/2}$ oraz dla $t>\infty$, $D(\infty)\sim\mu^2\delta/\alpha^2\varepsilon^{1/2}$, gdzie ε jest parametrem granularności przepływu zamówień. Parametr granularności jest bezwymiarowy i wyraża się następującą zależnością: $\varepsilon:=\sigma/N_c=\delta\sigma/\mu$, gdzie N_c jest charakterystyczną ilością akcji i równa jest δ/μ . Farmer, i in. (2003) wykazują, że

struktura rynku oparta na zasadach podwójnej aukcji ma znaczący wpływ na ruch jaki odbywa się na rynku. Model ten pozwala określić zachowanie rynku, które w wielu aspektach jest zbliżone ilościowo do zachowania rynku rzeczywistego. W pracy Briggs, et. al. (2008?) widzimy, że wyniki symulacji na podstawie modelu Farmer, i in. (2003), który przedstawił porównanie wyników symulacji modelu podwójnej aukcji z agentami ZIT do danych z Londyńskiej Giełdy Papierów Wartościowych (ang. *LSE London Stock Exchange*) wskazują na konkretne różnice pomiędzy modelem, a rzeczywistym rynkiem jak na przykład brak widocznego grupowania w zmienności rynku. Wolumen podobnie jak i wartości średnich zwrotów rynku są dość spójne. Brak jest pozytywnej stałej autokorelacji bezwzględnych wartości stopy zwrotu. Średnia wartość stopy zwrotu na krok jest na poziomie 20% czyli znacznie wyższa wartość niż wartości empiryczne przynajmniej w rozpatrywanym krótkim przedziale czasu (dzień lub mniej). Zjawisko jest szczególnie widoczne, gdy jest rozpatrywane na rzeczywistych wartościach cen z księgi zamówień. Te same ceny, które zeskalowane logarytmicznie wyglądają stosunkowo racjonalnie, w skali rzeczywistej są bardzo zmienne. Wykresy zaprezentowane w pracy Brigs, i in.(2008?) stanowią pewien odnośnik do oszacowania wykresów powstałych po wykonaniu symulacji z wykorzystaniem podstawowego modelu Farmera, i in. (2003) z agentami cierpliwyimi i niecierpliwyimi. Choć część parametrów pozwalających ustawić model była znana to na przykład liczba agentów danego typu nie została podana. Stąd oczywistym jest, że wyniki będą się różniły, ale powinny zachować zbliżony charakter. Brigs, 2008?, strona 7, rysunek 5g przedstawiający wartości stóp zwrotu od kroków czasowych wskazuje na 3000 wykonanych kroków, gdzie zakres wartości stóp zwrotu waha się w od -0,85 do 0,95 przy czym jest tylko jedna wartość równa około 0,95, a pozostałe to maksymalnie 0,85. Rozkład jest zmienny i stosunkowo stały posiadający losowy charakter choć jest to jedynie oszacowanie organoleptyczne. Wolumen przedstawiony na wykresie Brigs, 2008?, strona 7, rysunek 5d wskazuje na stały przedział bez grupowania wartości o stałym rozkładzie w zakresie między 275, a 375. Widoczne są również skrajne punktu osiągające wartości około 260 oraz 285. Wykres autokorelacji stóp zwrotu Brigs, 2008?, strona 7, rysunek 5d mieści się w przedziale -0,05 i 0, 05 przy 9 punktach wychodzących poza obszar tej granicy na 200 istniejących.

Jako sugerowaną formę rozwoju modelu oraz działanie, które może wpłynąć na rozwiążanie problemu antykorelacji wygenerowanej przez mechanizm podwójnej aukcji jest wprowadzenie agenta typu „low intelligence” (por. Farmer, i in. 2003).

Przyrost rzeczywistych cen na rynkach finansowych generalnie posiada charakter typu błądzenia losowego. Można byłoby błędnie pomyśleć, że przy niezależnym i identycznym

rozkładzie Poissona przepływu zamówień przyrost cen również powinien mieć rozkład niezależny i identyczny. Jednak ze względu na warunki brzegowe parowania odpowiednio ofert kupna i sprzedaży z odpowiadającymi ograniczonymi ofertami sprzedaży i kupna taki rozkład nie występuje. Ze względu na fakt, że podaż i popyt mają tendencję rozbudowywającą (np. wzrasta głębokość oczekujących ograniczonych zamówień) wraz z każdym ruchem zwiększać odległość od środka księgi zamówień, a zmiany zwrotu cen są częściej występujące niż zmiany z zachowaniem tego samego zwrotu na określonym kierunku. W wyniku takiego ruchu przyrosty ceny wygenerowane przez ten model są bardziej antyskorelowane aniżeli te realne ceny w serii.

2.2.2 Model z agentem „low-Intelligence”

Zgodnie ze wskazaniami dalszego rozwoju modelu Farmera, i in. (2003) do pracy został wprowadzany agent typu Low-Intelligence. Niski poziom inteligencji w przeciwieństwie do zerowego czyli losowego poziomu inteligencji został utworzony na podstawie implementacji algorytmu wykorzystującego model jednokierunkowej (ang. feed forward) sieci neuronowej. Dzięki możliwości uczenia się z wykorzystaniem algorytmu propagacji wstecznej (ang. back propagation) agent może analizować sytuację i podejmować odpowiednie decyzje na podstawie otaczających go bodźców oraz zdarzeń, które miały miejsce na rynku.

Sieci neuronowe umożliwiają budowanie modeli reprezentujących zagadnienia wielowymiarowe o wysokim stopniu nieliniowości. Właśnie dlatego są dobrym rozwiązaniem do zastosowania w tak złożonym systemie jak ekonomia (por. Grothmann, 2002).

Wykorzystanie sieci neuronowych jako modelu zachowania się agenta typu low-intelligence pozwala na zamodelowanie agenta, który podejmuje decyzje na podstawie przeprowadzonego procesu predykcyjnego, którego podstawą jest algorytm zaimplementowany w sieci neuronowej. W pierwszej kolejności agenci trenują na podstawie danych historycznych wykorzystując przejście jednokierunkowe przez sieć (ang. feed forward). Następnie po utworzeniu zbioru danych historycznych następuje uczenie sieci z wykorzystaniem algorytmu propagacji wstecznej (ang. back propagation). Zgodnie z Grothmannem,(2002) połączenie modelu wieloagentowego z zaimplementowaną siecią neuronową, która umożliwia przewidywanie wartości przyszłych stóp procentowych pozwala nam otrzymać model ekonometryczny z możliwością badania zachowania się samej dynamiki systemu.

Zgodnie z Grothmannem, (2002) sieci neuronowe są formą reprezentacji funkcjonowania umysłu ludzkiego z wykorzystaniem algebraicznych form tej reprezentacji. Umysł można przedstawić jako złożony, nieliniowy i równolegle przetwarzający informacje system.

Zgodnie z Ng, (2015) mózg zbudowany jest z komórek zwanych neuronami. Posiadają one wiele połączeń, przez które są przesyłane dane wejściowe. Te połączenia nazywa się dendrytami. Połączenia wyjściowe, którymi informacja się wydostaje z neuronu określana jest jako akson. Patrząc na neuron poprzez pryzmat matematycznego modelu komórka otrzymuje szereg informacji wejściowych, które przetwarza generując informacje wyjściowe. Neurony komunikują się pomiędzy sobą wysyłając impulsy elektryczne. Informacja wychodząca z aksonu jednego neuronu jest odbierana poprzez dendryt drugiego neuronu. Połączenie pomiędzy aksonem i dendrytem nazywa się synapsami. Po przetworzeniu informacji przez neuron podejmowana jest decyzja czy dana informacja powinny być przesłana dalej do kolejnych neuronów.

Przykładowa struktura sztucznej sieci neuronowej składa się z warstw (ang. layer), neuronów wejściowych x, neuronów wyjściowych y, połączeń pomiędzy neuronami, na których występują wagi (ang. weight), oraz neuronów w warstwach pośrednich, w których występują funkcje aktywacji. Funkcja aktywacji jest odpowiedzialna za to czy na podstawie sygnału wejściowego i określonej wagi informacja będzie przesłana dalej i w jakiej postaci. W modelu często są również wprowadzane w warstwach dodatkowe neurony ze stałą wartością (ang. bias), która wspomaga układ podczas uczenia przesuwając charakterystykę funkcji aktywacji co poprawia ustawienie granicy klasyfikacji wyników.

Zgodnie z Grothmannem, (2002) współczynniki wagowe odpowiadają za siłę informacji pochodzącej od danej wejściowej. Wagi mogą przyjmować zarówno dodatnie jak i ujemne wartości. Połączenie jest odpowiednikiem synapsy w biologicznym neuronie. Jeżeli informacja osiągnie określony poziom aktywacji to neuron z warstwy pośredniej generuje informację wyjściową. Za zachowanie przepuszczania informacji odpowiada wspomniana już funkcja aktywacji. W zależności od rodzaju funkcji aktywacji zakres wartości ma określony zakres. Przepuszczana wartość może mieć charakter binarny lub ciągły. Na podstawie napływających informacji, które stanowią dane wejściowej sieć neuronowa podejmuje decyzje, które dane są istotne. Następnie dane są filtrowane i na podstawie wybranych danych podejmowana jest ostateczna decyzja odnośnie kupna lub sprzedaży akcji.

Przygotowanie modelu sieci neuronowych jak wskazuje Ng, (2015) odbywa się w następujących etapach: wybór architektury, trenowanie, uczenie. W pracy zastosowano sieć z dwiema warstwami pośrednimi, jednym wyjściem, czteroma wejściami po dwie zmienne oraz

dodatkowe neurony o stałej wartości (ang. bias). Jako funkcję aktywacji została przyjęta funkcja tangens hiperboliczny.

$$\operatorname{tgh} x = \frac{\sinh x}{\cosh x} = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (4)$$

Przyjęcie takiej funkcji aktywacji pozwala na otrzymanie wyniku o ciągłych wartościach od -1 do 1 co może być w wygodny sposób interpretowane jako wartość stopy zwrotu -100% lub +100%. Encog używa funkcji aktywacji w celu zeskalowana wartości wyjściowych z warstw sieci neuronowej. Jest to istotny element z punktu widzenia trenowania sieci. Należy pamiętać, że funkcja aktywacji przy wykorzystaniu algorytmu propagacji wstecznej musi być różniczkowalna. Wynika to z wykorzystania metody gradientu prostego w celu określenia optymalnych wartości wag.

Podczas symulacji generowany jest zbiór treningowy. W tym etapie wartości wag są generowane losowo. Po wygenerowaniu zbioru treningowego implementowany jest algorytm propagacji wstecznej, dzięki któremu obliczane są optymalne wartości wag.

Algorytm propagacji wstecznej został wprowadzony do sieci neuronowych w 1986 roku przez Davida Rumelharta, Geoffreya Hintona oraz Ronaldą Williamsa. Algorytm wstecznej propagacji błędów został pierwotnie wprowadzony do nauki przez Paula Werbosa w 1974 roku w jego pracy doktorskiej napisanej na Uniwersytecie Harvard. Jedną z najbardziej istotnych pozycji w literaturze lat osiemdziesiątych dwudziestego wieku dotyczącej sieci neuronowych była książka grupy naukowców pod przewodnictwem Davida Rumelharta pod tytułem: „Parallel Distributed Processing: Explorations in the Microstructure of Cognition” (por. Grothmann, 2002)

Metoda propagacji wstecznej jest realizowana przy uczeniu sieci z nadzorem. Oznacza to, że algorytm treningowy jest implementowany na zbiorze treningowym, w którym dane wejściowe posiadają idealne dane wyjściowe. Innymi słowy uczymy sieć neuronową na znanym zbiorze. Algorytm propagacji wstecznej przechodząc przez serię iteracji zmniejsza w każdym przejściu błąd funkcjonowania sieci neuronowej. Wartość błędu jest różnicą procentową pomiędzy aktualną wartością wyjścia, a idealną wartością wyjścia, która jest w badanym zbiorze treningowym. Wartość wagi jest obliczana dla każdej danej znajdującej się w zbiorze treningowym. Platforma Encog aktualnia wartość wagi przy każdej iteracji.

Każda iteracja rozpoczyna się od wykonania pętli przez wszystkie elementy w zbiorze treningowym. Dla każdego elementu jest wykonywany podwójny proces przejścia, a mianowicie proces jednokierunkowego przejścia do przodu od wejścia do wyjścia oraz proces

propagacji wstecznej. Proces przejścia jednokierunkowego do przodu jest typową kalkulacją danych w sieci neuronowej w taki sposób, jak gdyby nie był realizowany proces treningowy. Podawane są dane na wejściu, następnie odbywa się proces kalkulacji czyli przetwarzania informacji przez sieć i obliczana jest wartość wyjściowa dzięki czemu następnie obliczany jest błąd.

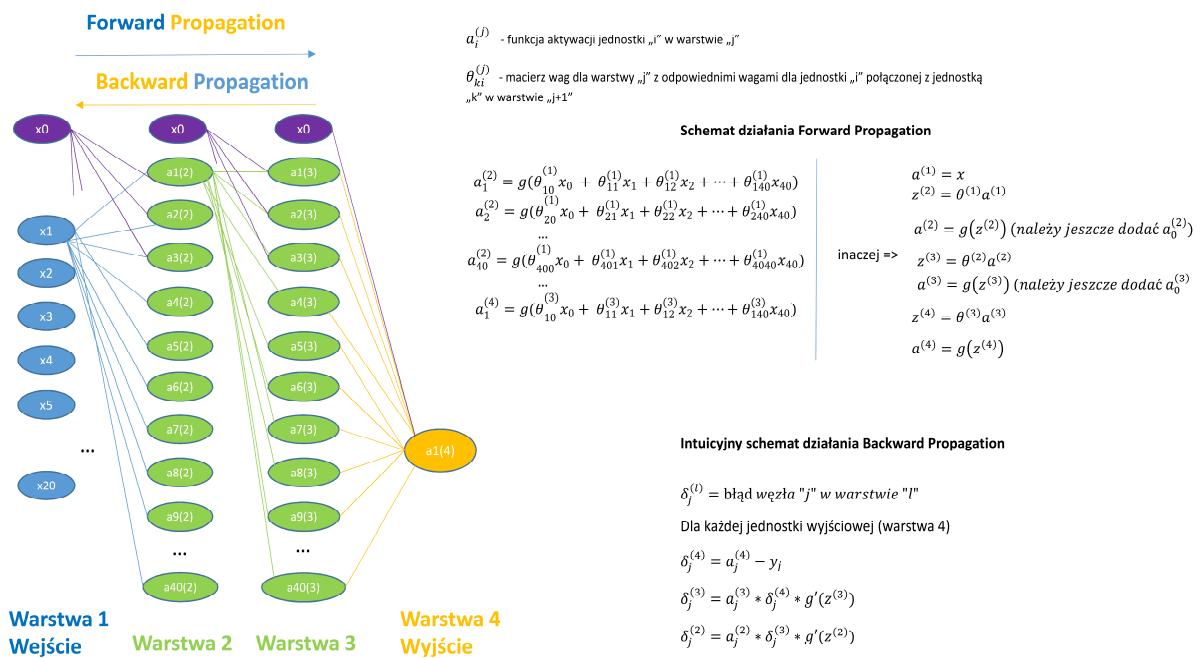
Przejście z propagacją wsteczną wykorzystuje pochodną wartość funkcji aktywacji w celu obliczenia błędu dla każdego połączenia w sieci neuronowej poprzez implementację algorytmu gradient prostego

Jednym z parametrów algorytmów propagacji wstecznej jest parametr uczenia. Iloczyn parametru uczenia i gradientu jest dodawany do macierzy wag i w ten sposób przeprowadzony jest proces optymalizacji wartości wag w celu generowania najmniejszych błędów. Zgodnie z Ng, (2015) parametr uczenia można potraktować jak wielkość skoku pomiędzy kolejnymi punktami, w kierunku wyznaczanym przez gradient, w celu poszukiwania optymalnej wartości wagi.

Problem jaki pojawia się przy wykorzystaniu algorytmu gradientu prostego to dążenie do lokalnego minimum. Choć lokalne minimum z pewnością jest punktem niskiej wartości błędu to nie musi ono stanowić najmniejszej globalnej wartości błędu.

Drugi parametr algorytmu propagacji wstecznej, który pozwala na wyjście z lokalnego minimum jest nazwany momentem. Moment określa w jakim stopniu zmiany wag w poprzednich iteracjach powinny wpływać na zmianę w obecnej.

W celu wykorzystania momentu algorytm propagacji wstecznej musi śledzić zmiany jakie zaszły w wagach we wcześniejszych iteracjach (por. Heaton, 2011).



Rysunek nr 2. Schemat struktury sztucznej sieci neuronowej zaimplementowanej w opisywanym projekcie wraz ze schematycznie przedstawionym algorytmem Froward Propagation oraz Backward propagation czyli sieci jednokierunkowej z algorytmem wstecznej propagacji.

Źródło: Rysunek i opis matematyczny zostały przygotowane w oparciu o materiały przygotowane przez Ng., (2015).

2.2.3 Efektywność rynków finansowych

„Najbardziej podstawową zasadą wszystkich gier hazardowych to równe warunki np.: między graczami, między widzami, finansowe, w danej sytuacji, pojemników na kości i w końcu między samymi kościemi do gry. Stopień odchylenia od poziomu równości na korzyść oponenta jest stopniem poziomu głupoty gracza, a stopień odchylenia na korzyść gracza jest stopniem jego nieuczciwości” tak pisał już w 1565 roku prominentny włoski matematyk Girolamo Cardano w swoje książce „Libre de Ludo Aleae” (pl. Księga gier losowych). Ponad trzysta lat później w 1876 roku farmer z Ohio Samuel Benner napisał „Przepowiednie Bennera przyszłych wzrostów i spadków cen”, gdzie zawarł następujące zdanie „Cena dowolnego produktu jest eksponentą zakumulowanej dostępnej wiedzy kraju o podaży i przewidywanym popycie na ten produkt...”. W tym samy wieku 13 lat później w 1889 roku efektywność rynków została już jednoznacznie powiązana z informacją dotyczącą akcji. George Gibson w swojej książce zatytułowanej „Rynki finansowe w Londynie, Paryżu i Nowym Jorku” napisał, że gdy „akcje

stają się publicznie znane na otwartym rynku ich wartość może być odniesiona do najlepszego wywiadu na ich temat". (por. Sewell, 2012).

Zgodnie z Weatherall, (2013) jeżeli przyjąć, że rynek składa się z wielu poinformowanych graczy, którzy zgadzają się na cenę w jakiej są oferowane akcje to cenę akcji można zinterpretować jako cenę, która uwzględnia wszelkie możliwe informacje na temat tych akcji. Jest to cena przy takiej liczbie poinformowanych uczestników na rynku, zakładających że cena wzrośnie, ilu zakładających że cena spadnie. Innymi słowy cena w danym momencie odzwierciedla wszystkie informacje na jej temat sugerując, że wzrośnie ona z prawdopodobieństwem 50% równym prawdopodobieństwu, że cena ta zmaleje. Jeżeli rynki funkcjonują w sposób sugerowany przez Bachelier, (1900) to hipoteza, że mają one charakter błędzenia losowego znajduje tutaj swoje uzasadnienie i jest ona istotną kwestią podstawy funkcjonowania rynków finansowych (por. Weatherall, 2013). Takie spojrzenie na rynki jest określone dzisiaj mianem hipotezy rynku efektywnego, której podstawowym założeniem jest to, że cena akcji odzwierciedla prawdziwą jej wartość ponieważ zawiera ona wszelkie dostępne na jej temat informacje. Pierwszym, który zasugerował taką koncepcję był Bachelier, jednak ten, który przedstawił światu i opracował tę hipotezę jest Eugene Fama (Fama, 1965) (por. Weatherall, 2013).

2.2.4 Efektywność rynków finansowych według Fama, (1970)

Hipoteza efektywnego rynku (ang. efficient market hypothesis EMH) od 1970 roku była centralną teorią rynków finansowych i jest jedną z najczęściej studiowanych hipotez w socjologii. Jednak nadal, nawet w środowisku ekonomistów, nie ma osiągniętego konsensu w kwestii tej teorii (por. Sewell, 2012).

Rynek zawierający zbiór informacji i jest efektywny wtedy, gdy cena w pełni odzwierciedla ten zbiór informacji zgodnie z Fama, (1970) np. jeżeli cena pozostałyby niezmieniona po ujawnieniu zbioru informacji wszystkim uczestnikom rynku. Klasyczna taksonomia zbiorów informacji przedstawiona przez Fama, (1970) składa się z trzech zbiorów:

1. Słaba forma efektywności rynku, gdzie zbiór informacji zawiera jedynie historię cen.
2. Średnia forma efektywności rynku, gdzie zbiór informacji zawiera wszystkie znane (publicznie dostępne) wszystkim uczestnikom rynku informacje.

3. Silna forma efektywności rynku, gdzie zbiór informacji zawiera wszystkie znane (włącznie z prywatnymi) wszystkim uczestnikom rynku informacje.

Zbiory są zagnieżdżone w sposób, w którym każdy następny zbiór jest odpowiednio nadzbiorem poprzedniego. Kwestia weryfikalności i możliwości istnienia EMH zawsze była przedmiotem sporu. Efektywny rynek zawsze w pełni odzwierciedla dostępne informacje, ale w celu określenia w jaki sposób rynek w pełni powinien odzwierciedlać te informacje należy określić kwestię preferencji inwestorów podejmowania ryzyka. Stąd też każdy test EMH jest zarówno testem efektywności rynku jak również preferencji inwestorów do podejmowania ryzyka. Jest to powód, dla którego EMH nie jest dobrze zdefiniowaną, a zatem empirycznie łatwą do odrzucenie hipotezą.

Zgodnie Nikunj, i in. (2011) jest ogólnie przyjęte, że rynki rozwinięte są bardziej efektywne niż te rozwijające się i te jeszcze nie rozwinięte. Definicja efektywności rynków finansowych (Fama, 1970) odnosi się do efektywności informacyjnej. Według Nikunj, i in. (2011) oznacza to, że nie ma strategii inwestycyjnej, która mogłaby być wykorzystana do predykcji cen na rynku oraz żaden z uczniaków nie może wypracować niestandardowo wysokiego zwrotu. Zgodnie z definicją zmiana kolejnej wartości ceny względem tej, która ją poprzedza posiada niezależny i identyczny rozkład losowy. To sugeruje, że zmiana serii cen nie posiada pamięci (Fama, 1965).

3 Wieloagentowe modelowanie rynków finansowych

Rozdział trzeci porusza kwestię modelowania wieloagentowego jako formy symulowania rynków finansowych. Pierwsza część stanowi ogólne wprowadzenia, a w drugiej została omówiona platforma informatyczna MASON pozwalająca na zrealizowanie symulacji wieloagentowej z wykorzystaniem języka programowania Java. Trzecią część tego rozdziału stanowi opis modelu zbudowanego w tej pracy.

3.1 Agenci na rynkach finansowych

Rozpatrując modelowanie wieloagentowe w pierwszej kolejności chcielibyśmy zdefiniować pojęcie agenta. Definicja agenta przetoczona przez Gilbert i Troitzsch, (2005), którzy odnieśli się do Huhns i Singh, (1998) mówi, że pojęciem agenta określa się samoistny program, który samodzielnie kontroluje swoje akcje w oparciu o odbierane bodźce z otaczającego go środowiska. W odniesieniu do modelu ludzkiego pojęcie agenta ma charakter odwzorowujący charakter określonego działania człowieka. Posiada on następujące cechy: jest autonomiczny (nikt nie narzuca mu realizacji konkretnych działań), posiada zdolności socjalne (oddziałuje z innymi agentami w swoim środowisku), jest reaktywny (w stosunku do otaczającego środowiska), jest proaktywny (sam może rozpoczęć proces reaktywności w środowisku). Agent najczęściej posiada pewien stopień intencjonalności w zakresie swojego zachowania (posiada przekonania, pragnienia, motywy, a nawet emocje). Agenci rozpatrywani poprzez pryzmat wiedzy i przekonań muszą realizować swoje akcje w oparciu o to co wiedzą o swoim środowisku (oraz innych agentach). Aspekt wnioskowania przez agenta oparty jest o zbiór przekonań jakie posiada. Model socjalny zakłada, że agenci posiadają zdolność uczenia się na temat wewnętrznych relacji zachodzących pomiędzy innymi agentami, a światem, w którym wszyscy partycypują. Rozpatrując cele jakie agenci mają do osiągnięcia wyłania się potrzeba usatysfakcjonowania wewnętrznego celu jakim jest przetrwanie co staje się motorem napędowym do realizacji innych założeń. Agent musi określić drogę, proces postępowania wiodący go do osiągnięcia założonych celów stąd musi planować swoje działania. Pomiędzy agentami zachodzi pewna interakcja, która jest realizowana za pomocą języka, który strony rozumieją. W sferze emocji występujących u agentów nieroziwiązaną kwestią pozostaje czy emocja jest jednostką jako taką czy jest powstałą cechą w wyniku zdolności poznawczych i podświadomych stanów. Stąd powstaje kwestia do rozwiązania z chęcią odpowiedzi na pytanie jaka jest relacja pomiędzy celem, a emocją.

W odniesieniu do architektury istotnymi technikami, które rozwiązuje takie problemy jak złożoność, rozwiązywalność prostych ludzkich zachowań jak np. zdrowy rozsądek, mała odporność na drobne zmiany są systemy produkcyjne, programowanie obiektowe uczenie maszynowe, tworzenie i parsowanie języka.

Z naszego punktu widzenia najistotniejszym elementem w tworzeniu architektury dla modelowania wieloagentowego jest właśnie programowanie obiektowe. Zgodnie z Gilbert i Troitzsch, (2005) obiektami są struktury programowe, które przechowują zarówno dane jak i zestawy procedur pozwalających wykonywać operacje na tych danych. Zmienne są przechowywane w polach, a procedury określone są mianem metod. Obiekty są tworzone z klas, które określają charakter obiektu, dane, na których obiekt pracuje oraz metody, które wykorzystuje. Klasy mogą być zorganizowane w hierarchii pozwalającej na dziedziczenie pewnych cech od klas nadrzędnych. Mogą również zachowywać się jak gdyby były instancjami innych klas w drzewie dziedziczenia czyli mogą być polimorficzne.

Projektowanie środowiska, w którym funkcjonują agenci (np. agenci reprezentujący ludzi) będzie skupione na stworzeniu przestrzeni reprezentującej kontekst, w którym agenci funkcjonują. Następnie agenci są umieszczani w świecie np. na siatce w określonych węzłach pomiędzy, którymi mogą się poruszać. Idealnym rozwiązaniem jest możliwość reagowania agentów w świecie w sposób równoległy. W przeciwny razie należy definiować porządek według, którego agenci będą funkcjonowali.

W roku 2010 Macal i North (2010) określili modelowanie i symulacje w oparciu o układ z wykorzystaniem agentów (ang. agent-based modelling and simulation, ABSM) jako względnie nowe podejście do modelowania systemów złożonych z autonomicznymi, wchodzący w interakcję agentami. Tego typu podejście jest formą modelowania dynamiki złożonych systemów. Systemy takie mają zdolność do samoorganizacji i tworzenia wewnętrznego porządku. Zawierają one również modele zachowań (np. zachowań ludzkich) i są używane do obserwacji efektu kolektywizacji oraz interakcji zachodzących pomiędzy agentami.

Zachowanie agentów jest często opisane prostymi zasadami oraz interakcjami pomiędzy innymi agentami, które wpływają na zachowanie każdego z agentów. Samoorganizacja jest zauważalna wtedy, gdy system jest budowany z dołu na szczyt czyli agent po agencie i interakcja po interakcji. To właśnie te dwie cechy czyli heterogeniczność oraz samoorganizacja systemu są dwiema cechami wyróżniającymi modelowanie wieloagentowe wśród innych technik (por. Macal i North, 2010).

Aplikacje modelowania wieloagentowego obejmują bardzo szeroki zakres zastosowania. Począwszy od modelowania rynków finansowych, które zostały przedstawione w tej pracy jak

również zgodnie ze wskazaniem Macal i North, (2010) są zaprezentowane przez Arthur, i in. (1997)¹. Kolejnymi obszarami są na przykład symulacje łańcuchów dostaw (Macal, 2004a), rozprzestrzenianie się epidemii (Bagni, i in. 2002), stosowanie broni biologicznych (Carley, i in. 2006), modelowanie możliwości adaptacyjnych układu immunologicznego (Folcik, i in. 2007), symulacje rynku konsumenckiego w celu zrozumienia zachowania kupujących (North, i in. 2009), badania starożytnych cywilizacji (Kohler, i in. 2005), modelowania zaangażowania sił na polu walki (Moffat, i in. 2006) czy na morzu (?Hill, i in. 2006) oraz wiele innych (por. Macal i North, 2010).

Struktura modelu wieloagentowego składa się ze zbioru agentów, ich atrybutów, zachowań, zbioru relacji jakie zachodzą między tymi agentami (czyli znajdującej się u podstaw topologii połączeń określających w jaki sposób i z kim agenci wchodzą w interakcję) oraz ze środowiska, w którym agenci się znajdują (por. Macal i North, 2010). Zwizualizowanie struktury typowego agenta przedstawia Marcal i North, 2010, rysunek 1, strona 152 na podstawie Epstein i Axtell, 1996.

Najistotniejszą cechą, która określa agentów jest ich zdolność do bycia autonomicznymi czyli zdolność do samodzielnego funkcjonowania w sytuacji, w której się znaleźli bez zewnętrznych nakazów. Agenci posiadają cechy, które pozwalają im podejmować samodzielne decyzje. Generalnie agenci są aktywni, a ich akcje są inicjowane chęcią osiągnięcia wewnętrznego celu. Są również reaktywni w stosunku do innych agentów oraz do środowiska. Agenci są samodzielnymi, modułowymi oraz unikalnie określonymi jednostkami. Oznacza to również, że agenci posiadają swoje ograniczenia. Jak już wcześniej zostało wspomniane są autonomiczni oraz sami określają kierunki swoich działań. Mogą działać niezależnie w swoim środowisku oraz w obszarze swojej interakcji z innymi agentami. Stany w jakich znajdują się agenci mogą różnić się w czasie. Są socjalnie ukierunkowani przez co wchodzą w dynamiczne interakcje z innymi agentami co bezpośrednio wpływa na ich zachowanie. Komunikują się ze sobą poprzez określone protokoły. Innymi ważnymi cechami są zdolności adaptacyjne np. poprzez posiadanie zaimplementowanych zasad zachowania. Oznacza to, że mogą mieć zdolność do uczenia się poprzez akumulowanie swoich doświadczeń co wpływa na ich zachowanie, a dalej na możliwość adaptowania się do sytuacji. Agenci mogą być zorientowani na konkretny cel, który muszą osiągnąć (nie koniecznie musi to być forma optymalizacji jakiegoś parametru). Agenci mogą być heterogeniczni w odróżnieniu od symulacji częstek, gdzie muszą one być względnie homogeniczne jak np. cząsteczki gazu idealnego czy symulacje dynamiki molekuł.

¹ Wszystkie przywołania literatury w tym akapicie za Macal i North, (2010).

W modelu wieloagentowym wszystko co jest związane z agentem jest albo jego atrybutem albo metodą, która wykonuje operacje na tym atrybutie. Atrybuty mogą być statyczne jak np. nazwa agenta lub dynamiczne jak np. pamięć agenta o wydarzeniach z poprzednich iteracji.

Jednym z dużych wyzwań w modelowaniu wieloagentowym jest modelowanie relacji i interakcji zachodzących pomiędzy agentami. Określają one zarówno to kto z kim i w jaki sposób jest połączony jak również określają samą dynamikę mechanizmu interakcji. Jednym z głównych założeń złożonego systemu oraz modelu wieloagentowego jest to, że agenci mają dostęp wyłącznie do informacji lokalnej, a sam system jest zdecentralizowany. Agencie wchodzą w interakcję ze sobą, ale nie każdy agent musi wejść w interakcję z każdym agentem. Agenci najczęściej wchodzą w interakcję wyłącznie z pewną określoną grupą agentów, których określa się mianem sąsiadów (ang. neighbours). Topologia czyli system połączeń, którymi powiązani są agenci może być w postaci przestrzennej kratownicy lub sieci z węzłami, gdzie każdy węzeł to agent, a połączenie to relacja. Topologia określa, kto komu przekazuje informacje. Pierwotnie przestrzeń agentów była modelowana jako automaty komórkowe (ang. cellular automata, CA) (Garder, 1970). Komórki otaczające agenta stawały się jego sąsiadami. Każda komórka może być interpretowana jako agent, który wchodzi w interakcję z zakotwiczonym zbiorem sąsiadujących komórek. W komórkach agenci poruszają się z jednej komórki do drugiej sąsiadującej przy czym w jednej komórce nie może się znajdować więcej niż jeden agent. Model przestrzeni Euklidesowej umożliwia agentom wędrowanie w dwu, trzy lub więcej wymiarowej przestrzeni. Sieć pozwala na zdefiniowanie sąsiedztwa w sposób bardzo ogólny przy czym sieć może być zarówno statyczna jak i dynamiczna. W topologii bazującej na Systemie Informacji Geograficznej agenci przemieszczają się pomiędzy obszarami. W topologii zwanej „zupą” lub modelem nieprzestrzennym agent nie posiada żadnej lokalizacji ponieważ nie jest ona istotna. Agenci są wybierani losowo w celu interakcji a następnie wracają do „zupy” jako kandydaci do przyszłych interakcji (por. Macal i North, 2010). Taki model jest zaprezentowany w tej pracy. Wizualizacja struktury topologii relacji pomiędzy agentami przedstawia Marcal i North, 2010, rysunek 3, strona 155.

Agenci oprócz tego, że oddziałują ze sobą to oddziałują również na środowisko lub na siebie poprzez środowisko jak ma to miejsce w modelu prezentowanym w tej pracy. Środowisko może również dostarczać informacje o przestrzeni i położeniu agentów. Innymi słowy środowisko jest przestrzenią wiążącą agentów. Z praktyki wynika, że najbardziej efektywną metodologią budowania agentów jest podejście od dołu do szczytu (ang. bottom-up) (por. Macal i North, 2010).

Z punktu widzenia budowanego w tej pracy modelu najbardziej interesującym obszarem modelowania wieloagentowego jest wieloagentowe modelowanie ekonomii (ang. agent-based computational economics, ACE). Zdecentralizowany rynek ekonomiczny składa się z dużej liczby ekonomicznych agentów zaangażowanych w rozproszone lokalne interakcje. Te interakcje rozwijają się w makroekonomiczne regulacje takie jak protokoły handlowe, społecznie akceptowany system monetarny, szeroko akceptowana innowacja technologiczna, które z drugiej strony wpływają na określenie lokalnych interakcji (por. Tesfatsion, 2002). Zgodnie z Tesfatsion, (2002) w celu przeprowadzenia badań procesów powstawania zdecentralizowanych rynków ekonomicznych wykorzystuje się platformy obliczeniowe z zaimplementowanymi modelami ACE. Dwa obszary są szczególnie interesujące. Pierwszy to globalne zachowania i sposób ich opisu oraz wyjaśnienia powstawania konkretnych zjawisk, które pojawiają się pomimo podejścia od dołu do szczytu. Drugi obszar skupia się na samym mechanizmie prowadzącym do powstawania badanych zjawisk. Budując model ACE początkowy stan ekonomiczny określa się poprzez zdefiniowanie początkowych atrybutów agentów. Atrybuty mogą zawierać takie informacje jak normy zachowań, wewnętrzne typy zachowań, w skład których wchodzą rodzaje komunikacji z innymi agentami czy zdolność uczenia się oraz takie informacje jak wiedza o sobie samym oraz innych agentach. Badania w zakresie ACE można podzielić na osiem obszarów. Pierwszy to uczenie i wbudowany umysł czyli szeroka reprezentacja procesów uczenia wśród agentów. Proces uczenia jest realizowany z wykorzystaniem między innymi sieci neuronowych, algorytmów genetycznych, programowania genetycznego. Procesy te mają najczęściej za zadanie modelować ludzkie zachowanie agentów. Opisywany model w tej pracy zalicza się właśnie do tej kategorii. Drugi obszar dotyczy ewolucji norm zachowań. Zgodnie z Tesfatsion, 2002 został przetoczony cytat z Axelrod, (1997) definiujący zachowanie jako: „Norma istnieje w określonym społeczeństwie w takim rozumieniu, że jednostka zachowuje się najczęściej w określony sposób i jest karana wtedy, gdy nie zachowuje się w ten sposób”. Zjawisko normy zachowania jest formą ewolucyjną i wzrasta ona lub zanika z określonym stopniem. Trzeci obszar to modelowanie procesów rynków od dołu do szczytu. Zdolność określonych typów procesów rynkowych do samoorganizacji jest jednym z głównych kierunków badań ACE. Ta kategoria również odnosi się do modelu, który jest prezentowany w tej pracy. Czwarty obszar to formowanie się sieci ekonomicznych. Interakcje w sieci w kontekście rynkowym są często analizowane w rozumieniu kosztów transakcyjnych. To podejście opiera się o założenie powstania optymalnych i dobrze dopasowanych form organizacji, które odzwierciedlane przez agentów realizujących transakcje od ręki. Problem polega na określeniu tych optymalnych form

organizacji. Piąty obszar odnosi się modelowani samych organizacji. Rozwojowi w modelowaniu organizacji sprzyja programowanie obiektowe, które pozwala na zamodelowanie organizacji w jej formie jako grupy posiadającej cel lub grupy składającej się z jednostek posiadających cel. Szósty obszar skupia się na tworzeniu lub obliczeniach związanych ze zautomatyzowanymi agentami będącymi uczestnikami rynków. Siódmy obszar to równolegle prowadzenie eksperymentów z rzeczywistymi oraz komputerowymi agentami. Człowiek jest istotnym obiektem analiz w prowadzonych eksperymentach w zakresie ekonomii. Ostatni, ósmy obszar dotyczy samych narzędzi, które są wykorzystywane do modelowania ACE. Większość narzędzi wykorzystuje obiektowe języki programowania, które pozwalają na stworzenie modeli agentów oraz środowiska, które mogą stanowić pakiety bibliotek składających się z różnych rodzajów modelowanych obiektów. Jest to wygodna forma dla użytkownika do korzystania z takiej struktury. Dodatkowo istnieje możliwość budowania praktycznie dowolnych interfejsów graficznych co w znacznym stopniu ułatwia obsługę symulacji. Głównymi językami wykorzystywanymi do modelowania to C++, Java oraz Python.

3.2 Platforma symulacyjna MASON

Ta część opisu odnosi się do ogólnej budowy platformy MASON (por. Luke, 2014), która stanowi ramę całego zbudowanego w tej pracy systemu.

W modelowaniu wieloagentowym są trzy standardowe rozwiązania przy wyborze platformy zależne od tego jak dużo wsparcia dane środowisko programistyczne dostarcza projektant modelu. Pierwsze podejście opiera się na środowisku zorientowanym wokół utworzonych bibliotek, drugie podejście jest związane z wykorzystaniem zintegrowanego środowiska programistycznego (ang. integrated development environment, IDE) lub trzecie rozwiązanie hybrydowe wiążące dwa poprzednie. W podejściu zorientowanym wokół bibliotek narzędzie do modelowania agentów składa się z uporządkowanych bibliotek w formie interfejsu programistycznego (API). Projektant modelu musi wykonać serię zapytań do różnych funkcji danej platformy. Jest on również odpowiedzialny za zapewnienie poprawnej sekwencji zapytań oraz za to, żeby model zawierał wszystkie wymagane pliki. W zamian za to otrzymuje się największą elastyczność w tworzeniu modelu. Przykładami takiego rozwiązania są platformy Repast (North, i in. 2006), MASON (GMU, 2009) oraz Swarm (SDG, 2009). Rozwiązanie z wykorzystaniem IDE umożliwia edytowanie kodu, żeby móc zorganizować konstrukcję projektowanego modelu. W celu skompilowania kodu wykorzystywany jest wewnętrzny mechanizm. Przykładem takiego rozwiązania jest program NetLogo (Wilensky, 1999,

NetLogo, 2009). Jest to rozwiązanie, które pozwala w sposób szybki i stosunkowo prosty przyswoić wiedzę na jego temat jednak problem jaki się pojawia to możliwość skalowania modelu do dużych i bardziej skomplikowanych systemów. Rozwiązanie hybrydowe jest połączeniem dwóch wyżej opisanych rozwiązań. Przykładem jest program Repast Simphony (North, i in. 2007, ROAD, 2009) oraz AnyLogic (XJ Technologies, 2009) (por. Macal i North, 2010).

Na potrzeby tego modelu opisywanego w tej pracy została wybrana platforma MASON właśnie ze względu na elastyczność, możliwość wykorzystania obiektowego języka programowania JAVA, a przez to wybranie IDE Eclipse, które jest dobrze rozwiniętym narzędziem budowanym w konwencji Open Source.

Zgodnie z Luke, i in. (2005) MASON jest szybkim, elastycznym, narzędziem do budowania wieloagentowych dyskretnych symulacji zdarzeniowych z wykorzystaniem języka programowania Java. Został stworzony, jako narzędzie mające na celu w jak najlepszy sposób służyć projektantom symulacji wieloagentowych w szerokim zakresie od robotyki ławic (ang. swarm robotics), przez uczenie maszynowe do złożonych środowisk socjalnych. MASON wyznacza granicę pomiędzy modelem, a wizualizacją pozwalając na dołączanie modeli w sposób dynamiczny do wizualizatora oraz na wprowadzanie zmian między startami. Główne skupienie w pracy nad platformą było związane z modelami ławicowymi w celu umożliwienia prowadzenia symulacji z wykorzystaniem od jednego do milionów agentów. Jest to projekt tworzony w konwencji Open Source i jest on bezpłatny. Platforma jest wynikiem pracy zespołu z Centrum do Złożonej Socjologii z Uniwersytetu George Mason. Filozofia towarzysząca twórcom podczas budowania platformy była taka, żeby struktura bibliotek była ograniczona do minimum co pozwoliłoby doświadczonemu programiście Java w prosty sposób dodawać nowe cechy. Twórcy systemu chcieli uniknąć budowania wielu gotowych rozwiązań, które w skalowalnych systemach przy ich rozbudowie byłyby trudne do usunięcia lub modyfikacji. Do systemu bibliotek została dodana część pozwalająca na wizualizację wyników oraz część z graficznym interfejsem użytkownika. Takie rozwiązanie zapewniło elastyczność, dzięki której platforma mogła być wykorzystana w wielu różnych modelach. Na modelach mogły być efektywnie i równolegle prowadzone symulacje na klastrach obliczeniowych. Ze względu na wykorzystanie języka Java platforma może być uruchomiona na dowolnym systemie operacyjnym. Takie same wyniki można otrzymać niezależnie od platformy. Wizualizacja jest możliwa zarówno w dwu jak i trój wymiarze. Dodatkowo został wprowadzony mechanizm,

który pozwala na zatrzymanie symulacji w dowolnym momencie i wznowienie jej w celu kontynuowania symulacji na innej platformie uzyskując ten sam wynik. Możliwa liczba wprowadzonych agentów nie jest niczym ograniczona z wyjątkiem kwestii pamięci danego klastra. Warto również uwzględnić fakt, że kod jest napisany w sposób pozwalający efektywnie wykorzystać pamięć klastra obliczeniowego. Należy jednak zwrócić uwagę na ograniczenia tej platformy. Jest to rozwiązanie architektoniczne pozwalające na realizację jednoprocesowej symulacji. Oznacza to, że nie ma możliwości przeprowadzenia równoległych obliczeń pojedynczej symulacji w klastrze.

Platforma składa się z trzech warstw, a mianowicie z warstwy użytkowej, warstwy modelu oraz warstwy wizualizacji. Warstwa użytkowa składa się z klas, które mogą być wykorzystane do dowolnego celu. Zawiera ona generator liczb losowych, efektywniejszą strukturę danych niż ta, która została stworzona przez Java, graficzny interfejs użytkownika oraz infrastrukturę pozwalającą na robienie zdjęć i filmów. W warstwie modelu klasy składają się na harmonogram realizacji zdarzeń dyskretnych, harmonogram użytkowy, oraz zestaw pól, które trzymają obiekty i kojarzą te obiekty z ich położeniem. Kod w czystej postaci jest wystarczający, żeby pisać podstawowe symulacje z wykorzystaniem wiersza poleceń. Warstwa wizualizacji pozwala na realizację wizualizacji z wykorzystaniem interfejsu użytkownika oraz na ustawienie modelu.

Rysunek przedstawiający uproszczony diagram relacji w oparciu o obiekty w modelu oraz o warstwę wizualizacji znajduje się w Luke, i in. 2005, rysunek 1, strona 4 . Dla większości elementów warstwy modelu istnieje pewna przestrzeń w warstwie wizualizacji odpowiedzialna za możliwość wprowadzania ustawień w obiektach modelu w celu ich wyświetlania oraz weryfikacji ich zawartości. Widoczne jest jednoznaczne oddzielenie warstw, które pozwala w każdej chwili oddzielić je od siebie i traktować je jako samowystarczające jednostki, które można zatrzymać, przenieść do innego klastra i uruchomić od momentu zatrzymania kontynuując obliczenia.

Model MASON jest całkowicie zawarty w pojedynczej instancji zdefiniowanej przez użytkownika, dziedziczącej z klasy SimState. Ta instancja zawiera harmonogram zdarzeń dyskretnych Schedule, generator liczb losowych MersenneTwister oraz może posiadać pola.

MASON w specyficzny sposób określa agenta. W systemie agent reprezentuje obliczeniową jednostkę, która może być umieszczona w harmonogramie w celu realizacji jakiegoś zadania

oraz w celu wprowadzenia zmian w środowisku. Należy zauważyć, że agent nie jest wyłącznie umieszczony fizycznie w środowisku. MASON odnosi się do agenta jako agenta wcielonego (ang. embodied agent). Agenci są „mózgami”, które mogą, ale nie muszą być wcielone. W MASON nie układamy harmonogramu zadań, które później miałyby być wysłane do agenta, a układamy harmonogram z samymi agentami, którzy wchodzą (ang. stepped) w odpowiednim momencie czasu w przyszłość lub inaczej są wołani w odpowiednim momencie czasu co wynika z tego, że agenci implementują interfejs Steppable. Wielokrotne ułożenie w harmonogramie agenta w celu wykonania przez niego różnych zadań jest możliwe przy wykorzystaniu anonimowej klasy wrapper. W celu zaistnienia jakiegoś obiektu w określonym momencie w czasie musi on być typu Steppable oraz musi być ułożony w odpowiedni sposób w harmonogramie. Dodatkowo harmonogram Schedule może być podzielony na wiele określonych porządków (ang. ordering), które dalej dzielą dany krok czasowy (ang. timestep). Taki podział pozwala ułożyć agentów w danym kroku czasowym. Agent z ustawnionym porządkiem na wcześniejszy będzie w danym kroku czasowym przywoływany przed agentem z ustawnionym późniejszym porządkiem. W MASON dostępnych jest wiele opakowujących klas (ang. wrapper) typu Steppable, które pozwalają na grupowanie agentów, iterowanie po tych agentach, wywoływanie ich równolegle na osobnych wątkach (ang. thread). Dodatkowo agenci mogą być wywoływania asynchronicznie (por. Luke, i in. 2005).

Pola w MASON są powiązane zarówno z obiektami lub z wartościami ze współrzędnymi przestrzeni. Dany obiekt może występować w wielu polach w jednym czasie. W jednym polu jeden obiekt może występować wiele razy. Używanie pól nie jest konieczne.

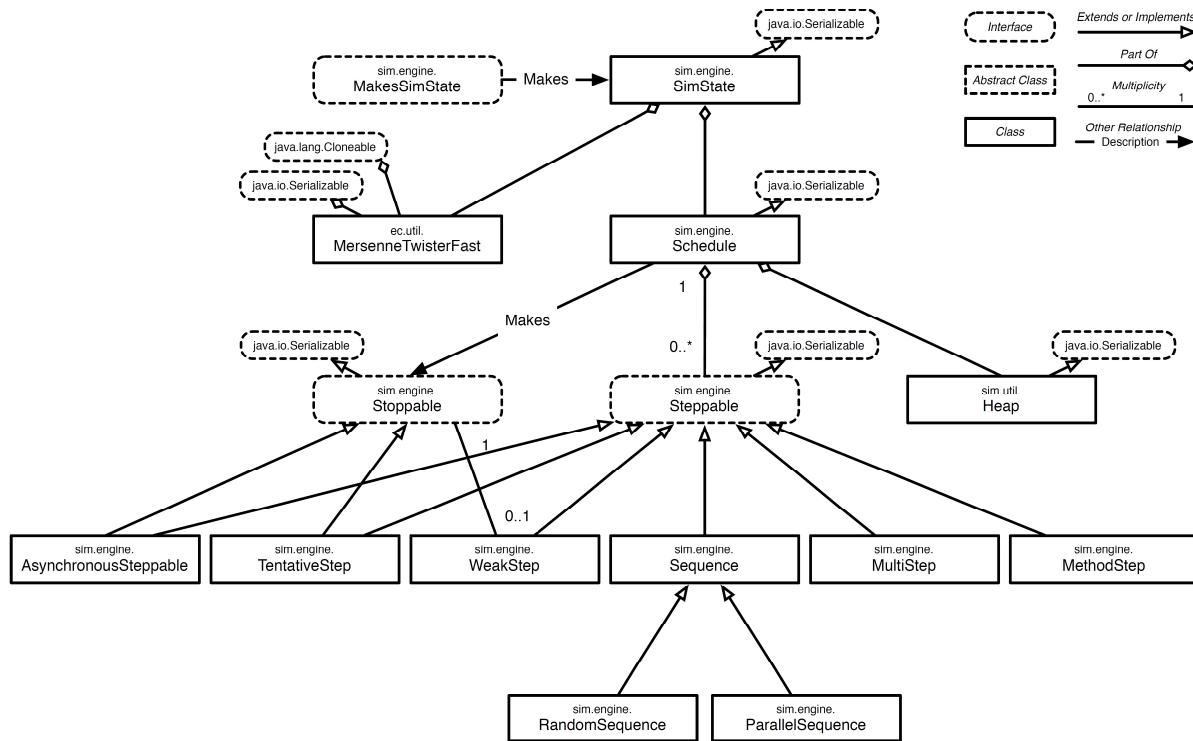
Przy prowadzeniu symulacji bez wykorzystania warstwy wizualizacji MASON posiada nadzorską pętlę. Symulacja rozpoczyna się od utworzenia nowego SimState lub wczytaniu istniejącego zewnętrznego pliku. Następnie rozpoczyna się przejście przez pętlę, gdzie najpierw sprawdzane jest czy są jacyś agenci do zwołania w Schedule. Jeżeli nie lub maksymalna liczba kroków czasowych została wykonana następuje wyjście z pętli. Jeżeli są agencie do zwołania to MASON ustawa czas na minimum harmonogramu agenta, a następnie wywołuje wszystkich agentów ustawionych na ten czas według określonego porządku. Agenci z danej grupy porządkowej są wywoływani losowo. Agenci mają pełny dostęp do SimState, możliwości manipulowania polami, do Schedule oraz do generatora liczb losowych.

3.3 Informatyczny model ZIT z mechanizmem podwójnej ciągłej aukcji

W tej części zostanie opisany model wykorzystywany w opisywanym w tej pracy projekcie.

Na potrzeby prezentowanego modelu zostały wykorzystane jedynie dwie warstwy modelu MASON czyli warstwa użytkowa i warstwa modelu. Warstwa wizualizacji nie była tutaj potrzebna ponieważ dane zapisane do pliku txt przechowujące wyniki symulacji są w kolejnym etapie analizy wczytywane do programu R. Niewykorzystanie warstwy wizualizacji wynikało głównie z faktu zbędnego na rzecz tej symulacji śledzenia w czasie rzeczywistym generowanych wykresów. Dodatkowo należy zauważyć, że generowanie wykresów w trakcie trwania symulacji negatywnie wpływa na czas realizacji obliczeń opóźniając ich realizację. Kolejna przyczyna nie wykorzystania warstwy wizualizacji wynika z faktu, że model ten jest typu „zupa” stąd nie mamy tutaj do czynienia z agentami rozlokowanymi w przestrzeni, a jedynie znajdującymi się w „zbiorniku”, z którego są wybierani w określonej sekwencji.

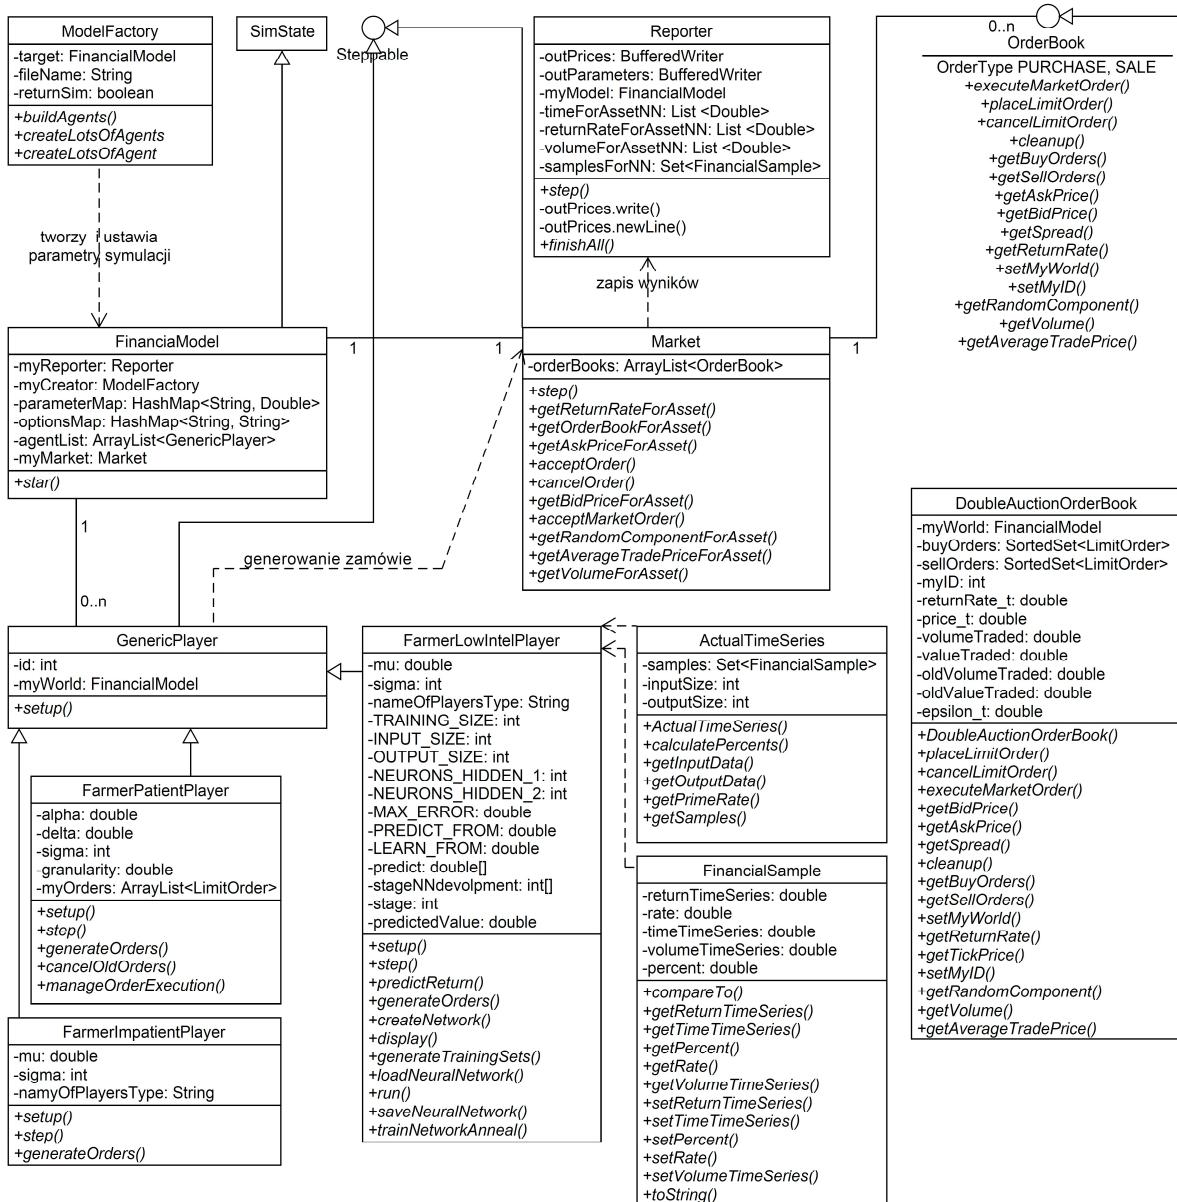
Tak jak to zostało opisane w rozdziale 3.2 model do swojej konstrukcji wykorzystuje strukturę platformy MASON czyli pakiety sim.engine.SimState (globalny obiekt odpowiedzialny za utrzymanie symulacji opisywanego modelu), sim.engine.Schedule (harmonogram dyskretnych zdarzeń odpowiedzialny za określenie czasu w symulacji), sim.engine.Stepable (interfejs, który jest implementowany przez agentów czyli obiekty ustawiane w harmonogramie). Reprezentację struktury przedstawia rysunek schematu UML na rysunku nr 3.



Rysunek nr 3. Diagram UML rdzenia symulacji i harmonogram dyskretnych zdarzeń platformy MASON.

Źródło: Luke, i in. (2014), strona 86, rysunek 4.1.

Statyczna platforma, której strukturę przedstawia schemat UML umieszczony na rysunku, jest modyfikacją modelu zaprezentowanego przez Briggs, i in. (2008?). Model składa się z rynku FinancialMarket bazującego na zasadach podwójne ciągły aukcji DoubleAuctionOrderBook. Gracze biorący udział w rynku FarmerPatientPlayer oraz FarmerLowIntelPlayer oddziałuje poprzez rynek finansowy. Ceny znajdują się w księdze zamówień OrderBook.



Rysunek nr 4. Diagram UML głównych komponentów i relacji w modelu rynków finansowych opisywanego w tej pracy. Klasy SimState oraz interfejs Steppable to elementy nadzędne platformy MASON. Klasa FinancialModel dziedziczy z klasy SimState, a klasa GenericPlayer z interfejsu Steppable.

Źródło: Opracowanie własne z wykorzystaniem programu Umlet Diagram.

W opisywanym projekcie klasą dziedziczącą z **SimState** jest klasa **FinancialModel**. To w tej klasie mamy główną pętlę platformy MASON czyli **doLoop()**. Z tej klasy wywołujemy wczytywanie parametrów modelu poprzez klasę **ModelFactory** oraz zapisywanie wyników symulacji do plik poprzez klasę **Reporter**.

Chcąc ustawić model należy wczytać plik z określonymi wartościami parametrów. Poniższa tabela nr 3 przedstawia parametry, ich wartości oraz ich znaczenie.

Tabela nr 3. Wartości parametrów wieloagentowego modelu podwójnej ciągłej aukcji.

Oznaczenie	Wartość	Opis
maxT	600	Maksymalna liczba kroków czasowych w modelu
numAssets	1	liczba jednostek akcji jakie oferują gracze
agentConfiguration	farmerNN.txt	Nazwa pliku tekstowego, z którego program wczytuje konfigurację agentów. W opisywanym modelu będzie to FarmerLowIntelPlayer=100 oraz FarmerPatientPlayer=100
orderBookClass	DoubleAuctionOrderBook	Nazwa klasy reprezentującej daną księgę zamówień co wiąże się z mechanizmem funkcjonowania rynku finansowego
orderBookOptions	logPricing	Jakiego rodzaju ceny znajdują się w księdze zamówień czy będą to logarytm wartości ceny czy po prostu wartość ceny rynkowej. W przypadku opisywanego modelu symulację realizujemy z wykorzystaniem logarytmu wartości ceny
Farmer_alpha	0.585	Wskaźnik napływu zamówień ograniczonych α [(liczba akcji)/(jednostka ceny*jednostka czasu)]
Farmer_delta	0.39	Wskaźnik usuwania zamówień δ [(1)/(jednostka czasu)]
Farmer_mu	325	Wskaźnik napływu zamówień rynkowych μ [(liczba akcji)/(jednostka czasu)]
Farmer_sigma	1	liczba realizowanych zamówień rynkowych σ [liczba akcji]
Farmer_logPricing	true	Jeżeli Prawda to orderBookOption jest ustawiany na "logPricing"
Farmer_granularity	0.0	Parametr granularności zamówień przechowywanych w księdze zamówień dla cen ograniczonych (wyłącznie dla cen, które nie są logarytmem ceny) 0.0 == Wartość ciągła, 100.0 == handel małymi wartościami np. grosze

Źródło: Opracowane na podstawie Briggs, i in. (2008?).

Wartości zmiennych są wczytywane z pliku, a odpowiedzialna za to jest klasa ModelFactory. Fragment kodu przedstawiający ustawienie wartości maksymalnej ilości kroków czasowych znajduje się w załączniku 8.2. W tej klasie znajduje się również metoda, poprzez którą powołujemy agentów i ustawiamy ich harmonogram. Dane konfiguracji znajdują się w niezależnych plikach, z których wczytujemy wartości zmiennych co widać w kodzie w załączniku 8.3. Wyniki zapisywane są do zewnętrznego pliku timeSeries.txt co zostało przedstawione w kodzie w załączniku 8.4.

Efekt losowości w podejmowaniu decyzji bazujący na rozkładzie Poissona stanowiącym podstawę modelu ZIT jest zrealizowany przez kod umieszczony w każdej klasie określającej danego agenta. Przykład kodu zaimplementowanego w klasie agenta FarmerPatientPlayer znajduje się w załączniku 8.5. Metoda generateOrders() zawiera kod wykorzystujący rozkład Poissona do generowania zamówień. Również usuwanie zamówień jak to zostało wcześniej opisane posiada rozkład Poissona co jest widoczne w kodzie w metodzie cancelOldOrders()

W danym kroku czasowym o kolejności wywołania decyduje nadany porządek i to jak uczestniczy rynku określeni w klasach FarmerPatientPlayer i FarmerLowIntPlayer mają nadaną wartość porządkową 1. Oznacza to, że zostaną wywołani jako pierwsi.

- target.schedule.scheduleRepeating(0.0, 1, this, 1.0);

Następnie decyzje poszczególnych graczy trafiają na wywołany w drugiej kolejności rynek w klasie ModelFacktory oznaczony jako myMarket, który ma nadaną wartość porządkową 2

- target.schedule.scheduleRepeating(target.myMarket, 2, 1.0)

Na końcu wszystkie informacje zostaje odnotowane w raporcie, który jest utworzony w klasie FinancialModel i oznaczony jako myReport ma nadaną wartość porządkową 10.

- schedule.scheduleRepeating(myReporter, 10, 1)

4 Symulacje wieloagentowe podwójnej ciągłej aukcji

W podsumowaniu, które stanowi czwarty rozdział tej pracy zostały przedstawione wyniki, analiza oraz schematy analiz. Znajduje się tutaj opis dokonanych modyfikacji, które pozwoliły uzyskać przedstawione wyniki. Zakończenie tego rozdziału stanowią wskazania do dalszych badań.

4.1 Hipoteza badawcza

Hipoteza jaka została postawiona w tej pracy zakłada, że wprowadzenie agenta typu „low-intelligence” nie wpłynie na zachowanie rynku w sposób poprawiający jego efektywność według Fama (1970). Oznacza to, że wprowadzenie zmodyfikowanego agenta nie zmieni mechanizmu formowania się cen wprowadzając pozytywną autokorelację, co w konsekwencji miałoby doprowadzić do nieskorelowanej zmiany cen przy założeniu, że ceny mają charakter błędzenia losowego.

Przyrost cen nie posiada niezależnych o identycznym rozkładzie statystycznym procesów pomimo, że same procesy składania ofert są realizowane niezależnie o identycznych rozkładach Poissona. Wynika to ze względu na warunki brzegowe dla procesu składania ofert kupna i sprzedaży pomiędzy agentami działającymi według mechanizmu zamówień rynkowych (ang. market order) i zamówień ograniczonych (ang. limit order).

Ze względu na fakt, iż wzrasta popyt i podaż (np. wzrost głębokości składanych ofert ograniczonych (ang. limit orders)), gdy jedno odsuwa się od środka księgi zamówień (ang. order book), zwroty kierunku zmiany wartości cen są częstsze niż zmiany wartości cen w tym samym kierunku.

W modelu Farmera, i in. (2003) generowany przyrost cen jest bardziej nieskorelowany niż ten występujący w rzeczywistości. Taki wynik posiada bardzo ciekawe następstwo. Przy założeniu, że mamy doczynienia z rynkiem efektywnym (brak autokorelacji) oraz przyrost cen ma charakter błędzenia losowego co wynika z tego, że prawdziwy proces składania ofert powinien posiadać pozytywną autokorelację w celu wyrównania silnej antykorelacji wygenerowanej przez model podwójnej ciągłej aukcji

Autorzy Farmer, i in. (2003) wskazują na możliwość rozwinięcia ich modelu poprzez wprowadzenie bardziej wyrafinowanego mechanizmu procesu przepływu transakcji w tym bardziej realistycznych zależności składania i usuwania zamówień tworząc tym samy model bardziej realistycznym. W modelu przedstawionym w tej pracy poprzez modyfikacje samego

agenta przez nadanie mu charakteru „low-intelligence” wpływam na zmianę przepływu realizacji zamówień nie wpływając jednocześnie na sam model generowania tych zamówień, który nadal posiada charakter losowy.

Wiemy, że przyrosty cen wygenerowane przez ten model są bardziej antyskorelowane aniżeli te realne ceny w serii. Jeżeli uwzględnimy efektywność rynku i założymy, że przyrost rzeczywistych cen musi mieć charakter błądzenia losowego to realny przepływ zamówień powinien mieć pozytywną autokorelację w celu skompensowania antykorelacji, która jest wynikiem ciągłej podwójnej aukcji (por. Farmer, i in. 2003). Inaczej mówiąc, jeżeli wprowadzenie agenta „low intelligence” wpłynie na funkcję przyrostu cen w sposób, który nada mu charakter błądzenia losowego to nie wyklucza to możliwości, że wpłynęło to na zmianę mechanizmu składania zamówień (przepływ powinien mieć pozytywną autokorelację) co skompensuje antykorelację, która jest wynikiem mechanizmu podwójnej aukcji.

4.2 Założenia

Zgodnie z zaleceniami Farmera, i in. (2003) do modelu została wprowadzona modyfikacja polegając na implementacji agenta typu Low-Intelligence. Pierwotnie w modelu Farmera, i in. (2003) byli agencje typu cierpliwego oraz agencje typu niecierpliwego.

W zamian za agenta typu ZIT został wprowadzony agent typu low-intelligence. Głównym założeniem było zachowanie losowego charakteru o rozkładzie Poissona składania ofert oraz losowego charakteru złożenia oferty kupna lub sprzedaży równo z prawdopodobieństwem 0,5 co przedstawia kod w załączniku 8.8.

Agent został rozszerzony o sztuczną inteligencję, która jest reprezentowana przez sztuczne sieci neuronowe. Stąd zdefiniowane parametry sieci oraz metoda predictReturn(). Metoda generateOrders() została wzbogacona o dodatkowy warunek, który ma na celu pozwolić graczowi decydować się tylko na taki ruch, który na podstawie jego przewidywań pozwoli mu czerpać korzyść z wzięcia udziału w aukcji. Oznacza to, że gdy agent składa ofertę sprzedaży to może do niej przystąpić tylko wtedy, gdy przewiduje, że stopa zwrotu w następnym kroku będzie ujemna. Gdyby nie sprzedał to straciłby w kolejnym ruchu. Gdy agent składa ofertę kupna to może do niej przystąpić tylko wtedy, gdy przewiduje, że stopa procentowa w kolejnym kroku będzie większa od zera. Nie jest istotny poziom zysku, a jedynie fakt, żeby agent nie stracił. W celu realizacji symulacji z zaimplementowanym algorytmem sztucznych sieci neuronowych został utworzony nowy pakiet model.agents.farmerliextraclass z dwiema klasami

ActualTimeSeries oraz FinancialSample, które odpowiednio pozwalają na organizację obecnie przetwarzanych danych oraz na organizację całej próbki danych.

Generowanie zbioru treningowego odbywa się za pomocą danych wejściowych generowanych przez symulację (dziesięć kolejnych wartości stóp procentów oraz dziesięć kolejnych wartości wolumenu), które zmieniają się co krok symulacji. W tym celu wykorzystany jest model sieci jednokierunkowej (ang. Feed Froward) z losowo generowanymi wartościami wag.

Po wygenerowaniu zbioru treningowego sieć przechodzi do fazy trenowania, w której przy wykorzystaniu algorytmu propagacji wstecznej (ang. Back Propagation) obliczane są optymalne wartości wag.

Dane wejściowe oraz dane wyjściowe są tablicami o wartościach zmiennoprzecinkowych. Ich liczba nie ulega zmianie. Budowę sieci neuronowej można koncepcyjnie porównać do struktury tablic z haszowaniem czyli klucz i powiązana z nim informacja jak w słowniku. Dane wejściowe stanowią klucz, a dane wyjściowe wartość. Logiczną reprezentację sieci neuronowych stanowi operator XOR, który funkcjonuje podobnie do połączenia AND oraz OR. Dla operatora AND [0,0 False; 0,1 False; 1,0 False; 1,1 True] dwie strony równocześnie muszą być prawdziwe, a przy operatorze OR [0,0 False; 0,1 True; 1,0 True; 1,1 True] wystarcza, że jedna ze stron jest prawdziwa, żeby całe wyrażenie było prawdziwe. Dla operatora XOR [0,0 False; 0,1 True; 1,0 True; 1,1 False] dwie strony muszą być od siebie różne, żeby wyrażenie było prawdziwe.

Budowa sieci na platformie Encog jest zrealizowana w następujący sposób. W pierwszej kolejności jest tworzona architektura sieci poprzez zdefiniowanie jej wymiarów:

W projekcie przyjęto wartości parametrów uczenia równe 0.00001 i momentu równe 0.1.

W modelu został wprowadzony dodatkowo jeszcze jeden algorytm, którego celem jest przyspieszenie procesu znalezienia optymalnych wartości wag. Proces ten nosi nazwę symulowanego wyżarzania (ang. simulated annealing). Nazwa została zaczerpnięta z procesu obróbki cieplnej materiałów. Celem tego procesu jest przybliżenie materiału, a w naszym przypadku wyników symulacji do warunków równowagi (usunięcie wewnętrznych naprężeń, polepszenie obrabialności, uzyskanie jednorodnej struktury materiału). W celu zaimplementowania symulowanego wyżarzania sieć neuronowa musi być przekształcona w tablicę liczb typu double. W celu zasymulowania procesu wyżarzania i powolnego chłodzenia materiału został zaimplementowany proces losowości. W czasie, gdy sieć neuronowa ma już „wysoką temperaturę” wartości wag nabierają wysoką prędkość zmian. W czasie „schładzania” proces losowości zaczyna zmniejszać swoją prędkość. Przechowywane są jedynie te wyniki,

które pozytywnie wpływają na zachowanie się sieci neuronowej (por. Heaton, 2011). W modelu algorytm ten został wprowadzony w kodzie przedstawiony w załączniku 8.10.

Jeżeli wartość błędu po 100 iteracjach nadal jest powyżej wartości 0.05 i błąd obecny jest większy od poprzedniego lub bezwzględna wartość różnicy błędów obecnego i poprzedniego jest mniejsza od 0.001 to rozpoczęamy proces symulowanego wyżarzania. Dzięki temu uzyskujemy optymalny poziom błędu zmniejszając jednocześnie liczbę iteracji co znaczaco przyspiesza czas symulacji co przedstawia kod w załączniku 8.11

Obiekt NeuralSimulatedAnnealing jest wykorzystany do trenowania sieci. Wartości 10 i 2 oznaczają punkty startu i końca temperatur. Wyższa wartość produkuje więcej losowości, a mniejsza mniej. Wartość 100 określa liczbę cykli na iterację, jakie powinny zostać zrealizowane, żeby przejść z wysokiej do niskiej temperatury. Im więcej cykli tym bardziej dokładne wyniki można uzyskać. Jednak im więcej cykli tym dłuższy jest czas symulacji. Nie ma jednoznacznej reguły doboru tych parametrów.

W celu weryfikacji hipotezy zostały przeprowadzone symulacje na trzech modelach. Pierwsza jest oparta na modelu Farmer, i in. (2003), druga to model zmodyfikowany, w którym agent niecierpliwy został zastąpiony agentem typu low-intelligence. Trzecia symulacja to połączenie dwóch poprzednich czyli mamy wszystkich trzech agentów (cierpliwy, który występuje zawsze, niecierpliwy oraz low-intelligence) w jednym środowisku.

4.3 Wyniki

W pracy zostało wykonanych 50 symulacji dla każdego z trzech modeli:

- FM - Model odwzorowujący ten przedstawiony przez Farmera, i in. (2003) z agentami typu cierpliwego i agentami typu niecierpliwego. Ten model zwany jest dalej modelem FM. Znaczna część kodu została zaczerpnięta od Briggs, i in. (2008?) i jest do wglądu zarówno w załączniku tej pracy jak również pełny kod źródłowy modelu symulacyjnego jest dostępny pod adresem <https://github.com/m-zbik/FinancialMarketModel>
- FMNN - Model, który jest modyfikacją tego przedstawionego przez Farmera, i in. (2003) polegającą na zamianie agenta typu niecierpliwego na agenta typu low-intelligence. Ten model zwany jest dalej FMNN i jest on głównym obiektem zainteresowania. Wykorzystany kod to zarówno Briggs, i in. (2008?) jak również Heaton, (2011) oraz kod własny. Kod jest do wglądu częściowo w załączniku, a pełny kod źródłowy modelu symulacyjnego jest dostępny pod adresem <https://github.com/m-zbik/FinancialMarketModel>.

- FMPlusNN - Model, który jest modyfikacją tego przedstawionego przez Farmera, i in. (2003) polegającą na dodaniu do agentów typu cierpliwego i niecierpliwego agentów typu low-intelligence. Ten model zwany jest dalej FMPlusNN. Wykorzystany kod podobnie jak to zostało opisane wyżej to zarówno Briggs, i in. (2008?) jak również Heaton, (2011) oraz kod własny- pełny kod źródłowy modelu symulacyjnego jest dostępny pod adresem <https://github.com/m-zbik/FinancialMarketModel>.

Każda symulacja składa się z 600 kroków czasów. W pracy rozważanych jest 500 kroków czasów. W dalszej analizie uwzględnione są wyniki począwszy od 101 okresu danej symulacji, gdyż pierwsze 100 wyników symulacji stanowi zbiór treningowy dla agentów typu low-intelligence. Następnie zbiory są sprawdzane pod kątem zawartości luk w zbiorze danych czyli NA (ang. Not Available). Z takie podejścia otrzymujemy macierz o wymiarach 50x500. Docelowo macierz jest przekształcana w wektor posiadający 500 liczb, których każda kolejna od 1 do 500 stanowi wartość średnią wszystkich 50-ciu symulacji w danym kroku czasowym. W ten sposób otrzymujemy 3 wektory odpowiednio dla każdego z rozpatrywanych modeli. Ustawienia modelu FM oraz parametrów symulacji, a przez to wyniki poniżej, odpowiadają tym zaproponowanym przez Briggs, i in. (2008?). Należy jednak zwrócić uwagę, że w opisywanej symulacji przyjęliśmy po 100 agentów danego typu występujących w omawianym modelu, a liczba kroków równa jest 600 przy czym pierwszych 100 kroków jest przeznaczona jako zbiór treningowy dla modli rozbudowanych o agentów typu low-intelligence.

Dane, które podlegają analizie to stopy zwrotu (r) i wolumen (v) dla każdego z badanych modeli oznaczone odpowiednio rFM, rFMNN, rFMPlusNN oraz vFM, vFMNN, vFMPlusNN.

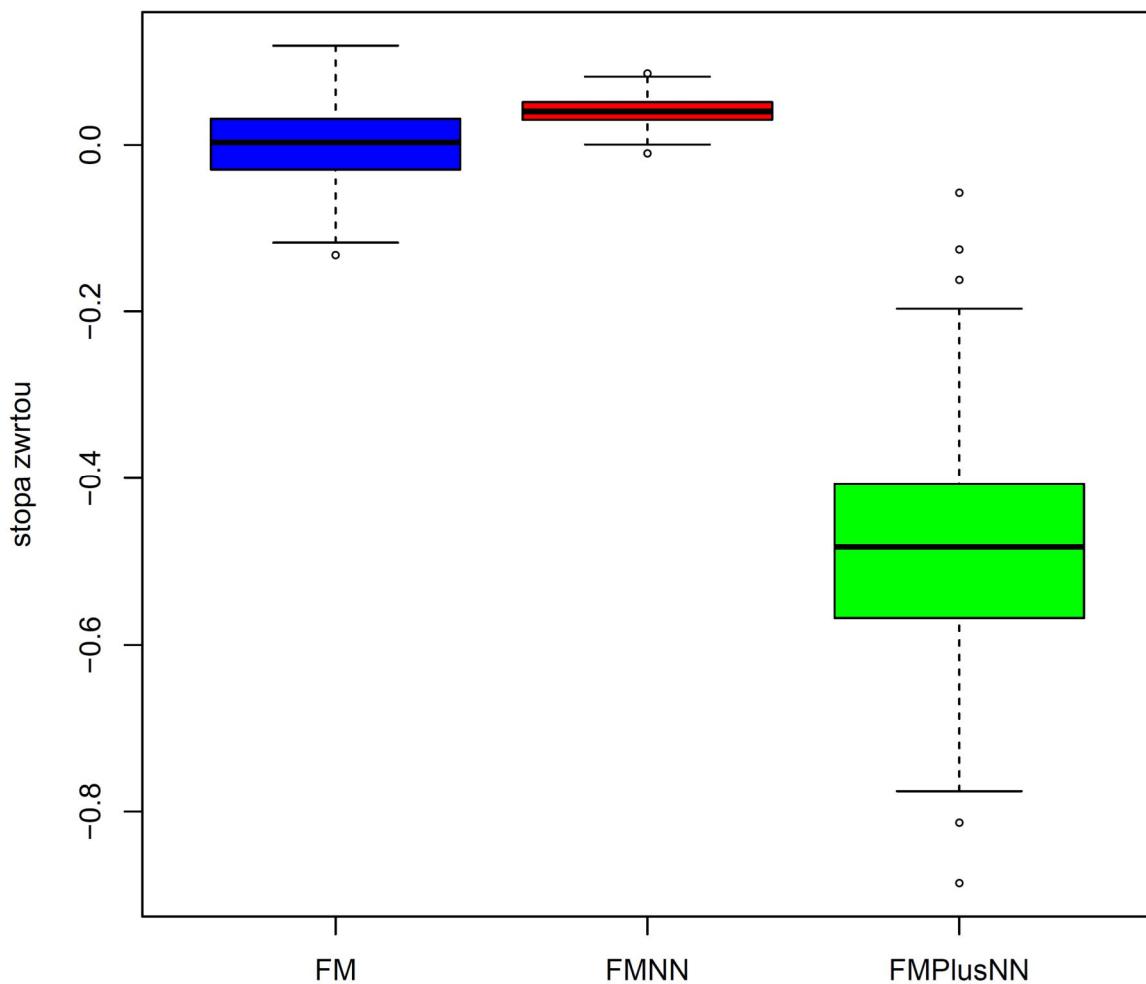
Podsumowanie wartości opisanych powyżej danych podlegających analizie przedstawia tabela nr 4, a zwizualizowane wartości stóp zwrot, które są głównym obiektem naszego zainteresowania zostały porównane dla trzech modeli na wykresie nr 1.

Tabela nr 4. Podsumowanie wyników stóp zwrotu (r) oraz wolumenu trzech modli FM, FMNN, FMPlusNN. Informacje zawarte w tabeli to wartości średnie oraz odchylenia standardowe wyników średnich wartości z przeprowadzonych 50 symulacji.

	rFM	rFMNN	rFMPlusNN
wartość średnia	0.0006	0.0406	- 0.487
odchylenie standardowe	0.0445	0.0153	0.118
	vFM	vFMNN	vFMPlusNN
wartość średnia	32.4761	16.2484	44.7618
odchylenie standardowe	0.8039	0.5855	0.9517

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Wartości stóp zwrotu trzech modeli: FM, FMNN, FMPlusNN



Wykres nr 1. Wykres typu box plot przedstawiający porównanie średnich wartości stóp zwrotu z 50 symulacji trzech modli FM, FMNN, FMPlusNN.

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Sprawdzamy również korelację pomiędzy wartościami stóp zwrotu oraz volumenu dla danej symulacji określonego modelu.

Tabela nr 5. Wartości korelacji stóp zwrotu i volumenu dla trzech modli FM, FMNN i FMPlusNN.

	FM	FMNN	FMPlusNN
KorelacjaStopyZwrotuOrazVolumnu	0.0016	0.1391	-0.0128

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Największą wartość bezwzględną korelacji stopy zwrotu i volumenu posiada modelu FMNN.

Kolejnym krokiem jest zgodnie z Ruppert, (2011) określenie niepewności wartości średnich oraz odchyleń standardowych analizowanych danych poprzez oszacowanie błędu standardowego oraz przedziału ufności. W tym celu wykorzystamy komputerową symulacyjną technikę Bootstrap. Technika ta została przedstawiona w 1979 roku przez Bradleya Efrona. Jest to metoda pozwalająca na oszacowanie rozkładu błędów estymacji. Polega ona na wielokrotnym losowaniu ze zwracaniem z próby. Zgodnie z Zivot, (2015) główne zalety tej metody to mniejsza liczba założeń dzięki temu, że dane nie muszą posiadać rozkładu normalnego. Kolejna kwestią to dokładność tej metody, do której określenia nie jest wymagana bardzo duża ilość danych w przeciwieństwie np. do Centralnego twierdzenia granicznego (ang. Central limit theorem).

Wartości średnie (śr.), błędy standardowe wartości średnich (bł.st.śr.), bias wartości średniej inaczej odchylenie systematyczne czyli wartość różnicy pomiędzy wartością średnią z wartości obliczonych metodą Bootstrap a wartością średnią z wartości symulacji dla danego modelu, odchylenia standardowe wraz błędami standardowymi tych wartości oraz bias wartości odchyleń standardowych przedstawia tabela nr 6.

Tabela nr 6. Wartości średnie (śr.) oraz odchylenia standardowe (odch.st.) analizowanych danych (stopy zwrotu - r, wolumen - v) obliczone z wykorzystaniem techniki Bootstrap dla trzech modeli (FM, FMNN, FMPlusNN). Do każdej wartości danej wielkości zostały obliczone błędy standardowe oraz bias inaczej odchylenie systematyczne czyli wartość różnicy pomiędzy wartością średnią z wartości obliczonych metodą Bootstrap a wartością średnią z wartości symulacji dla danego modelu.

	śr.	bł.st.śr.	bias	odch.st.	bł.st.odch.	bias
rFM	0.0007	0.0020	0.0001	0.0445	0.0014	0.0000
rFMNN	0.0406	0.0007	0.0000	0.0153	0.0005	0.0000
rFMPlusNN	-0.4869	0.0054	0.0001	0.1179	0.0041	-0.0001
vFM	32.4762	0.0350	0.0001	0.8038	0.0233	0.0000
vFMNN	16.2480	0.0264	-0.0004	0.5843	0.0180	-0.0011
vFMPlusNN	44.7600	0.0418	-0.0018	0.9475	0.0298	-0.0042

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Obliczenia wartości średnich i odchyleń standardowych wraz z ich przedziałami niepewności dla stóp zwrotu, wolumenu i błędów predykcyjnych dla modeli FM, FMNN, FMPlusNN przedstawia tabela nr 7.

Tabela nr 7. Średnie wartości i przedziały niepewności analizowanych danych (stopy zwrotu - r, wolumen - v) obliczone z wykorzystaniem techniki Bootstrap dla trzech modeli (FM, FMNN, FMPlusNN). W tabeli odpowiednie oznaczania przedstawiają: w.Stat – wartość wielkości statystycznej; n.0.95dół i n.0.95góra – dla przedziału ufności 95% przy założeniu, że dane wartości posiadają rozkład

normalny prezentuje dolną i górną wartość przedziału; kwant0.025 i kwant.0.975 wartości kwantyli rzędu 0.025 i 0.975; śr – wartość średnia; odch.st – odchylenie standardowe.

	w.Stat	n.0.95dół	n.0.95góra	kwant.0.025	kwant.0.975
śr.rFM	0.0007	-0.0035	0.0045	-0.0030	0.0048
odch.st.rFM	0.0014	0.0417	0.0472	0.0417	0.0473
śr.rFMNN	0.0406	0.0393	0.0419	0.0393	0.0419
odch.st.rFMNN	0.0005	0.0143	0.0163	0.0143	0.0162
śr.rFMPplusNN	-0.4869	-0.4977	-0.4766	-0.4979	-0.4763
odch.st.rFMPplusNN	0.0041	0.1101	0.1260	0.1100	0.1262
śr.vFM	32.4762	32.4074	32.5447	32.4047	32.5415
odch.st.vFM	0.0233	0.7583	0.8496	0.7568	0.8510
śr.vFMNN	16.2480	16.1971	16.3006	16.1968	16.3019
odch.st.vFMNN	0.0180	0.5513	0.6219	0.5486	0.6210
śr.vFMPplusNN	44.7600	44.6816	44.8455	44.6751	44.8366
odch.st.vFMPplusNN	0.0298	0.8976	1.0143	0.8882	1.0050

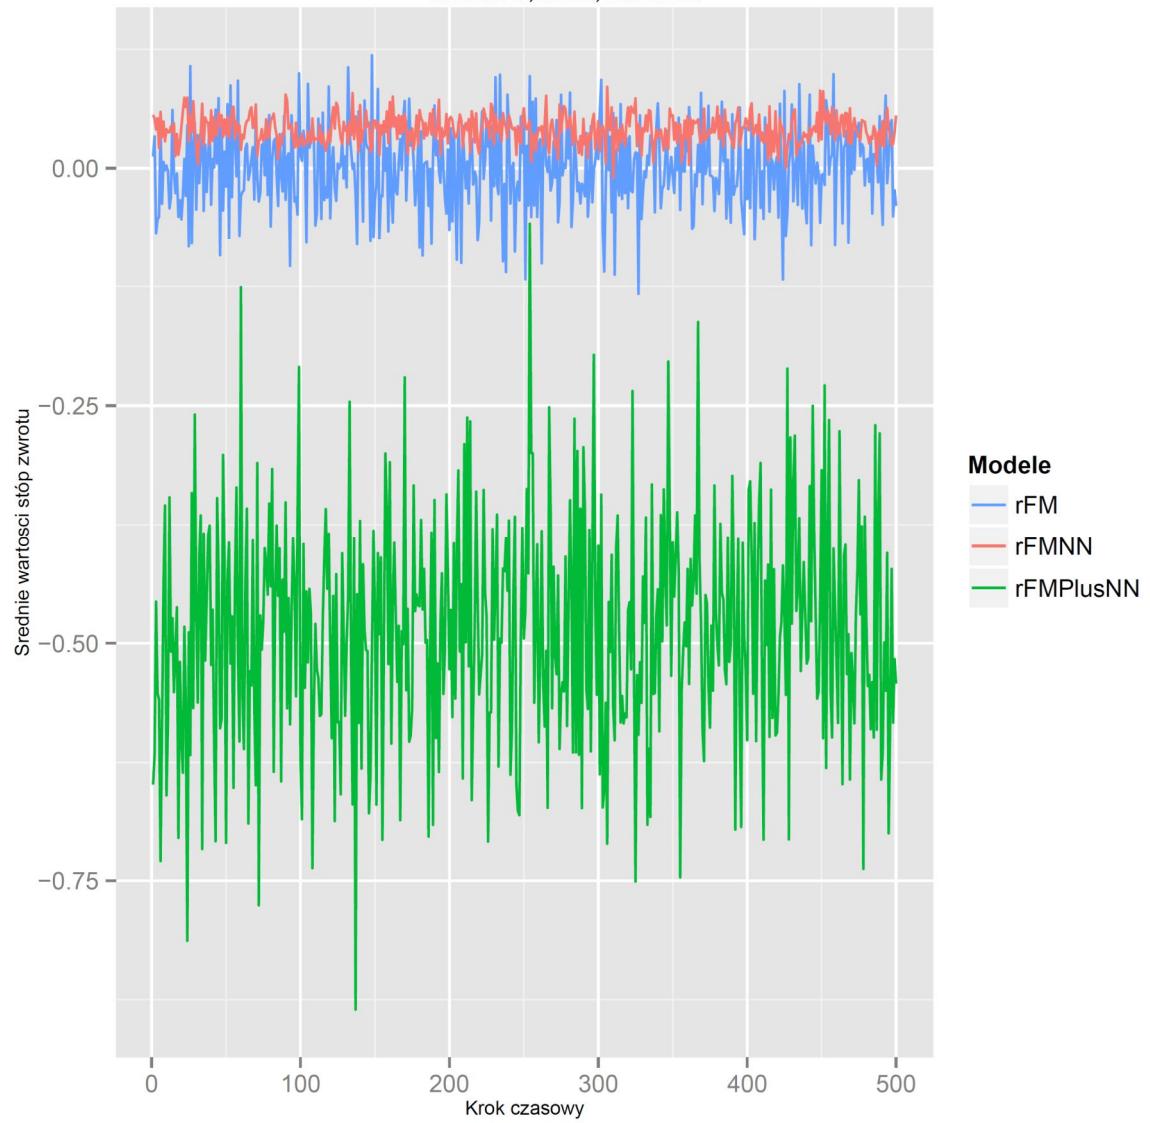
Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Poniższy wykresy nr 2a przedstawia w jaki sposób zmieniały się średnie wartości stóp zwrotu w zależności od kroków czasowych dla trzech modeli z 50 symulacji. Wykres nr 2 b przedstawia rozkład tych wartości przedstawiony na histogramach. Natomiast wykres nr 2 c jest wizualizacją 5%-towego przedziału ufności dla każdego kroku symulacji. Przedziały te zostały obliczone z wykorzystaniem metody Bootstrap. Na wykresie zaznaczone są górne i dolne wartości przedziału ufności każdego kroku czasowego dla odpowiednich modeli.

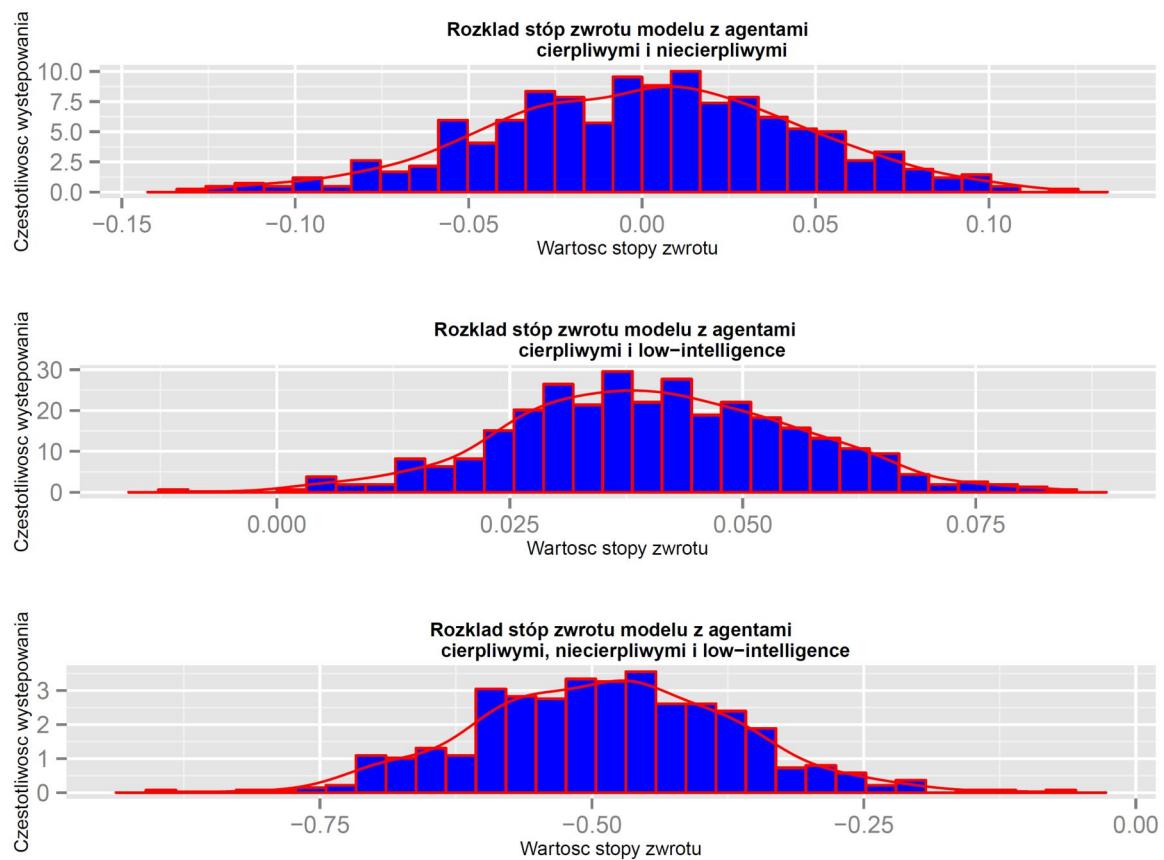
Wykres nr 3 przedstawia średnie wartości wolumenu dla 3 modeli i 50 symulacji. Został zaprezentowany w celu przedstawienia braku występowaniem zjawiska grupowania wolumenu.

a)

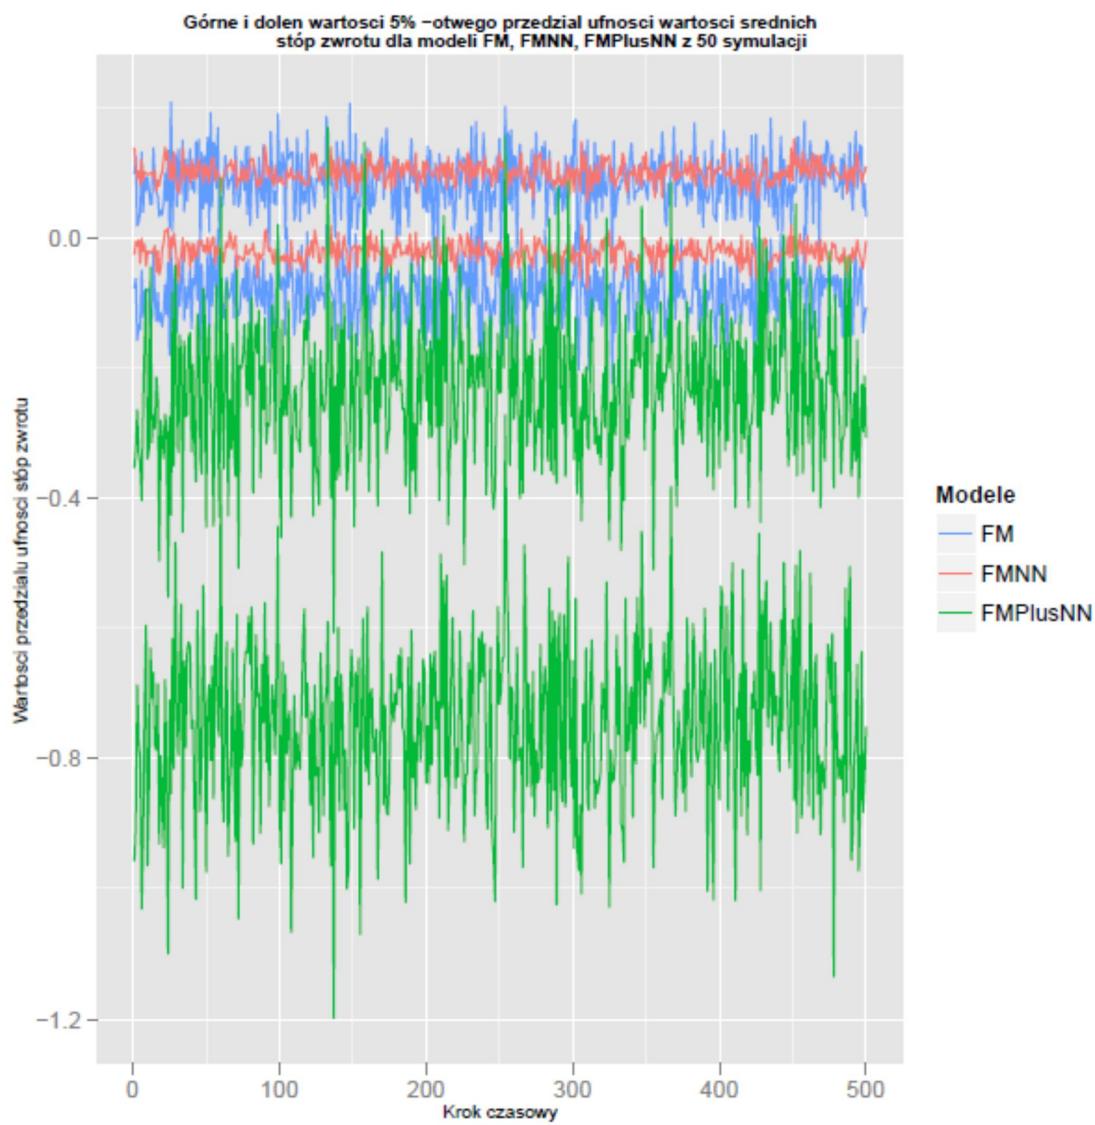
Srednie wartosci stóp zwrotu z 50 symulacji
modeli FM, FMNN, FMPlusNN



b)

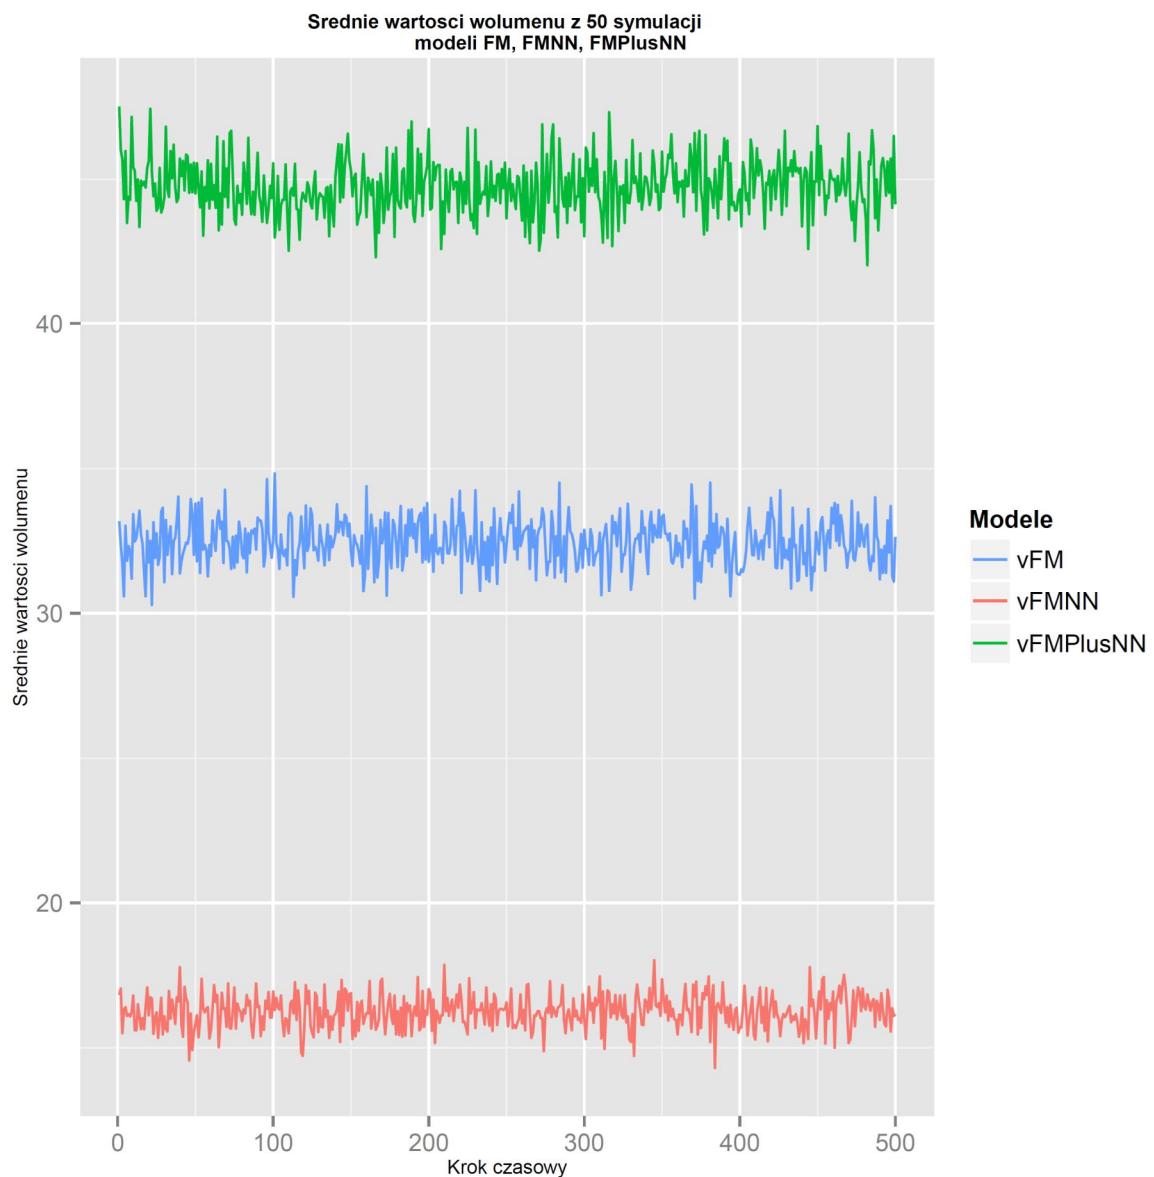


c)



Wykres nr 2. Wykres przedstawiający a) wartości stóp zwrotu średnich wartości z 50 symulacji dla trzech modeli FM, FMNN, FMPlusNN w funkcji kroków czasowych wraz z b) rozkładem wyników przedstawionych na histogramach oraz c) wykresami górnych i dolnych wartości 5% -ontewo przedziału ufności obliczonego metodą Bootstrap.

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.



Wykres nr 3. Wykres przedstawiający wartości wolumenu średnich wartości z 50 symulacji dla trzech modeli FM, FMNN, FMPPlusNN w funkcji kroków czasowych.

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Podsumowaniem rozkładu wartości stóp zwrotu jest tabela nr 8 zawierająca dane dotyczące kurtozy i skośności rozkładu.

Tabela nr 8. Kurtoza i skośność rozkładu stóp zwrotu dla poszczególnych modeli.

	śr.	odch.st.	skośność	kurtoza
rFM	0.0006	0.0445	-0.1194	-0.1510
rFMNN	0.0406	0.0153	0.0268	-0.0413
rFMPPlusNN	-0.4870	0.1180	0.0805	0.1844

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Analizując wyniki rozkładu stóp zwrotu na podstawie danych z tabeli nr 8 oraz wykresu nr 2 b w odniesieniu odpowiednio do modeli FM, FMNN, FMPlusNN można zauważyć następujące:

- rFM: Rozkład jest prawie symetryczny z tendencją do lewego dłuższego ogona dystrybucji przy grubości ogona dystrybucji mniejszą od rozkładu normalnego.
- rFMNN: Rozkład jest prawie symetryczny przy grubości ogona dystrybucji mniejszej od rozkładu normalnego.
- rFMPlusNN: Rozkład jest zbliżony do symetrycznego z lekką tendencją do prawego dłuższego ogona dystrybucji przy grubości ogona dystrybucji mniejszą od rozkładu normalnego (choć największej z trzech badanych modeli).

Dążąc do weryfikacji modelu i wyników symulacji z modelem błędzenia losowego (oznaczonego jako R_w z ang. Random Walk) została przeprowadzona analiza z wykorzystaniem języka programowania R. Przy pomocy tego języka został zasymulowany model błędzenia losowego sparametryzowany odpowiednio względem trzech modeli FM, FMNN oraz FMPlusNN .

Zgodnie z Ruppert, (2011) hipoteza błędzenia losowego stanowi, że pojedyncze okresy logarytmicznych wartości stopy zwrotu (patrz równanie nr 1) są od siebie niezależne. Wynika to z:

$$1 + R_t(k) = (1 + R_t) \dots (1 + R_{t-k+1}) = e^{r_t} \dots e^{r_{t-k+1}} = e^{r_t + \dots + r_{t-k+1}} \quad (4)$$

gdzie:

$$\log(1 + R_t) = r_t + \dots + r_{t-k+1} \quad (5)$$

Zgodnie z Ruppert, (2011) model ma charakter błędzenia losowego, gdy:

$$S_t = S_0 + Z_1 + \dots + Z_t \quad (6)$$

S_0, S_1, \dots jest błędzeniem losowym, a Z_1, Z_2, \dots kroki tego błędzenia, które posiadają identyczny i niezależny rozkład. W przypadku, gdy ten rozkład jest standardowym normalnym rozkładem Gaussa to błędzenie losowe jest nazywane standardowym normalnym błędzeniem losowym Gaussa. Wartość oczekiwana i wariancja S_t pod warunkiem znanego S_0 są odpowiednio równe

$$E(S_t|S_0) = S_0 + \mu * t \quad (7)$$

$$\text{Var}(S_t|S_0) = \sigma^2 * t \quad (8)$$

gdzie μ w tym przypadku jest równe 0 i jest to określony kierunek przemieszczania się błądzenia losowego. σ jest zmiennością i określa jak bardzo błądzenie losowe oscyluje wokół $E(S_t|S_0)$.

Odchylenie standardowe dla S_t pod warunkiem S_0 jest równe $\sigma * t^{0.5}$. Stąd wartość średnia jest równa

$$(S_0 + \mu * t) \pm \sigma * \sqrt{t} \quad (9)$$

Na podstawie Zivot, (2014) w naszym przypadku niech Y_t będzie wartością stopy procentowej w kroku t . Stąd

$$Y_t = Y_{t-1} + \epsilon_t \quad (10)$$

gdzie:

$$\epsilon_t \sim \text{standardowy rozkład normalny } (0, \sigma_\epsilon^2)$$

czyli

$$Y_t = Y_0 + \sum_{j=1}^t \epsilon_j \quad (11)$$

$$Y_0 = E[Y_t] \quad (12)$$

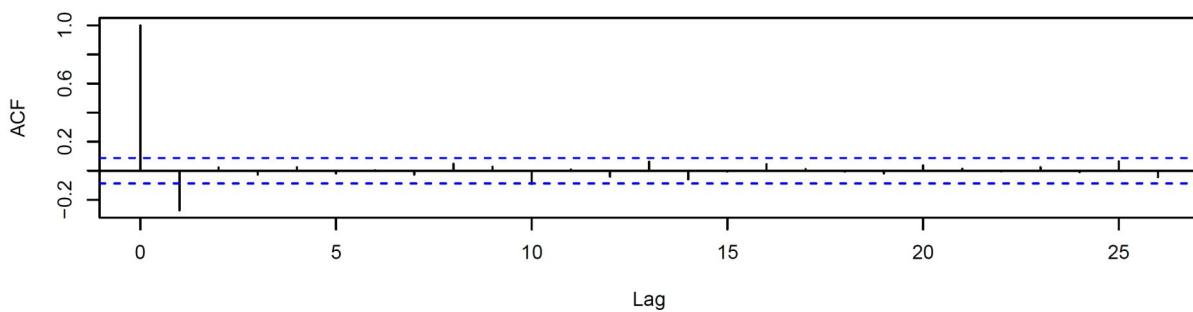
$$\sigma^2 = Var(Y_t) = \sum Var(\epsilon) = t * \sigma_\epsilon^2 \quad (13)$$

$$\Delta Y = Y_t - Y_{t-1} = \epsilon_t \quad (14)$$

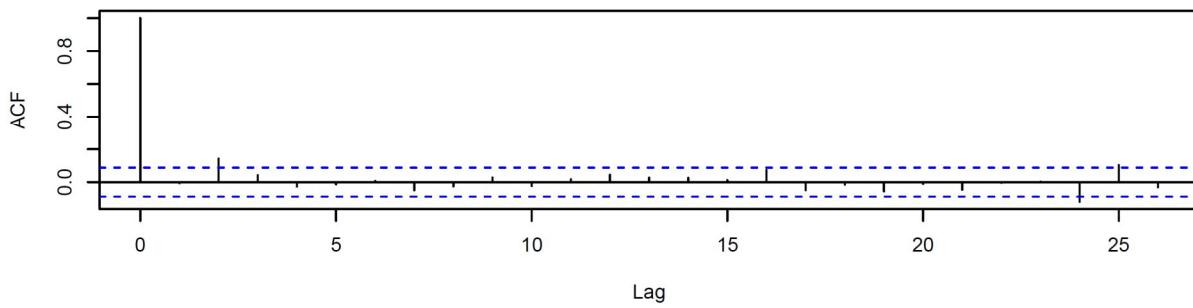
W pracy zostały przeprowadzone dodatkowo symulacje modelu błądzenia losowego odpowiednio sparametryzowanego względem modeli FM, FMNN oraz FMPlusNN. Kod modelu błądzenia losowego został napisany w języku programowania R. Takie podejście pozwoliło na weryfikację autokorelacji nie tylko samych modeli FM, FMNN, FMPlusNN, ale również zestawienie ich z modelami RwFM, RwFMNN, RwFMPlusNN.

Ostatnim elementem weryfikacji hipotezy jest sprawdzenie czy występuje korelacja pomiędzy kolejnymi wartościami stóp zwrotu dla poszczególnych modeli.

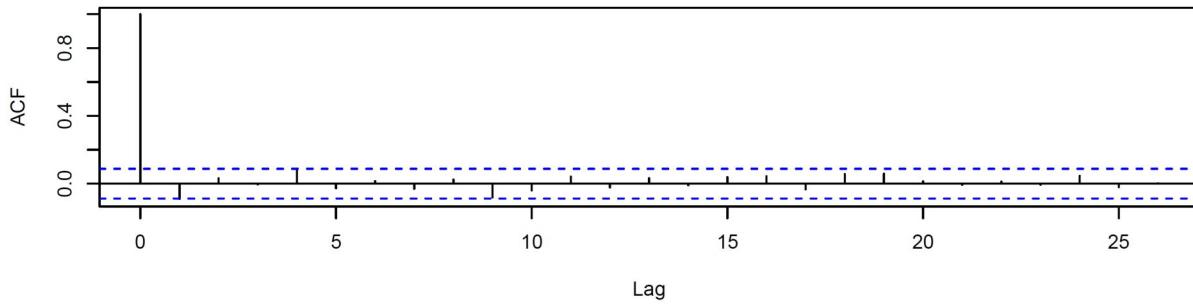
Autokorelacja wyników symulacji modelu FM



Autokorelacja wyników symulacji modelu FMNN



Autokorelacja wyników symulacji modelu FMPlusNN



Wykres nr 4. Wykresy autokorelacji dla modeli FM, FMNN, FMPlusNN.

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Wartości, które przekraczają poziom ufności na poziomie 5% dla autokorelacji odpowiednio dla modeli FM, FMNN i FMPlusNN oraz odpowiednio sparametryzowanych w odniesieniu do tych modeli, modeli błędzenia losowego RwFM, RwFMNN, RwFMPlusNN:

FM: **0.1064**

RwFM: **-0.2721; -0.0901**

FMNN: **0.1416; -0.1180; 0.1035**

RwFMNN: **0.1064**

FMPlusNN: -0.0907

RwFMPlusNN: 0.1064

Tabela nr 9. Porównanie wyników autokorelacji modeli FM, FMNN oraz FMPlusNN wraz z ich odpowiednikami modeli błądzenia losowego.

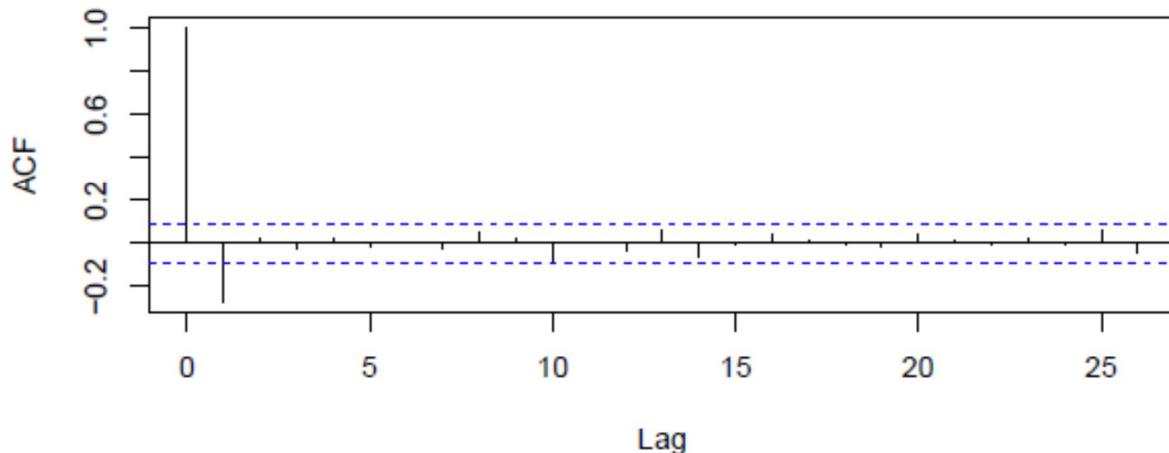
Model	Liczba wartości poza poziomem ufności 5%	Czy przekroczyony poziom ufności?	Wniosek
FM	1 Nie	Zgodnym z modelem Farmer, i in. (2003)	
RwFM	1 Nie	-	
FMNN	3 Tak	Odrzucamy hipotezę	
RwFMNN	1 Nie	-	
FMPlusNN	1 Nie	Gdyby ten model stanowił przedmiot zainteresowania nie byłoby dowodów pozwalających odrzucić hipotezę.	
RwFMPlusNN	1 Nie	-	

Na tej podstawie nie mamy dowodów, żeby stwierdzić, że stopy zwrotu wygenerowane w wyniku symulacji modelu FMNN posiadają charakter błądzenia losowego. Tym samym brak jest dowodów pozwalających odrzucić hipotezę postawioną w tej pracy (wprowadzenie agenta typu „low-intelligence” nie wpłynie na zachowanie rynku w sposób poprawiający jego efektywność według Fama (1970)). Stąd brak jest również dowodu na to, że poprzez wprowadzenie zmodyfikowanego agenta zmienił się mechanizm formowania cen wprowadzając pozytywną autokorelację. Po wprowadzeniu agenta typu low-intelligence dla modelu FMPlusNN widać znaczącą różnicę w wartości stóp zwrotu w stosunku do modelu FM. Dla modelu FMNN wartości odchyleń standardowych są znacznie mniejsze niż dla modeli FM i FMPlusNN. Jednak model FMNN nie różni się zakresem wartości stóp zwrotu od FM tak jak FMPlusNN. Sytuacja ta jest widoczna na wykresie nr 2 a. Niestety nie została również zauważona zmiana w wolumenie, która miała polegać na grupowaniu charakterystycznym dla rynków rzeczywistych o czym pisał Brigs, i in. (2008?). Uwagę zwracającą charakterystyki rozkładów wyników stóp zwrotu dla wszystkich trzech modeli, które są znacznie bardziej „płaskie” niż rozkład normalny, gdzie rozkłady dystrybucji stóp zwrotu na rynkach rzeczywistych mają charakter wręcz odwrotny czyli ogony dystrybucji są grubsze niż dla rozkładów normalnych.

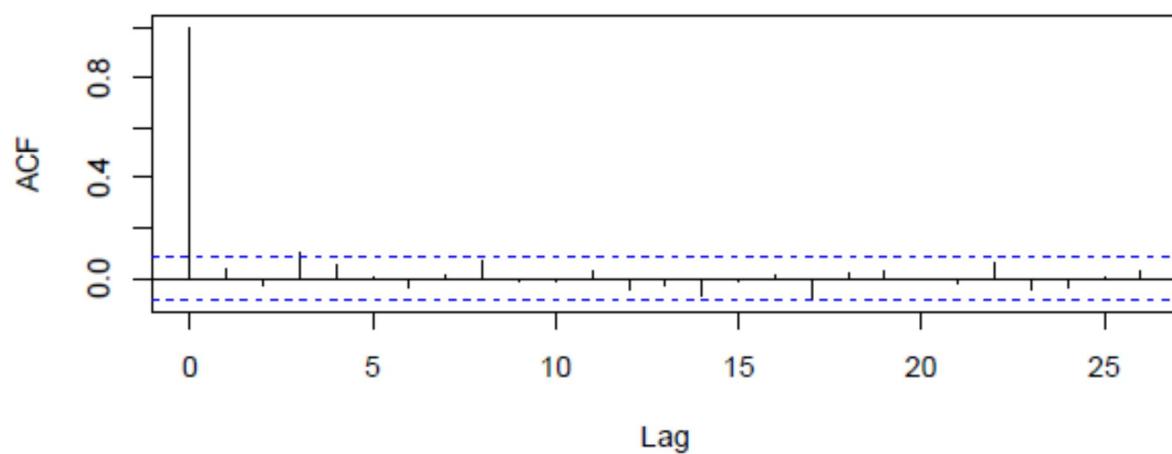
Wykres nr 5 przedstawia zestawienie wykresów autokorelacji stóp zwrotu dla modelu oraz symulacji błędzenia losowego opartego na tym modelu. Takie zestawienia pokazuje jaki charakter ma wykres autokorelacji dla błędzenia losowego i jak przedstawiają się wyniki z symulacji modeli.

a)

Autokorelacja wyników symulacji modelu FM

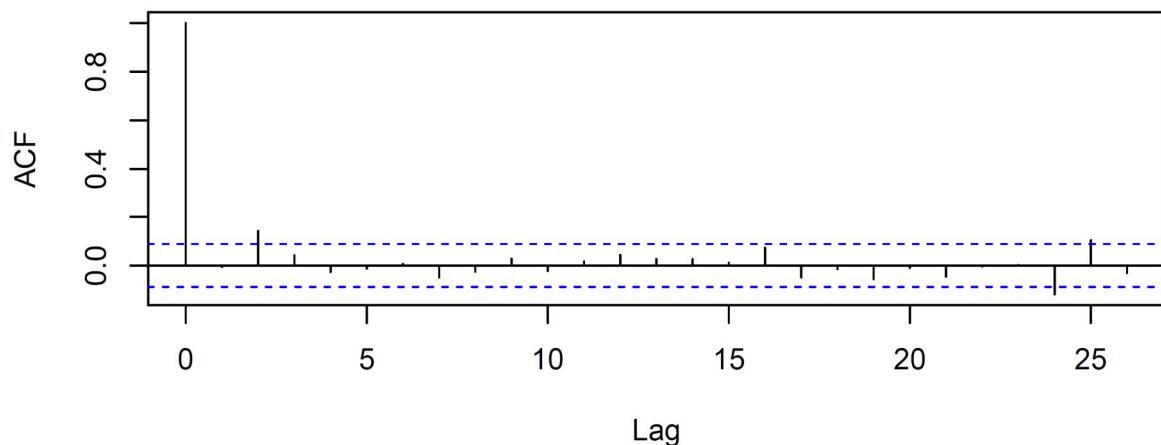


Autokorelacja wyników symulacji modelu
bladzenia losowego (wedlug FM)

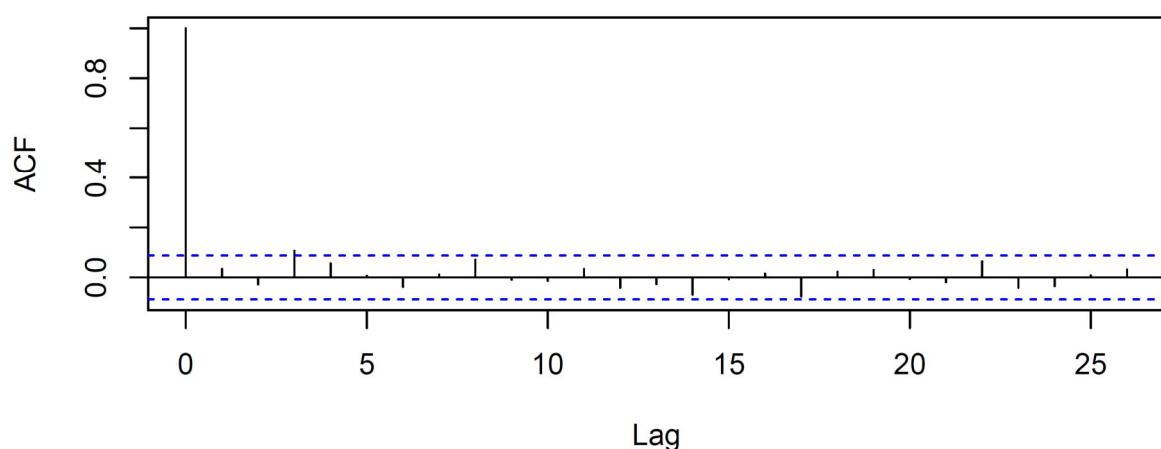


b)

Autokorelacja wyników symulacji modelu FMNN

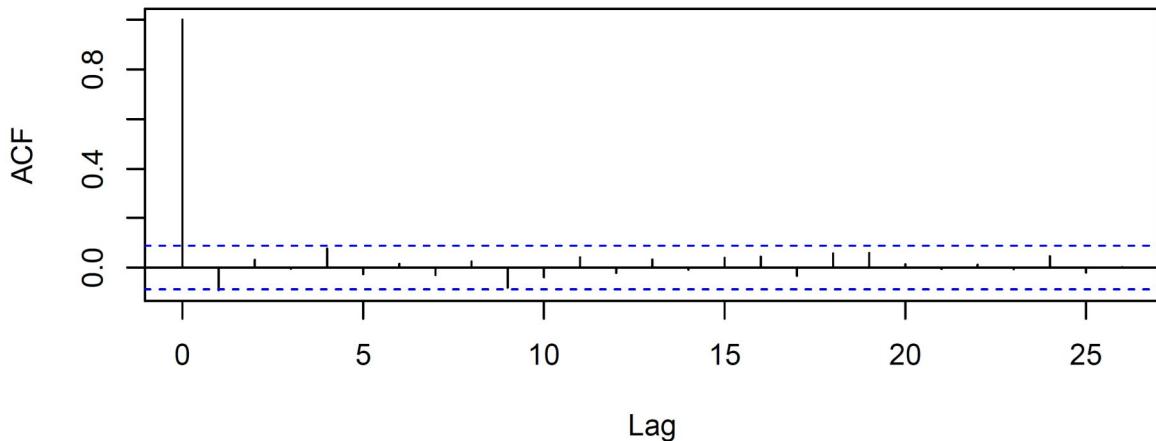


Autokorelacja wyników symulacji modelu bladzenia losowego (wedlug FMNN)

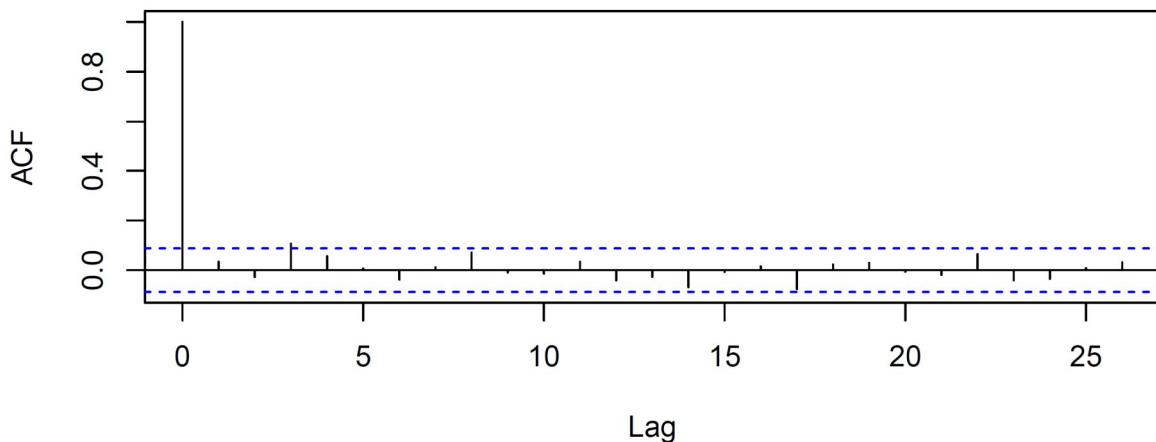


c)

Autokorelacja wyników symulacji modelu FMPlusNN



Autokorelacja wyników symulacji modelu błądzenia losowego (według FMPlusNN)



Wykres nr 5. Zestawienie autokorelacji dla wyników symulacji modelu błądzenia losowego oraz autokorelacji wyników symulacji modelu na podstawie, którego zostało on sparametryzowany odpowiednio a) FM, b) FMNN, c) FMPlusNN.

Źródło: Opracowanie własne z wykorzystaniem języka programowania R.

Swell, (2012) odnosząc się do średniej wartości wskaźnika Dow Jones Industrial Average (DJIA) napisał, że 22 z 30 firm posiadają pozytywną autokorelację stóp zwrotu. Wskazuje on, że dla pierwszego rzędu autokorelacji jest ona pozytywna dla całego okresu dla autokorelacji dziennych i miesięcznych stóp zwrotu bliskich zeru. Autokorelacja jest mała, bliska zeru i pozytywna. W badaniach Swell, (2012) wskazuje, że hipoteza niezależności kolejnych stóp zwrotu została odrzucona dla dziennych wartości. Jednak brak jest podstaw do odrzucenia hipotezy dla tygodniowych, miesięcznych oraz rocznych stóp zwrotu. Bardziej szczegółowo

analiza wskazuje, że dzienne, tygodniowe oraz malejące stopy zwrotu wykazują najmniejszy dowód pozwalający na potwierdzenie hipotezy o efektywności rynku w oparciu o te dane. Choć jest to dodatkowe spojrzenie na kwestię weryfikacji hipotezy efektywności rynku zgodnie z Fama, (1970) to nie rozjaśnia to zagadnienia, a wskazuje na wysoki poziom trudności związanych z interpretacją wyników z opisywanej symulacji.

4.4 Dyskusja

Odnosząc się do poprzedniego rozdziału związanego z analizą wyników symulacji uwagę zwraca model FMPlusNN, dla którego jest zaobserwowany brak autokorelacji podobnie jak dla modelu FM. Oznacza to, że wprowadzenie agentów typu low-intelligence jako trzeciej grupy spowodowało całkowity brak możliwości przewidywania w kolejnych krokach wartości stóp zwrotu. Przede wszystkim należałoby się zastanowić co powoduje pojawienie się tak dużych różnic pomiędzy modelami FM, FMNN oraz FMPlusNN, a z drugiej dlaczego FM i FMPlusNN posiadają charakter błędzenia losowego w przeciwieństwie do FMNN. Z jednej strony mając doczynienia z rynkami efektywnymi co zostało założone w hipotezie przewidywanie wartości nie powinno być możliwe. Dalsze badania powinny wyjaśnić dlaczego zostały zarejestrowane takie wartości i w jaki sposób zmodyfikować model w celu dążenia do osiągnięcia modelu odwzorowującego rynek efektywny według Fama, (1970) w odniesieniu do modelu FMNN.

Na wykresie nr 2 b, rozkład wartości przedstawiony na histogramach oraz wartości kurtozy i skośność widoczne w tabeli nr 8 wskazują na to, że brak jest grubego ogona dystrybucji. Należałoby się zastanowić co powoduje taki kształt rozkładu. Jednym z istotnych elementów, który powinien zostać poddany analizie jest jednolita „strategii inwestycyjna” dla wszystkich agentów typu low-intelligence w danej symulacji. Wszyscy korzystają z tej samej informacji jaką jest przewidywana wartość stopy zwrotu w danym kroku czasowym. Powoduje to, że połowa rynku posiada tę samą informację dla modelu FMNN, a dla modelu FMPlusNN jedną trzecią rynku. Choć występuje tutaj losowy czynnik decydujący o tym czy złożyć zamówienie kupna i sprzedaży, a dalej losowy czynnik o rozkładzie Poissona ile zamówień zostanie złożonych. Warto w kolejnych badaniach całkowicie uniezależnić od siebie każdego z agentów typu low-intelligence.

W modelu ϵ granularność jest przyjęta na poziomie 0.0 co oznacza, że są to wartości ciągłe czyli dobre odwzorowanie rzeczywistości. Tak jak Daniels, i in. (2003) wskazali, że małe

wartości ϵ dobrze odwzorowują jakościowo sytuację na rynku finansowym to jednak brak jest dobrego odwzorowania ilościowego. Dla dużych wartości ϵ zarówno jakościowe jak i ilościowe odwzorowanie jest dobre. Wskazuje to na konieczność wprowadzenia analizy wrażliwości zbudowanego modelu w celu szerszego spojrzenia na jego możliwości.

Zagadnieniem, które nie zostało w tej pracy zweryfikowane jest pomiar dyfuzji ceny między kolejnymi punktami, która tak jak dla Farmera, i in. (2003) jest realizowana poprzez pomiar wariancji środka ceny. Następnie wyniki ze zmodyfikowanego modelu należałyby porównywać z tymi przedstawionymi przez Farmera, i in. (2003).

Kolejną kwestią, która mogłaby stanowić rozbudowę modelu po wcześniejszym rozwiązaniu problemu dużej autokorelacji mogłaby być modyfikacja modelu w celu odniesienia go do danych rzeczywistych. W pierwszej kolejności należałoby go sparametryzować względem danych, na których pracowali Farmer, i in. (2003) z Londyńskiej Giełdy Papierów Wartościowych, a następnie odnieść się do danych np. z Nowojorskiej Giełdy Papierów Wartościowych.

Naturalnym rozwinięciem modelu z informatycznego punktu widzenia jest modyfikacja platformy w sposób bardziej przystępny dla użytkownika.

Stąd też po połączeniu przyjaznej użytkownikowi platformy z modelem sparametryzowanym względem danych historycznych z rynku finansowego można byłoby rozpatrzyć uzupełnienie platformy o możliwość analizowania danych w czasie rzeczywistym wykorzystując takie narzędzia jak Apache Spark i Apache Storm.

5 Podsumowanie

Celem pracy było sprawdzenie hipotezy, która zakłada, że wprowadzenie agenta typu low-intelligence nie wpłynie na zachowanie rynku w sposób poprawiający jego efektywność według Fama (1970). Podjęta analiza wynika z sugestii jaką podał Farmer, i in. (2003) wskazując na możliwość wprowadzenia agenta typu low-intelligence co miało doprowadzić do nieskorelowanych zmian cen przy założeniu, że mają one charakter błądzenia losowego. Takie założenie związane jest również z tym, że wprowadzenie zmodyfikowanego agenta nie zmieni mechanizmu formowania się cen, a ich formowanie będzie miało pozytywną autokorelację.

Stąd też badane jest założenie będące podstawą do dalszych analiz czyli sprawdzenie występowania autokorelacji stóp zwrotu. Jest to forma weryfikacji charakteru procesu zmiany względnych wartości cen, który powinien być typu błądzenia losowego.

Obszarem zainteresowania były również same wyniki symulacji dla wielkości stóp zwrotu i wolumenu. Wyniki symulacji wolumenu nie przedstawiają podobieństwa do wyników z rynków finansowych, gdyż nie występuje grupowanie wyników jak wskazuje Briggs, i in. (2008?).

Dane, które były interesujące to wartości średnie, odchylenia standardowe oraz przedziały ufności. Znając już wartości średnie oraz odchylenia standardowe należało poznać błędy standardowe w celu określenia zakresu występowania wartości badanych danych. W tym celu została wykorzystana metoda Bootstrap, która nie jest wrażliwa na charakter rozkładu wyników.

Dodatkowo zostały przeprowadzone obliczenia współczynnika korelacji dla stóp zwrotu i wolumenu dla określonego modelu. Ciekawa jest zależność pomiędzy wolumenem danego modelu, a jego wartościami stóp zwrotu. Choć tabel nr 6 nie wskazuje na występowanie korelacji w danym modelu pomiędzy tymi wartościami to na wykresie nr 2 a i 3 a, możemy zauważyc, że model posiadające większe wartości stóp zwrotu posiadają mniejsze wartości wolumenu odpowiednio dla wszystkich modeli. Przyczyny należy szukać w kodzie opisującym agentów low-intelligence oraz w sposobie budowania modelu sztucznych sieci neuronowych. W tej pracy wszyscy agencie dla danej symulacji korzystali z tego samego modelu sztucznych sieci neuronowych, który przeszedł proces uczenia dla określonej ilości kroków. W kolejnych analizach należałyby się zastanowić nad wprowadzeniem tylu modeli ilu jest agentów lub przynajmniej określonych grup agentów, a sieci neuronowe powinny być poddawane

procesowi weryfikacji w celu nieustanego uczenia. Takie rozwiązanie miałyby na celu zmniejszenie błędu predykcji dla określonych grup agentów, ale również wprowadzenie większej niezależności pomiędzy agentami, co mogłyby skutkować występowaniem zjawiska grupowania wolumenu.

Kolejnym krokiem pozwalającym przybliżyć się do określenia charakteru błędzenia losowego wyników stóp zwrotu badanych modli było zbudowanie modelu błędzenia losowego, który został sparametryzowany na podstawie wyników odpowiednio z modeli FM, FMNN, FMPlusNN. Takie podejście pozwala w przejrzysty sposób porównać wyniki autokorelacji.

Analiza autokorelacji dostarczyła informacji pozwalających na stwierdzenie, że brak jest dowodów na odrzucenie hipotezy zerowej względem modelu FMNN. Zmiana wartości stóp zwrotu nie ma charakteru błędzenia losowego.

Wyniki modeli FMNN, FMPlusNN były odnoszone do modelu FM, który został zbudowane na wzór tego zaproponowanego przez Briggs, i in. (2008), a odnosi się on do Farmera, i in. (2003). Charakter stóp zwrotu prezentowanego modelu FM jest zbieżny choć wyniki są różne na co miało wpływ ustalenie różnej liczby agentów biorących udział w symulacji. Cała symulacja jest realizowana w ramach platformy MASON. Kod przygotowany przez Briggs, i in. (2008?), następnie podany modyfikacji w połączeniu z bibliotekami Encog pozwolił na utworzenie symulacji z zaproponowanym przez Farmera, i in. (2003) agentem low-intelligence. Niezależnie od nakreślonych wskazań do dalszych pracy jakie można zrealizować z wykorzystaniem tego modelu wymaga on analizy wrażliwości parametrów, zoptymalizowania kodu w celu usprawnienia realizacji tej analizy i umieszczenia go w klastrze obliczeniowy, który przyspieszy czas obliczeń. Jest to szczególnie istotne przy wprowadzaniu zmian związanych z agentami typu low-intelligence, gdzie każdy z agentów korzystałby z modelu sieci neuronowych o różnych wartościach wag.

Z tego miejsca ciekawe są trzy kolejne kroki z perspektywy rozwoju modelu. Pierwszy to wprowadzenie i weryfikacja nowych strategii inwestycyjnych. Drugi to rozbudowanie platformy o możliwość podłączenia danych stanowiących element informacji na rynku (Twitter, Newsy itp.) oraz integracja z platformą Hadoop uzupełnioną o narzędzie do prowadzenia analiz z wykorzystaniem języka programowania R. Trzecim krokiem mogłyby być uzupełnienie platformy o agentów tworzących tło makroekonomiczne gospodarki, w której funkcjonują rynki finansowe. Takie podejście mogłyby stanowić ciekawy krok do rozpoczęcia badań nad problemem powstawania kryzysów na rynkach finansowych. Takie badania

prowadzone są np. przez Komisję Europejską poprzez projekt CRISIS (<http://www.crisis-economics.eu/vision/what-is-crisis/>)

6 Bibliografia

Bachelier, L., 1900. Théorie de la Spéculation. *Annales scientifiques de l'École Normale Supérieure*, volume: 17, page 21-86, [online] Available at: <<http://eudml.org/doc/81146>>

Becker, Gary S. 1962. Irrational Behavior and Economic Theory. *Journal of Political Economy* Vol. 70, No. 1 (Feb., 1962), pp. 1-13 [online] Available at: <<http://www.jstor.org/stable/1827018>>

Briggs, J., Trusiano, F., Latek, M. , Marks, R. (Programming Group) and Lin, S., Hansen Ch., Tzitzouris, T. (Data Analysis Group) 2008?. Simulating Financial Markets using MASON Framework. Center for Social Complexity, George Mason University, USA.

Brown, R, 1828. A Brief Account of Microscopical Observations Made in the Months of June, July, and August 1827, on the Particles Contained in the Pollen of Plants; and on the General Existence of Active Molecules in Organic and Inorganic bodies. Private distribution in London at the press of Richard Taylor, [online] Available at: <http://sciweb.nybg.org/science2/pdfs/dws/Brownian.pdf>

Daniels, M., Farmer, J.D., Gillemot, L., Iori, G., and Smith, D.E., 2003. Quantitative model of price diffusion and market friction based on trading as a mechanistic random process. *Physical Review Letters* 9019, 10. *ArXiv.com Cornell University Library*, [online] Available at: <[arXiv:cond-mat/0112422](https://arxiv.org/abs/cond-mat/0112422)>.

Einstein, A., 1905. Investigations on the theory of, the Brownian Movement. Dover Publications, INC, 1956, [online] Available at: <http://www.math.uconn.edu/~gordina/Einstein_Brownian1905.pdf>

Fama, E. F., 1970. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383-417, [online] Available at <<http://dx.doi.org/10.2307/2325486>>.

Fama, E. F. (1965). The behavior of stock-market prices. *Journal of Business*, 38(1), 34-105. [online] Available at: <http://dx.doi.org/10.1086/294743>.

Farmer, D.J, 2012. Economics needs to treat the economy as a complex system. National Science Foundation under Grant No.0965673, the European Union Seventh Framework Programme FP7/2007-2013 under grant agreement CRISIS-ICT-2011-288501, and by the Sloan Foundation, [online] Available at: <http://inateconomics.org/conference/berlin/economics-needs-treat-economy-complex-system>

Farmer, D. J., Foley, J., 2009. The economy needs agent-based modelling. *Nature*, Volume 460, 685-686, [online] Available at: <<http://www.nature.com/nature/journal/v460/n7256/full/460685a.html>>

Farmer, D. J., Patelli, P., and Zovko, I., 2003. The Predictive Power of Zero Intelligence in Financial Markets. *ArXiv.com Cornell University Library*, [online] Available at: <<http://arxiv.org/abs/cond-mat/0309233>>

Gilbert, N., Troitzsch, K.G., 2005 .Open UniversitySimulation for the Social Scientist. Open University Press.

Gode, K. and Sunder, S., 1993. Allocative Efficiency of Markets with Zero-Intelligence Traders: Market as a Partial Substitute for Individual Rationality. *Journal of Political Economy*, vol. 101, no. 1. Available through:
JSTOR Journal Storage <
<http://www.jstor.org/discover/10.2307/2138676?uid=6851048&uid=3738840&uid=2&uid=6850976&uid=3&uid=67&uid=62&sid=21106072936841>>.

Grothmann R., 2002. Multiagent market modeling based on neural networks. University of Bremen, Germany, Siemens AG, Corporate Technology, Munich, Germany, Thesis presented for the Degree of Doctor of Economics, [online] Available at: <https://www.deutsche-digitale-bibliothek.de/binary/BZY53RWHY5AGYPBUI5B3KFZHUAUE3UXH/full/1.pdf>

Heaton, J., 2011. Programming Neural Networks with Encog3 in Java. Heaton Research, Inc. St. Louis, MO, USA [online] Available at: <http://www.heatonresearch.com>

LeBaron, B. (2000). Agent-based computational finance: Suggested readings and early research. *Journal of Economic Dynamics and Control* 24, 679-702, [online] Available at: <http://www2.econ.iastate.edu/tesfatsi/blake.SuggestedRead.pdf>

Luke, S., 2014. Multiagent Simulation and the MASON Library. Department of Computer Science George Mason University Manual Version 18

Luke, S., Cio-Revilla, C., Panait, L., Sullivan, K., and Balan, G., 2005. MASON: A Multiagent Simulation Environment. *Simulation: Transactions of the society for Modeling and Simulation International*. 82(7):517-527.

Macal, C.M, North, M.J, 2010. Tutorial on agent-based modelling and simulation. *Journal of Simulation* (2010) 4, 151–162

Macal, Ch.M., North, M.J., 2009. Agent-based modeling and simulation. Winter Simulation Conference, [online] Available at: <http://www.informs-sim.org/wsc09papers/009.pdf>

Mandelbrot, Benoit, 1963. The Variation of Certain Speculative Prices, *The Journal of Business*, 36(4), 394–419, [online] Available at: <<http://www.e-m-h.org/Mand63.pdf>>

McBride, M., 2014. Netlogo model of zero-intelligence trading by Gode and Sunder. [online] Available at: <https://github.com/memcbride/ZITrading>

Nikunj, R., Bhavesh, K., Darshan, R., 2011. Testing Weak form market efficiency of Indian Stock Markets. *SS International Journal of Business and Management Research* volume 1, Issue 3 [SEP 2011], ISSN 2231-4970, [online] Available at: www.ssirn.com

Ng, A., 2015. Machine learning course. Coursera.org, Massive Open Online Course [online] Available at: <<https://www.coursera.org/learn/machine-learning/home/>>

Nobel Prize Organization, 1970 [online] Available at: <http://www.nobelprize.org/nobel_prizes/economic-sciences/lauriates/1970/index.html>

Osbourne, M.F.M., 1959. Brownian Motion in the Stock Market, *Operations Research*, 7(2), 145–73, [online] Available at: <<http://www.e-m-h.org/Osbo59.pdf>>

Pearson, K. (1905). The Problem of the Random Walk. *Nature*. 72, 294.

Regnault, J., 1863. Calcul des chances et philosophie de la bourse. Mallet-Bachelier Castel, Paris 1866, [online] Available at: <https://archive.org/details/calculdeschances00regn>

Ruppert, D., 2011. Statistics and Data Analysis for Financial Engineering. *Springer Science+Business Media*.

Sewell, M., 2012. The Efficient Market Hypothesis: Empirical Evidence. *International Journal of Statistics and Probability* Vol 1, No 2 (2012), [online] Available at: <http://ccsenet.org/journal/index.php/ijsp/article/view/17911>

Smith, E., Farmer, J.D., Gillemot, L., and Krishnamurthy,S., 2003. Statistical theory of the continuous double auction. *Quantitative Finance*, [online] Available at: <http://arxiv.org/abs/cond-mat/0210475>

Smith, V.L., 1982. Microeconomic Systems as an Experimental Science. *The American Economic Review* Vol. 72, No. 5 (Dec., 1982), pp. 923-955 [online] Available at: <<http://www.jstor.org/stable/1812014>>

Strutt, J.W., Lord Rayleigh, 1880. On the Resultant of a Large Number of Vibrations of the Same Pitch and of Arbitrary Phase, *Philos. Mag.* 10, 73 [online] Available at: <http://www.tandfonline.com/doi/abs/10.1080/14786448008626893>

Tesfatsion, L., 2002. Agent-Based Computational Economics: Growing Economies from the <http://www2.econ.iastate.edu/tesfatsi/acealife.pdf>

Weatherall, J.O., 2013. *The Physics of Wall Street*. Houghton Mifflin Harcourt Boston New York

Venn, J. (1888). The Logic of Chance, 3rd edn. Macmillan, London.

Zivot, E., 2015. Introduction to Computational Finance and Financial. University of Washington, ECON 424/CFRM 462 [online] Available at: <http://faculty.washington.edu/ezivot/econ424/econ424.htm>

7 Spis tabel, rysunków i wykresów

7.1 Tabele

Tabela nr 1. Zmieniające się wartości akcji i spredy po realizacji zamówienia 150 akcji.....	18
Tabela nr 2. Charakterystyczne współczynniki dla analizy wymiarowej rynków finansowych na podstawie Smith, i in. (2003).....	24
Tabela nr 3. Wartości parametrów wieloagentowego modelu podwójnej ciągłej aukcji.	47
Tabela nr 4. Podsumowanie wyników stóp zwrotu (r) oraz wolumenu trzech modli FM, FMNN, FMPlusNN. Informacje zawarte w tabeli to wartości średnie oraz odchylenia standardowe wyników średnich wartości z przeprowadzonych 50 symulacji.....	53
Tabela nr 5. Wartości korelacji stóp zwrotu i wolumenu dla trzech modli FM, FMNN i FMPlusNN.....	54
Tabela nr 6. Wartości średnie (śr.) oraz odchylenia standardowe (odch.st.) analizowanych danych (stopy zwrotu - r , wolumen - v) obliczone z wykorzystaniem techniki Bootstrap dla trzech modeli (FM, FMNN, FMPlusNN). Do każdej wartości danej wielkości zostały obliczone błędy standardowe oraz bias inaczej odchylenie systematyczne czyli wartość różnicy pomiędzy wartością średnią z wartością obliczonych metodą Bootstrap a wartością średnią z wartością symulacji dla danego modelu.	55
Tabela nr 7. Średnie wartości i przedziały niepewność analizowanych danych (stopy zwrotu - r , wolumen - v) obliczone z wykorzystaniem techniki Bootstrap dla trzech modeli (FM, FMNN, FMPlusNN). W tabeli odpowiednie oznaczania przedstawiają: w.Stat – wartość wielkości statystycznej; n.0.95dół i n.0.95góra – dla przedziału ufności 95% przy założeniu, że dane wartości posiadają rozkład normalny prezentuje dolną i górną wartość przedziału; kwant0.025 i kwant.0.975 wartości kwantylów rzędu 0.025 i 0.975; śr – wartość średnia; odch.st – odchylenie standardowe.....	55
Tabela nr 8. Kurtoza i skośność rozkładu stóp zwrotu dla poszczególnych modeli.	60
Tabela nr 9. Porównanie wyników autokorelacji modeli FM, FMNN oraz FMPlusNN wraz z ich odpowiednikami modeli błędzenia losowego.....	65

7.2 Rysunki

Rysunek nr 1. Schemat składania zamówień kupna i sprzedaży oraz procesu przecina się ofert. Nowe oferty sprzedaży mogą być złożone w dowolnej cenie większej niż najlepsza oferta kupna

b(t), a nowe oferty kupna mogą być złożone w dowolnej cenie mniejszej niż najlepsza oferta sprzedawy a(t).....	17
Rysunek nr 2. Schemat struktury sztucznej sieci neuronowej zaimplementowanej w opisywanym projekcie wraz ze schematycznie przedstawionym algorytmem Froward Propagation oraz Backward propagation czyli sieci jednokierunkowej z algorytmem wstecznej propagacji.	32
Rysunek nr 3. Diagram UML rdzenia symulacji i harmonogram dyskretnych zdarzeń platformy MASON.....	45
Rysunek nr 4. Diagram UML głównych komponentów i relacji w modelu rynków finansowych opisywanego w tej pracy. Klasy SimState oraz interfejs Steppable to elementy nadzędne platformy MASON. Klasa FinancialModel dziedziczy z klasy SimState, a klasa GenericPlayer z interfejsu Steppable.	46

7.3 Wykresy

Wykres nr 1. Wykres typu box plot przedstawiający porównanie średnich wartości stóp zwrotu z 50 symulacji trzech modli FM, FMNN, FMPlusNN.	54
Wykres nr 2. Wykres przedstawiający a) wartości stóp zwrotu średnich wartości z 50 symulacji dla trzech modeli FM, FMNN, FMPlusNN w funkcji kroków czasowych wraz z b) rozkładem wyników przedstawionych na histogramach oraz c) wykresami górnymi i dolnymi wartości 5% -ontewo przedziału ufności obliczonego metodą Bootstrap.....	59
Wykres nr 3. Wykres przedstawiający wartości wolumenu średnich wartości z 50 symulacji dla trzech modeli FM, FMNN, FMPlusNN w funkcji kroków czasowych.	60
Wykres nr 4. Wykresy autokorelacji dla modeli FM, FMNN, FMPlusNN.	64
Wykres nr 5. Zestawienie autokorelacji dla wyników symulacji modelu błędzenia losowego oraz autokorelacji wyników symulacji modelu na podstawie, którego zostało on sparametryzowany odpowiednio a) FM, b) FMNN, c) FMPlusNN.	69

8 Załączniki

Załącznik stanowi kod źródłowy modelu w języku programowania Java oraz kod źródłowy analizy danych w języku programowania R znajdujący się w internecie pod adresem:
<https://github.com/m-zbik/FinancialMarketModel>.

9 Streszczenie

Celem pracy jest stworzenie modelu rynku opartego na mechanizmie podwójnej ciągłej aukcji, poprzez którą oddziałują agenci typu ZIT (Zero Intelligence Trader) rozbudowanego o agentów typu „low-intelligence”. W pracy przyjęto model Farmera, i in. (2003) zakładający wykorzystanie agentów typu ZIT (cierpliwego i niecierpliwego). Model został rozszerzony o nowego agenta typu low-intelligence, który wykorzystuje algorytm sztucznych sieci neuronowych. Wyniki symulacji wieloagentowych przeprowadzonych w środowisku MASON wskazują, że wprowadzenie agenta typu low-intelligence nie wpływa na zachowanie rynku w sposób poprawiający jego efektywność według Fama (1970). Wyniki symulacji nie pozwoliły na potwierdzenie hipotezy Farmera, i in. (2003) o możliwości poprawy efektywności rynku poprzez wprowadzenie agenta typu low-intelligence.